

Recherche sémantique et graphes de connaissances pour le matching emploi-compétences : conception et évaluation interne d'un pipeline hybride

Irch Deffluviaire NGOULOU NGOUBILI

Institut Sous-régional de Statistique et d'Économie Appliquée (ISSEA)

Option Data Science et Marketing

Encadrement : Dr FOUTSE Yuehgoh

Data Scientist, PhD Computer Science

Mémoire professionnel - version article scientifique

Août 2026

Résumé

Le rapprochement entre profils de candidats et offres d'emploi reste difficile lorsque les compétences sont décrites avec des vocabulaires hétérogènes et que les systèmes de recommandation ne rendent pas leurs décisions explicites. Cet article présente un pipeline hybride de matching emploi-compétences combinant une recherche sémantique, un graphe de connaissances et une génération contrôlée. Le système harmonise 13 957 offres, 41 298 profils candidats et des référentiels métiers-compétences, puis adapte un encodeur SentenceTransformer avant d'indexer les représentations dans PostgreSQL/pgvector. Les relations entre candidats, compétences, métiers, formations et offres sont modélisées dans Neo4j afin de calculer la couverture des compétences et le *skill gap*. Sur 953 paires de test, l'encodeur adapté obtient une NDCG@10 de 0,6232, un MRR@10 de 0,5874 et un Recall@10 de 0,7398. Dans une ablation contrôlée sur un même vivier initial de 30 offres, l'ajout du graphe fait progresser la NDCG@10 de 0,5575 à 0,7392 et le MRR@10 de 0,6908 à 0,8093 selon un proxy de pertinence. Ces résultats établissent une amélioration interne du classement et une capacité d'explication relationnelle, mais ne constituent pas encore une preuve d'utilité métier ou d'impact sur l'insertion professionnelle. L'article documente ainsi une architecture opérationnelle et les conditions nécessaires à sa validation externe.

Mots-clés : recherche sémantique ; systèmes de recommandation ; emploi-compétences ; embeddings ; graphe de connaissances ; GraphRAG ; skill gap.

1 Introduction

L'appariement entre candidats et offres d'emploi est un problème de recommandation soumis à une forte hétérogénéité lexicale. Une même compétence peut être exprimée par un intitulé, une description d'expérience, un diplôme ou une formulation locale. Les approches par mots-clés sont alors sensibles à la surface textuelle, tandis que les systèmes fondés sur les interactions historiques exigent des données d'usage qui ne sont pas toujours disponibles dans les contextes émergents. Cette difficulté est également économique : l'information imparfaite et les frictions de recherche compliquent la rencontre entre l'offre et la demande de travail [Akerlof, 1970, Spence, 1973, Mortensen and Pissarides, 1994, Pissarides, 2000].

Les modèles de représentation dense permettent de comparer des textes selon leur proximité sémantique [Reimers and Gurevych, 2019, Muennighoff, 2022]. Cependant, une proximité vectorielle ne suffit pas toujours à expliquer la compatibilité professionnelle. Elle ne distingue pas nécessairement une compétence possédée d'une compétence requise, ne représente pas explicitement les chemins entre métiers et formations et peut reproduire les biais du corpus. Les graphes de connaissances fournissent une représentation complémentaire des entités et de leurs relations [Hogan et al., 2021, Schlichtkrull et al., 2018]. Les systèmes de génération augmentée par récupération peuvent ensuite produire une réponse conditionnée par des preuves récupérées [Lewis et al., 2020], sous réserve de contrôler la fidélité de la génération.

Cet article étudie donc la question suivante : *dans quelle mesure la combinaison d'une recherche sémantique et d'un graphe de connaissances peut-elle améliorer le classement et l'explicabilité d'un système de matching emploi-compétences ?* Le travail apporte trois contributions :

- un pipeline reproductible d'harmonisation, de représentation sémantique et de modélisation relationnelle pour des données d'emploi et de formation ;
- un moteur hybride qui utilise `pgvector` pour constituer un vivier puis `Neo4j` pour calculer la couverture et le *skill gap* ;
- une évaluation interne séparant le benchmark de l'encodeur, l'ablation du graphe, le réglage des poids et le contrôle de génération.

Les conclusions sont volontairement limitées à la faisabilité et aux performances internes mesurées avec les données disponibles. La pertinence métier n'est pas assimilée au proxy utilisé pour l'évaluation.

2 Travaux connexes

Les systèmes de recommandation fondés sur le contenu comparent les attributs des objets et du profil, alors que

les approches collaboratives exploitent les historiques d'interactions [Pazzani and Billsus, 2007, Koren et al., 2009, Ricci et al., 2011]. Dans le recrutement, ces historiques sont souvent incomplets et les interactions observées peuvent refléter des pratiques de sélection plutôt que la compétence réelle. Les modèles hybrides cherchent à combiner plusieurs signaux afin de réduire cette dépendance à une seule représentation [Burke, 2002].

Les encodeurs de phrases transforment un texte en vecteur dense utilisable pour le retrieval. Sentence-BERT a popularisé l'apprentissage de représentations adaptées à la comparaison de phrases [Reimers and Gurevych, 2019] ; les travaux de recherche sémantique évaluent notamment le rang du premier résultat et la qualité du top-*k* [Thakur et al., 2021, Muennighoff et al., 2023]. Dans le domaine des compétences, les graphes peuvent représenter les relations entre métiers, compétences et offres, et les méthodes neuronales peuvent exploiter leur structure [Goyal et al., 2023, He et al., 2020].

La génération augmentée par récupération réduit la dépendance aux connaissances paramétriques du modèle en lui fournissant un contexte externe [Lewis et al., 2020]. Les variantes GraphRAG ajoutent une navigation relationnelle, mais elles ne rendent pas automatiquement les données vraies : une réponse peut être fidèle à un contexte incomplet. Les workflows agentiques ajoutent une planification, des outils et une boucle de vérification [Yao et al., 2023, Asai et al., 2024]. Le présent travail se situe à l'intersection de ces approches, avec une architecture orientée vers l'application du matching plutôt que vers la seule génération de texte.

3 Méthodologie

3.1 Données et normalisation

Le corpus exploité contient 13 957 offres et 41 298 profils candidats. Il est complété par des référentiels de compétences et de professions, notamment ESCO [European Commission, 2024], ainsi que par des nomenclatures camerounaises des métiers et des formations [Ministère de l'Emploi et de la Formation Professionnelle, 2013]. Les données sont extraites, nettoyées et transformées dans une chaîne ETL. Les champs bruts sont conservés pour la traçabilité ; des champs normalisés décrivent le titre, le secteur, la localisation, le contrat, l'expérience, le niveau de qualification et les compétences.

Les textes destinés à l'encodage combinent les informations structurées et les descriptions nettoyées. Les diplômes et formations sont alignés sur des niveaux de qualification afin de limiter les divergences de codage. Les relations métiers-compétences issues des référentiels servent à enrichir le graphe et à distinguer la compétence directement

TABLE 1 – Composition synthétique du corpus exploité

Composante	Effectif	Fonction dans le pipeline
Offres d’emploi	13 957	Retrieval et recommandations
Profils candidats	41 298	Requêtes et calcul du skill gap
Compétences ESCO	13 939	Normalisation et relations
Professions ESCO	3 039	Enrichissement métier
Paires offre–description	6 476	Fine-tuning de l’encodeur

déclarée de la compétence associée à un métier.

La chaîne complète est organisée selon une séparation entre préparation, récupération, vérification et génération. Cette séparation permet d’identifier la contribution de chaque brique et limite le risque qu’un modèle génératif produise une recommandation sans preuve exploitable.




FIGURE 1 – Vue synthétique du pipeline hybride : normalisation, représentation vectorielle, graphe relationnel et génération contrôlée.

3.2 Représentation sémantique et fine-tuning

Le modèle de base est all-MiniLM-L6-v2, un encodeur dense produisant des vecteurs de 384 dimensions. Le fine-tuning utilise 6 476 paires offre–description, réparties en 4 542 observations d’entraînement, 981 de validation et 953 de test. L’apprentissage est réalisé pendant cinq époques, avec une taille de lot de 32, un taux maximal de 2×10^{-5} et une *Multiple Negatives Ranking Loss*. Les autres descriptions du lot jouent le rôle de négatifs implicites.

Pour une requête q et une offre o , la recherche vectorielle utilise une similarité cosinus :

$$s_{\text{vec}}(q, o) = \frac{e(q) \cdot e(o)}{\|e(q)\|_2 \|e(o)\|_2}. \quad (1)$$

Les vecteurs sont stockés et interrogés dans PostgreSQL avec l’index pgvector. Cette étape constitue un vivier initial d’offres sémantiquement proches ; elle ne fournit pas, à elle seule, une explication relationnelle.

3.3 Graphe et moteur hybride

Le graphe contient notamment des nœuds Candidat, Offre, Compétence, Métier et Formation. Le chemin central est représenté par

Candidat-POSSEDE-Compétence-REQUIERT-Offre.

Pour un couple candidat–offre, la couverture des compétences est définie par :

$$s_{\text{graph}}(c, o) = \frac{|K_c \cap K_o|}{|K_o|}, \quad (2)$$

où K_c désigne les compétences du candidat et K_o les compétences requises par l’offre. Le *skill gap* est $K_o \setminus K_c$, avec une attention particulière aux compétences nécessaires au métier et au niveau de qualification.

Le moteur hybride reclasse le vivier selon :

$$s_{\text{hyb}}(c, o) = \alpha s_{\text{vec}}(c, o) + \beta s_{\text{graph}}(c, o), \quad \alpha + \beta = 1. \quad (3)$$

Les poids sont calibrés sur 690 couples associés à 69 candidats évalués. Cette calibration ne doit pas être interprétée comme une preuve qu’un poids est universel : elle dépend du proxy, du vivier présélectionné et de la fonction objectif.

3.4 Orchestration et génération contrôlée

Le workflow LangGraph analyse l’intention, sélectionne les outils, exécute les requêtes, construit un contexte et transmet les preuves au LLM final. Une recommandation mobilise pgvector et Neo4j ; une question sur les référentiels mobilise la recherche documentaire ; une question relationnelle peut utiliser Text-to-Cypher, sous contrôle du schéma. Un critic compare ensuite la réponse aux éléments du contexte et renvoie une décision accept ou revise. Le seuil calibré est de 0,46 sur un test contrastif de 102 comparaisons.

3.5 Protocole d’évaluation

Le benchmark de représentation évalue le modèle sur les 953 paires de test avec la NDCG@10, le MRR@10 et le Recall@10. L’ablation compare deux variantes sur le même pool de 30 offres par candidat : pgvector seul conserve l’ordre vectoriel ; pgvector + graphe reclasse le même pool avec la couverture relationnelle. Le proxy de pertinence combine recouvrement lexical, compatibilité sectorielle et niveau de qualification. Il sert de référence commune, mais ne remplace pas une annotation humaine.

4 Résultats

4.1 Benchmark de l’encodeur

Le modèle adapté obtient une NDCG@10 de 0,6232, un MRR@10 de 0,5874 et un Recall@10 de 0,7398 sur les données de test. Ces métriques montrent que le fine-tuning améliore la récupération des descriptions associées dans la tâche construite. Elles ne mesurent cependant ni la satisfaction d’un recruteur ni la qualité d’une embauche.

TABLE 2 – Performance du modèle adapté sur les 953 paires de test

Modèle	NDCG@10	MRR@10	Recall@10
SentenceTransformer adapté	0,6232	0,5874	0,7398

4.2 Ablation du graphe

Le tableau 3 compare les deux variantes sur le même vivier. Le graphe augmente la NDCG@10 de 0,1817, le MRR@10 de 0,1185 et le Recall@10 de 0,1656. L’amélioration est cohérente avec la fonction du graphe : il apporte un signal de couverture et des explications de compétences, tandis que la recherche vectorielle assure le rappel initial.

TABLE 3 – Ablation sur le même pool initial, selon le proxy de pertinence

Variante	NDCG@10	MRR@10	Recall@10
pgvector seul	0,5575	0,6908	0,4491
pgvector + graphe	0,7392	0,8093	0,6147

La comparaison est informative parce que le pool initial est maintenu constant. Elle reste néanmoins une évaluation par proxy. Le gain ne peut donc pas être formulé comme une amélioration de la pertinence réelle des recrutements. En outre, 11 des 80 candidats tirés initialement n’ont pas pu être évalués en raison d’erreurs techniques ; les résultats portent sur 69 candidats.

4.3 Calibration et critic

Après 500 essais Optuna [Akiba et al., 2019], l’objectif fondé sur la NDCG@10 retient la frontière Neo4j seul dans le vivier déjà présélectionné par pgvector, avec une valeur de 0,9697 selon le proxy. Pour l’objectif combinant MRR@10 et précision, le compromis est de 0,6615 pour le signal vectoriel et de 0,3385 pour le signal relationnel. Cette différence montre qu’il n’existe pas de poids optimal indépendant de la fonction objectif et de l’échantillon.

Le critic accepte 50 des 51 contextes réels et rejette les 51 contextes mélangés au seuil 0,46. Ce test documente une capacité de contrôle lexical dans le protocole utilisé. Il ne garantit pas la vérité métier, la complétude du contexte ou l’absence d’hallucination dans des situations non testées.

5 Discussion et limites

Les résultats soutiennent l’intérêt d’une architecture en deux mémoires. pgvector fournit une représentation continue et un rappel sémantique ; Neo4j encode des relations explicites, calcule la couverture et expose le *skill gap*. L’intérêt principal du pipeline n’est donc pas seulement l’amélioration d’une métrique, mais la séparation fonctionnelle entre recherche, vérification et explication.

Trois limites réduisent cependant la portée des conclusions. Premièrement, le proxy de pertinence est construit à partir de signaux disponibles dans les données et peut favoriser les critères qu’il réutilise. Deuxièmement, l’absence d’annotations indépendantes de recruteurs empêche d’estimer une pertinence métier de référence. Troisièmement, l’échantillon d’ablation est limité et comporte des échecs techniques ; aucune validation utilisateur ne mesure encore la compréhension ou l’utilité des explications.

Le corpus peut également contenir des biais de couverture, de secteur, de localisation et de collecte. Les résultats ne permettent donc pas d’affirmer une généralisation à l’ensemble du marché camerounais, encore moins une amélioration causale de l’emploi. Une validation future devrait inclure un jeu annoté par plusieurs recruteurs, une mesure de l’accord inter-évaluateurs, des tests utilisateurs, une analyse par sous-groupes et une évaluation temporelle hors échantillon. La reproductibilité exige en outre la publication des scripts, des versions de données, des paramètres d’indexation et des journaux d’exécution, sous réserve des contraintes de confidentialité.

6 Conclusion

Cet article a présenté un pipeline hybride pour le matching emploi-compétences combinant embeddings, recherche vectorielle, graphe de connaissances et génération contrôlée. Le modèle adapté obtient de bonnes performances dans le benchmark construit, et l’ablation indique un gain du graphe sur le même vivier initial selon le proxy disponible. Le système fournit en outre une représentation explicite des compétences couvertes et manquantes.

La conclusion défendable est celle d’une faisabilité technique et d’un apport interne mesurable du graphe, non celle d’une preuve d’impact sur le recrutement. La prochaine étape scientifique consiste à remplacer le proxy par des annotations humaines, à évaluer l’utilité des explications

et à étudier la robustesse du système selon les secteurs, les niveaux de qualification et les sources de données.

Déclaration sur l'utilisation d'outils d'IA

Les outils d'intelligence artificielle peuvent avoir été utilisés comme assistants de rédaction, de reformulation ou de programmation. Les auteurs restent responsables de la vérification des données, des méthodes, des résultats, des références et de la version finale du manuscrit. La déclaration définitive doit être adaptée aux règles de la revue ou de la conférence ciblée.

Références

- George A. Akerlof. The market for "lemons": Quality uncertainty and the market mechanism. *The Quarterly Journal of Economics*, 84(3):488–500, 1970. doi: 10.2307/1879431.
- Michael Spence. Job market signaling. *The Quarterly Journal of Economics*, 87(3):355–374, 1973. doi: 10.2307/1882010.
- Dale T. Mortensen and Christopher A. Pissarides. Job creation and job destruction in the theory of unemployment. *The Review of Economic Studies*, 61(3):397–415, 1994. doi: 10.2307/2297896.
- Christopher A. Pissarides. *Equilibrium Unemployment Theory*. MIT Press, Cambridge, MA, 2 edition, 2000.
- Nils Reimers and Iryna Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of EMNLP-IJCNLP*, pages 3982–3992, 2019. URL <https://aclanthology.org/D19-1410/>.
- Niklas Muennighoff. Sgpt: Gpt sentence embeddings for semantic search, 2022.
- Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d'Amato, Gerard de Melo, Claudio Gutierrez, Sabrina Kirrane, José Emilio Labra Gayo, Roberto Navigli, Sebastian Neumaier, et al. Knowledge graphs. *ACM Computing Surveys*, 54(4):1–37, 2021. doi: 10.1145/3447772.
- Michael Sejr Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, and Max Welling. Modeling relational data with graph convolutional networks. In *The Semantic Web – 15th International Conference, ESWC 2018*, volume 10843 of *Lecture Notes in Computer Science*, pages 593–607. Springer, 2018. doi: 10.1007/978-3-319-93417-4_38. URL https://doi.org/10.1007/978-3-319-93417-4_38.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems*, 33:9459–9474, 2020. URL <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- Michael J. Pazzani and Daniel Billsus. Content-based recommendation systems. *The Adaptive Web*, pages 325–341, 2007. doi: 10.1007/978-3-540-72079-9_10.
- Yehuda Koren, Robert Bell, and Chris Volinsky. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30–37, 2009. doi: 10.1109/MC.2009.263.
- Francesco Ricci, Lior Rokach, Bracha Shapira, and Paul B. Kantor, editors. *Recommender Systems Handbook*. Springer, 2011. doi: 10.1007/978-0-387-85820-3.
- Robin Burke. Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, 12:331–370, 2002. doi: 10.1023/A:1021240730564.
- Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *Advances in Neural Information Processing Systems*, volume 34, pages 28974–28989, 2021. URL <https://arxiv.org/abs/2104.08663>.
- Niklas Muennighoff, Nouamane Tazi, Loïc Magne, and Nils Reimers. MTEB: Massive text embedding benchmark. In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2014–2037, 2023. URL <https://aclanthology.org/2023.eacl-main.148/>.
- Nidhi Goyal, Jushaan Kalra, Charu Sharma, Raghava Mutharaju, Niharika Sachdeva, and Ponnurangam Kumaraguru. Jobxmlc: Extreme multi-label classification of job skills with graph neural networks. In *Findings of the Association for Computational Linguistics: EACL 2023*, pages 2181–2191. Association for Computational Linguistics, 2023. doi: 10.18653/v1/2023.findings-eacl.163. URL <https://aclanthology.org/2023.findings-eacl.163/>.
- Xiangnan He, Kuan Deng, Xiang Wang, Yan Li, Yongdong Zhang, and Meng Wang. Lightgcn: Simplifying and powering graph convolution network for recommendation. In *Proceedings of SIGIR*, pages 639–648, 2020.
- Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafra, Karthik Narasimhan, and Yuan Cao. React: Synergizing reasoning and acting in language models. In

International Conference on Learning Representations, 2023. URL https://openreview.net/forum?id=WE_vluYUL-X.

Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-rag: Learning to retrieve, generate, and critique through self-reflection. In *International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=hSyW5go0v8>.

European Commission. Esco: European skills, competences, qualifications and occupations, 2024. URL <https://esco.ec.europa.eu/>.

Ministère de l’Emploi et de la Formation Professionnelle. Nomenclature camerounaise des métiers, 2013.

Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 2623–2631, 2019. doi: 10.1145/3292500.3330701.