

*Communauté Économique et Monétaire  
de l'Afrique Centrale  
(CEMAC)*



*Institut Sous-régional de Statistique  
et d'Économie Appliquée*

Organisation Internationale

BP : 294 Yaoundé - Tél : 222 220 134

*Cameroon AI Enthousiaste*



*Direction du Développement et de la  
Recherche*

ONG camerounaise

BP : 83000 Toulon, France

*Mémoire professionnel de fin d'étude présenté en vue de l'obtention du  
diplôme d'Ingénieur Statisticien Économiste (ISE)*

*OPTION : Data Science et Marketing*

## CONCEPTION D'UN SYSTEME DE RECOMMANDATION HYBRIDE POUR LE MATCHING EMPLOI-COMPETENCES AU CAMEROUN PAR INTEGRATION DES LLMS ET DES GRAPHES DE CONNAISSANCES

Rédigé par :

NGOULOU NGOUBILI Irch Defluviaire

Élève Ingénieur Statisticien Économiste cycle long – 5<sup>e</sup> année

Sous l'encadrement de :

Dr. FOUTSE Yuehgoh

Présidente & Directrice exécutive adjointe, PhD Computer Science & Data Scientist

Année académique 2025-2026

---

# Dédicace

---

*À mes parents... (Max 1 page)*

---

# Remerciements

---

---

# Sommaire

---

|                                                                                                                 |               |
|-----------------------------------------------------------------------------------------------------------------|---------------|
| Dédicace                                                                                                        | i             |
| Remerciements                                                                                                   | ii            |
| Liste des sigles et abréviations                                                                                | v             |
| Liste des tableaux                                                                                              | vi            |
| Liste des figures                                                                                               | vii           |
| Avant-propos                                                                                                    | viii          |
| Résumé                                                                                                          | ix            |
| Abstract                                                                                                        | x             |
| Introduction générale                                                                                           | 1             |
| <br><b>I Cadre théorique et conceptuel</b>                                                                      | <br><b>4</b>  |
| <b>1 Fondements théoriques et revue de la littérature sur l'IA générative et les systèmes de recommandation</b> | <b>5</b>      |
| 1.1 Marché de l'emploi, information imparfaite et appariement des compétences . . . . .                         | 5             |
| 1.2 Les fondements des LLMs . . . . .                                                                           | 8             |
| 1.3 Généralité sur le fine-tuning des modèles de LLMs . . . . .                                                 | 14            |
| 1.4 Généralité sur des BD vectorielles et orientées graphes . . . . .                                           | 16            |
| 1.5 Généralité sur les systèmes de recommandation . . . . .                                                     | 20            |
| 1.6 Recherche sémantique et Génération Augmentée par Récupération (RAG) . . . . .                               | 22            |
| 1.7 Métriques d'évaluation des systèmes de recommandation . . . . .                                             | 22            |
| <b>2 Approche méthodologique et données</b>                                                                     | <b>24</b>     |
| <br><b>II Présentation des resultats</b>                                                                        | <br><b>25</b> |
| <b>3 Présentation et analyse des résultats</b>                                                                  | <b>26</b>     |
| <b>4 Discussion et recommandations</b>                                                                          | <b>27</b>     |

|                            |           |
|----------------------------|-----------|
| <b>Conclusion générale</b> | <b>I</b>  |
| <b>Bibliographie</b>       | <b>I</b>  |
| <b>Bibliographie</b>       | <b>II</b> |
| <b>A Annexes</b>           | <b>V</b>  |

---

# Liste des sigles et abréviations

---

---

# Liste des tableaux

---

|     |                                                                                                  |    |
|-----|--------------------------------------------------------------------------------------------------|----|
| 1.1 | Comparaison des embeddings statiques et contextuels. . . . .                                     | 11 |
| 1.2 | Variantes architecturales des LLMs et leurs applications au matching emploi-compétences. . . . . | 14 |
| 1.3 | Métriques d'évaluation des systèmes de recommandation emploi-compétences. . . . .                | 23 |

---

# Table des figures

---

|     |                                                        |    |
|-----|--------------------------------------------------------|----|
| 1.1 | Évolution chronologique des LLMs (2013-2024) . . . . . | 9  |
| 1.2 | Mécanisme de self-attention . . . . .                  | 12 |
| 1.3 | Architecture complète du Transformer . . . . .         | 13 |



---

# Avant-propos

---

L’Institut Sous-régional de Statistique et d’Économie Appliquée (ISSEA), institution spécialisée de la CEMAC créée en 1984, a pour mission principale la formation de cadres supérieurs en statistique, économie et data science, capables de répondre aux enjeux contemporains de décision fondée sur les données. Dans ce cadre, l’ISSEA propose plusieurs filières de formation, parmi lesquelles figure celle des Ingénieurs Statisticiens Économistes (ISE), alliant rigueur mathématique, modélisation économétrique et outils modernes d’analyse de données (Data Science).

Arrivés à un niveau avancé de leur formation, les élèves Ingénieurs Statisticiens Économistes sont tenus d’effectuer un stage professionnel d’une durée minimale de trois (03) mois. Ce stage constitue une phase essentielle du cursus, permettant de confronter les connaissances théoriques acquises à des problématiques réelles, tout en favorisant l’acquisition de compétences opérationnelles en environnement professionnel. Il est sanctionné par la rédaction d’un mémoire professionnel, soutenu devant un jury.

C’est dans ce cadre que nous avons effectué un stage du [DATE DE DÉBUT] au [DATE DE FIN] au sein de KmerAI, où nous avons été intégrés au département de la recherche et de l’innovation. Cette immersion nous a permis de travailler sur des problématiques liées à l’analyse de données, intelligence artificielle, traitement du langage naturel, aide à la décision, etc, en lien direct avec les besoins opérationnels de la structure d’accueil.

Le présent mémoire s’inscrit dans cette dynamique et porte sur le thème : « Conception d’un système de recommandation hybride pour le matching emploi-compétences au Cameroun par intégration des LLMs et des graphes de connaissances ». Il vise à [OBJECTIF PRINCIPAL : ex. concevoir un système de recommandation, analyser des données économiques, développer un modèle prédictif, réaliser un audit sémantique, etc.]. Plus spécifiquement, il s’agit de [OBJECTIFS SPÉCIFIQUES : modélisation, implémentation, évaluation, interprétation].

Ce travail répond à un double enjeu : d’une part, apporter une contribution analytique et méthodologique à la problématique étudiée, et d’autre part, proposer des outils opérationnels susceptibles d’améliorer la prise de décision au sein de la structure d’accueil.

---

# Résumé

---

**Mots-clés :** Économétrie, Statistique, Développement...

---

# Abstract

---

---

# INTRODUCTION GÉNÉRALE

---

## Contexte et justification

Le fonctionnement du marché de l'emploi constitue un déterminant central de la performance économique et sociale d'un pays. Au Cameroun, ce marché reste marqué par des déséquilibres structurels persistants, notamment l'inadéquation entre les compétences disponibles et les besoins des entreprises, la forte informalité et les difficultés d'insertion professionnelle des jeunes. Les données disponibles montrent que le chômage des jeunes demeure une réalité importante, avec un taux estimé à 6,6% en 2024 et 6,5% en 2025 selon les estimations modélisées de l'OIT relayées par la Banque Mondiale et la base FRED. Par ailleurs, plusieurs travaux sur le Cameroun soulignent que le problème ne tient pas uniquement au manque d'emplois, mais aussi à un mismatch entre formation, compétences et exigences du marché.

Dans ce contexte, la question du matching emploi-compétences devient centrale. En théorie, un marché du travail efficient devrait permettre d'associer rapidement les profils disposant des compétences requises aux postes vacants correspondants. En pratique, plusieurs frictions informationnelles persistent : asymétrie d'information entre recruteurs et candidats, faible structuration des profils de compétences, hétérogénéité des offres d'emploi et faiblesse des systèmes d'intermédiation comme le FNE et certains agences de recrutement. Ces dysfonctionnements conduisent à une situation paradoxale où coexistent des postes non pourvus et des chercheurs d'emploi, traduisant une inefficacité allocative du marché du travail.

Par ailleurs, l'essor des technologies numériques et de l'intelligence artificielle ouvre des perspectives nouvelles pour améliorer l'appariement entre offres et profils. Dans cette dynamique, KmerAI se positionne comme une plateforme camerounaise dédiée à la promotion de l'intelligence artificielle, à la vulgarisation de ses usages et à l'accompagnement des étudiants, chercheurs et entreprises dans l'adoption de solutions innovantes adaptées au contexte local. Ses missions consistent notamment à former aux bases de l'IA, à offrir un espace de partage d'expériences et à encourager la collaboration autour de cas d'usage appliqués à des secteurs stratégiques tels que la santé, l'agriculture, le transport, l'éducation et le marketing.

Cette orientation est particulièrement pertinente pour le marché de l'emploi camerounais, où les données liées aux offres, aux CV et aux compétences restent souvent dispersées et peu exploitées. Une approche fondée sur l'intelligence artificielle peut permettre d'analyser plus efficacement ces données hétérogènes afin de proposer des recommandations d'emploi plus pertinentes, plus rapides et plus personnalisées.

## Problématique

Le marché de l'emploi camerounais est marqué par une forte asymétrie d'information, une hétérogénéité des profils professionnels et des offres d'emploi, ainsi qu'une faible capacité des outils classiques à évaluer les écarts réels de compétences. Les systèmes fondés sur des mots-clés ou des filtres statiques ne parviennent pas à détecter les compétences implicites, les équivalences sémantiques et les trajectoires de montée en compétences.

Par ailleurs, si des référentiels structurants existent notamment la Nomenclature Camerounaise des

Métiers (NCM 2013) et le référentiel européen ESCO leur intégration opérationnelle dans les plateformes et outils d'appariement reste encore limitée. Ils sont peu exploités pour aligner les intitulés locaux de métiers sur des standards internationaux, harmoniser les compétences attendues, et rendre les correspondances profil-offre plus transparentes et comparables. Il en résulte un décalage entre la richesse potentielle de ces référentiels et leur usage effectif dans les systèmes d'information dédiés à l'emploi.

Dans ce contexte, la question centrale n'est plus seulement d'apparier un profil à une offre, mais de concevoir un système capable (i) d'exploiter conjointement les référentiels NCM et ESCO pour structurer les métiers et compétences, (ii) de mesurer finement le *skill gap* entre un candidat et un poste cible, et (iii) de proposer un parcours de montée en compétences lisible et actionnable. La question principale de recherche peut ainsi être formulée comme suit :

*Comment concevoir un système de recommandation hybride, fondé sur les LLMs, les graphes de connaissances, les embeddings vectoriels et le filtrage collaboratif, capable de mesurer le skill gap entre un profil et une offre d'emploi, puis de recommander un parcours de montée en compétences adapté au métier visé pour les membres de la communauté KmerAi ?*

Cette question générale se décline en plusieurs questions de recherche sous-jacentes :

- **Q1** : Comment identifier et formaliser, dans le contexte camerounais, les compétences, métiers et relations pertinentes pour un matching emploi-compétences fiable et opérationnel à partir des référentiels NCM 2013 et ESCO ?
- **Q2** : Dans quelle mesure l'intégration d'un graphe de connaissances améliore-t-elle la qualité et la précision du matching par rapport aux approches purement vectorielles ?

## Objectifs de l'étude

L'objectif général est de concevoir un système de recommandation hybride emploi-compétences capable d'identifier les écarts de compétences, de classer les correspondances avec les offres d'emploi et de proposer une roadmap personnalisée d'amélioration du profil. En d'autres termes, il s'agit de construire un modèle capable de faire des suggestions pertinentes non seulement en se basant sur des mots-clés, mais aussi sur le contexte et les significations partagées entre les offres et les demandeurs d'emploi. Plus spécifiquement il sera question de :

- identifier et formaliser les compétences, métiers et relations pertinentes pour le matching emploi-compétences dans le contexte camerounais ;
- concevoir un graphe de connaissances sous Neo4j représentant les liens entre candidats, compétences, métiers, secteurs et offres ;
- développer un module de similarité sémantique basé sur pgvector et un module d'enrichissement/extraction basé sur LLM ;
- construire un moteur de recommandation hybride intégrant le filtrage collaboratif, le calcul du skill gap et la génération d'une roadmap explicative.

## Intérêt de l'étude

L'intérêt d'une telle approche est renforcé par les limites des méthodes classiques de recrutement, souvent fondées sur des critères statiques ou sur des mots-clés, qui ne captent pas toujours la richesse

des parcours et des compétences. En combinant différentes logiques de recommandation, un système hybride peut mieux prendre en compte les dimensions explicites et implicites des profils candidats, tout en améliorant la qualité des correspondances proposées. Cela rejoint la mission de KmerAI, qui vise à favoriser l'appropriation locale de l'IA pour résoudre des problèmes concrets du développement camerounais.

## Hypothèses de recherche

Afin de répondre à la problématique, cette étude repose sur les hypothèses suivantes.

- **H1** : L'intégration conjointe de la NCM 2013 et d'ESCO dans un référentiel unifié métiers-compétences améliore la structuration et les performances d'appariement profil-offre, par rapport à une approche sans ces référentiels ;
- **H2** : La modélisation du marché de l'emploi sous forme de graphe de connaissances (Neo4j) améliore la qualité du matching par rapport à une approche purement vectorielle ;
- **H3** : Le *fine-tuning* d'un modèle de représentation sémantique sur le domaine emploi-compétences améliore la qualité des embeddings et la similarité sémantique entre profils et offres, par rapport au même modèle non adapté ;
- **H4** : La combinaison d'un RAG vectoriel, d'un GraphRAG et d'un score de recommandation hybride améliore la pertinence et l'explicabilité des recommandations de *skill gap* et de parcours de montée en compétences.

## Méthodologie de recherche

La démarche adoptée s'inscrit dans un cadre d'ingénierie des données combinant structuration des connaissances et modélisation hybride. Elle repose sur la collecte et la normalisation des données issues d'offres d'emploi sur les différents sites web et de profils, alignées sur la NCM 2013 afin d'assurer la cohérence sémantique. Un graphe de connaissances est ensuite construit sous Neo4j en intégrant les référentiels ESCO et NCM, à partir d'un processus d'extraction automatique de triplets à partir des données textuelles. Parallèlement, les descriptions sont vectorisées et indexées dans un espace sémantique permettant la mesure de similarité. Le moteur de recommandation combine ces différentes sources d'information à travers un score hybride intégrant similarité structurelle, similarité sémantique et signal collaboratif. Le système permet ainsi d'identifier les écarts de compétences entre profils et offres, et de générer des recommandations sous forme de trajectoires d'apprentissage. L'évaluation repose sur des métriques standard telles que la précision@K, le rappel et le NDCG, ainsi que sur l'analyse de la cohérence des recommandations générées.

## Plan du travail

Le mémoire est structuré en trois parties. La première présente le cadre théorique relatif aux systèmes de recommandation, aux modèles de langage et aux graphes de connaissances. La deuxième détaille l'approche méthodologique, incluant la modélisation du graphe et la conception du système hybride. La troisième analyse les résultats obtenus et discute les performances du modèle ainsi que ses implications dans le contexte du marché du travail camerounais.

## Première partie

# Cadre théorique et conceptuel

# FONDEMENTS THÉORIQUES ET REVUE DE LA LITTÉRATURE SUR L'IA GÉNÉRATIVE ET LES SYSTÈMES DE RECOMMANDATION

Ce chapitre constitue la colonne vertébrale théorique du présent mémoire. Il vise à positionner ce travail dans le paysage scientifique actuel en passant en revue les avancées les plus significatives dans six domaines complémentaires et interdépendants : le fonctionnement du marché de l'emploi, les LLMs, les systèmes de recommandation, la théorie des graphes et les graphes de connaissances, la recherche sémantique et la RAG, les métriques d'évaluation, ainsi que les défis et limites identifiés dans la littérature.

## 1.1 Marché de l'emploi, information imparfaite et appariement des compétences

Le thème du matching emploi-compétences ne peut pas être réduit à un problème purement informatique. Il s'inscrit d'abord dans une problématique économique classique : comment un marché du travail met-il en relation des travailleurs hétérogènes, porteurs de compétences observables et non observables, avec des emplois eux-mêmes hétérogènes par leurs exigences techniques, organisationnelles et sectorielles ? Dans un cadre concurrentiel simplifié, l'ajustement entre l'offre et la demande de travail devrait s'opérer par les salaires et conduire à une allocation efficace des travailleurs vers les postes où leur productivité est la plus élevée. Cette représentation est toutefois insuffisante pour analyser les marchés du travail réels, particulièrement dans les économies où l'information sur les compétences, les postes disponibles et les trajectoires de formation est incomplète.

### 1.1.1 Le marché du travail comme marché d'appariement

La théorie moderne de la recherche d'emploi considère le marché du travail comme un marché d'appariement plutôt que comme un simple marché d'équilibre instantané. Les travailleurs ne trouvent pas immédiatement l'emploi correspondant à leurs compétences, et les entreprises ne rencontrent pas instantanément le candidat adapté à leurs besoins. La rencontre entre offre et demande implique donc des coûts de recherche, des délais, des incertitudes et des frictions informationnelles. Les modèles de recherche et d'appariement de Mortensen et Pissarides montrent que le chômage peut coexister avec des postes vacants, non pas uniquement parce que le niveau global de demande est insuffisant, mais aussi parce que le processus de rencontre entre travailleurs et entreprises est imparfait [1, 2].

Cette approche est particulièrement pertinente pour le contexte du présent mémoire. Un système de recommandation emploi-compétences cherche précisément à réduire ces frictions : il améliore la visibilité



des offres, structure les profils, compare les compétences détenues et requises, puis propose des correspondances classées. Autrement dit, il agit comme une technologie d'intermédiation. Sa valeur ne réside donc pas seulement dans sa performance algorithmique, mais dans sa capacité à améliorer l'efficacité du mécanisme d'appariement sur le marché de l'emploi.

### 1.1.2 Asymétrie d'information et signalement des compétences

Le marché de l'emploi est aussi marqué par une forte asymétrie d'information. Les candidats connaissent mieux que les recruteurs certaines dimensions de leurs compétences, de leur motivation et de leur capacité d'apprentissage. Inversement, les entreprises connaissent mieux que les candidats la réalité des tâches, les conditions de travail et les compétences effectivement valorisées dans le poste. Akerlof a montré que l'asymétrie d'information peut conduire à une sélection adverse, c'est-à-dire à une dégradation de la qualité moyenne des échanges lorsque les acteurs ne peuvent pas distinguer correctement les bons et les mauvais profils [3]. Sur le marché du travail, ce problème se traduit par une difficulté à identifier les candidats réellement compétents lorsque les informations disponibles sont incomplètes, non standardisées ou difficilement comparables.

Dans cette perspective, les diplômes, certifications, expériences professionnelles et portefeuilles de projets jouent un rôle de signal. La théorie du signalement de Spence explique que certains attributs observables permettent aux candidats de transmettre une information crédible sur leur productivité potentielle [4]. Toutefois, dans les métiers numériques et dans les environnements où les compétences évoluent rapidement, les signaux traditionnels deviennent incomplets. Un intitulé de diplôme ne suffit pas toujours à inférer la maîtrise effective de Python, de l'analyse de données, de la gestion de bases relationnelles ou de la conception d'API. Le recours à des référentiels de compétences comme la NCM et ESCO, combinés à des représentations sémantiques, permet alors de transformer des signaux dispersés en informations structurées et comparables.

### 1.1.3 Capital humain, compétences et inadéquation

La théorie du capital humain considère l'éducation, la formation et l'expérience comme des investissements qui accroissent la productivité individuelle et les revenus futurs [5]. Cette théorie justifie l'importance accordée aux compétences dans l'analyse du marché du travail. Cependant, posséder un capital humain ne garantit pas automatiquement une bonne insertion professionnelle. Encore faut-il que les compétences acquises correspondent aux compétences demandées. Le problème central devient alors celui de l'inadéquation, ou *mismatch*, entre formation, compétences et besoins productifs.

L'inadéquation peut prendre plusieurs formes. Elle peut être verticale lorsqu'un individu est surqualifié ou sous-qualifié pour un poste. Elle peut être horizontale lorsque le domaine de formation ou d'expérience ne correspond pas au contenu réel de l'emploi. Elle peut enfin être sémantique lorsque les mêmes compétences sont décrites par des termes différents dans les CV, les offres d'emploi et les référentiels métiers. C'est cette dernière forme qui justifie directement l'utilisation des LLMs, des embeddings et des graphes de connaissances : le système doit reconnaître que des formulations différentes peuvent renvoyer à des compétences proches, complémentaires ou substituables.

### 1.1.4 Transformation numérique et demande de compétences

Les travaux récents sur le changement technologique montrent que la demande de travail se transforme sous l'effet de l'automatisation, de la numérisation et de la polarisation des tâches. Autor souligne que les technologies ne remplacent pas simplement des emplois entiers ; elles modifient surtout la composition des tâches au sein des métiers [6]. Cette distinction est décisive pour un système de recommandation. Apparier un candidat à un métier ne suffit plus : il faut identifier les tâches et les compétences associées, puis mesurer l'écart entre le profil actuel et le profil cible.

Dans le contexte camerounais, cette logique est encore plus importante car les intitulés de postes peuvent être peu standardisés, les parcours professionnels hétérogènes et les données d'emploi souvent non structurées. Un moteur hybride combinant graphes de connaissances, embeddings vectoriels et LLMs permet de représenter plus finement les relations entre métiers, compétences, secteurs, formations et trajectoires de montée en compétence. Il répond ainsi à une limite fondamentale du marché de l'emploi : l'information utile existe souvent, mais elle est dispersée, ambiguë et difficilement exploitable sans structuration algorithmique.

Ainsi, la littérature économique fournit le socle théorique du présent travail. Les systèmes de recommandation ne sont pas seulement des outils techniques ; ils peuvent être analysés comme des dispositifs d'intermédiation visant à réduire les coûts de recherche, les asymétries d'information et l'inadéquation des compétences. Cette lecture permet de relier directement la contribution informatique du mémoire à une problématique économique : améliorer l'efficacité de l'appariement sur le marché du travail camerounais.

### 1.1.5 Compétences, formation et besoin de standardisation

La notion de compétence occupe une place centrale dans l'analyse contemporaine du marché du travail. Elle ne se limite pas à la possession d'un diplôme ou à l'accumulation d'années d'expérience ; elle renvoie à la capacité effective de mobiliser des connaissances, des savoir-faire, des attitudes professionnelles et des ressources cognitives dans une situation de travail donnée. Dans une économie où les métiers se transforment rapidement, l'employabilité dépend donc moins d'un titre scolaire isolé que d'un portefeuille de compétences actualisables, transférables et lisibles par les employeurs.

La formation intervient comme le mécanisme principal de constitution, d'actualisation et de reconversion de ce portefeuille. Dans la perspective du capital humain, elle accroît la productivité attendue des individus et améliore leurs perspectives d'insertion [5]. Mais cette relation n'est pas mécanique. Une formation peut être de bonne qualité sur le plan académique tout en restant faiblement alignée sur les besoins opérationnels du marché. Inversement, un candidat peut disposer de compétences utiles sans que celles-ci soient visibles dans son CV, parce qu'elles sont décrites avec des termes non standardisés, dispersées dans des expériences informelles ou absentes des nomenclatures utilisées par les recruteurs.

Ce point est décisif pour le Cameroun. Le problème du matching emploi-compétences ne vient pas seulement d'un déficit de formation ; il vient aussi d'un déficit de lisibilité. Les candidats décrivent leurs capacités avec des formulations hétérogènes, les entreprises expriment leurs besoins dans des langages métier variables, et les plateformes d'emploi exploitent souvent des mots-clés sans comprendre les équivalences entre compétences proches. Par exemple, « analyse de données », « data analytics », « exploitation statistique » et « reporting décisionnel » peuvent désigner des familles de compétences partiellement communes, mais un moteur lexical naïf peut les traiter comme des réalités séparées.

C'est précisément ici qu'une nomenclature de standardisation devient stratégique. Une nomenclature métiers-compétences fournit un langage commun pour nommer les professions, les activités, les compétences et les niveaux de qualification. La NCM permet d'ancrer l'analyse dans le contexte camerounais, tandis que le référentiel européen ESCO propose une structuration fine des relations entre professions, aptitudes, compétences et qualifications [7]. L'intérêt n'est pas de remplacer les intitulés locaux par des catégories étrangères, mais de construire une table de correspondance entre les formulations observées dans les données et des concepts stabilisés.

Une telle standardisation produit trois gains analytiques. Premièrement, elle améliore la comparabilité : deux profils peuvent être comparés même s'ils utilisent des vocabulaires différents. Deuxièmement, elle réduit l'ambiguïté : une compétence peut être rattachée à une famille, à un métier ou à un niveau d'exigence. Troisièmement, elle rend possible l'explicabilité : le système peut justifier une recommandation en indiquant quelles compétences sont communes, quelles compétences manquent et quelles formations permettent de combler l'écart.

Cependant, une nomenclature tabulaire reste insuffisante si elle ne représente que des listes. Le marché de l'emploi est relationnel par nature : un métier exige des compétences, une compétence appartient à une famille, une formation développe certaines compétences, une compétence peut être proche ou complémentaire d'une autre, et un candidat peut viser plusieurs trajectoires professionnelles. La modélisation en graphe devient alors pertinente, car elle permet de représenter explicitement ces relations. Dans un graphe de connaissances, les entités *Candidat*, *Offre*, *Métier*, *Compétence*, *Formation*, *Secteur* et *Niveau* sont reliées par des arcs sémantiques tels que « possède », « exige », « développe », « est proche de » ou « appartient à ».

Ce passage de la nomenclature vers le graphe est essentiel pour le présent mémoire. La nomenclature apporte le vocabulaire contrôlé ; le graphe apporte la structure relationnelle ; les embeddings et les LLMs apportent la capacité à traiter les formulations non structurées. L'enjeu méthodologique consiste donc à articuler ces trois niveaux : normaliser les métiers et compétences, représenter leurs relations dans Neo4j, puis exploiter ces relations pour calculer un *skill gap* et recommander des formations adaptées. Sans cette couche de standardisation, le système risque de produire des correspondances superficielles ; sans la couche graphe, il risque de perdre l'information relationnelle nécessaire à une recommandation explicable.

## 1.2 Les fondements des LLMs

L'avènement des LLMs a profondément redéfini le champ de l'IA appliquée au langage. **Alammar et Grootendorst** (2024) qualifient l'année 2023 d'« année de l'IA générative », soulignant qu'en l'espace de quelques mois, ces modèles ont transformé en profondeur des tâches aussi variées que la traduction automatique, la génération de texte, la synthèse documentaire et la recommandation. Pour comprendre cette rupture technologique, il est nécessaire d'en restituer les fondements théoriques. Cette section retrace d'abord l'évolution historique du NLP jusqu'aux LLMs, présente ensuite l'architecture Transformer et le mécanisme d'attention qui en constitue le cœur, explicite la notion d'embedding et de représentation vectorielle, avant de comparer les principales variantes architecturales des LLMs.

### 1.2.1 Définition et évolution historique des LLMs en NLP

Le NLP, désigne le sous-domaine de l'IA dédié au développement de technologies capables de comprendre, traiter et générer le langage humain (Alammar & Grootendorst, 2024, chap. 1). Les deux termes sont aujourd'hui employés de manière largement interchangeable, en raison du succès continu des méthodes d'apprentissage automatique dans le traitement des problèmes linguistiques.

Un modèle de langage est, dans sa définition la plus générale, un système probabiliste qui attribue une probabilité à une séquence de mots (ou plus précisément à une séquence de tokens). Un Large Language Model est un modèle de langage à très grand nombre de paramètres généralement entraîné sur un corpus textuel massif capable de représenter ou de générer du texte avec une cohérence proche de celle de l'humain. Alammar et Grootendorst (2024) insistent toutefois sur le caractère évolutif de cette définition : le qualificatif « large » est arbitraire et dépend de l'état de l'art à un instant donné. Les auteurs proposent une lecture étendue qui inclut, sous le vocable LLM, à la fois les modèles génératifs (de type GPT, qui produisent du texte) et les modèles de représentation (de type BERT, qui produisent des plongements vectoriels exploitables pour la classification, la recherche sémantique ou le clustering).


### 1.2.2 Une évolution en plusieurs étapes

L'histoire du NLP peut être structurée en quatre grandes étapes successives comme illustre la figure 1.1 :

#### 1.2.2.1 Les approches statistiques et le sac-de-mots (Bag-of-Words)

La représentation textuelle par sac-de-mots, théorisée dans les années 1950 et popularisée dans les années 2000, constitue le point de départ historique du NLP moderne. Elle consiste à découper un texte en tokens (généralement des mots), à construire un vocabulaire, puis à représenter chaque document par un vecteur de comptages. Bien que simple et toujours utile en complément de modèles plus récents, cette approche présente une limite fondamentale : elle ignore la sémantique et le contexte, considérant le texte comme un simple ensemble non ordonné de mots.

FIGURE 1.1 – Évolution chronologique des LLMs (2013-2024)



Source : Auteur

### 1.2.2.2 Les représentations vectorielles denses Word2Vec (2013) :

L'introduction de Word2Vec par Mikolov et al. (2013) marque une rupture majeure. A l'aide d'un réseau de neurones peu profond, le modèle apprend des plongements vectoriels (embeddings) qui capturent les régularités sémantiques entre mots, en s'appuyant sur l'hypothèse distributionnelle selon laquelle « des mots qui apparaissent dans des contextes similaires ont des sens similaires ». Pour la première fois, des opérations algébriques sur les vecteurs de mots (par exemple roi - homme + femme = reine) deviennent significatives. Word2Vec produit toutefois des représentations statiques : le mot « banque » a la même représentation, qu'il désigne une institution financière ou la rive d'un fleuve.

### 1.2.2.3 Les réseaux récurrents et l'introduction de l'attention (2014-2016)

Pour modéliser le caractère séquentiel du langage, les RNN, notamment dans leurs variantes LSTM et GRU, ont été largement adoptés. Couplés en architecture encodeur-décodeur, ils ont permis d'aborder des tâches complexes comme la traduction automatique. Cependant, le traitement séquentiel impose la compression de toute l'information d'une phrase d'entrée dans un unique vecteur de contexte, ce qui dégrade les performances sur les longues séquences. Bahdanau, Cho et Bengio (2014) introduisent alors le mécanisme d'attention, qui permet au décodeur de pondérer dynamiquement les états cachés de l'encodeur et de « se concentrer » sur les portions pertinentes de la séquence d'entrée à chaque étape de génération.

### 1.2.2.4 Le Transformer et l'ère des LLMs (2017-aujourd'hui)

En 2017, Vaswani et al. publient l'article fondateur « Attention Is All You Need », qui propose une architecture entièrement fondée sur l'attention et abandonne la récurrence. L'architecture Transformer se révèle hautement parallélisable, ce qui ouvre la voie à un passage à l'échelle sans précédent. Elle donne naissance, dès 2018, à deux familles de modèles :

- **BERT** (Bidirectional Encoder Representations from Transformers, Devlin et al., 2018), modèle encodeur seul, dédié à la représentation contextuelle du texte ;
- **GPT** (Generative Pre-trained Transformer, Radford et al., 2018), modèle décodeur seul, dédié à la génération de texte.

La trajectoire des modèles GPT illustre la dynamique d'échelle qui caractérise l'ère des LLMs : 117 millions de paramètres pour GPT-1 (2018), 1,5 milliard pour GPT-2 (2019), 175 milliards pour GPT-3 (2020). Le lancement public de ChatGPT en novembre 2022, fondé sur GPT-3.5 puis GPT-4, marque la diffusion massive de ces technologies, atteignant 100 millions d'utilisateurs actifs en deux mois. Parallèlement, l'écosystème open source (LLaMA, Mistral, Falcon) et de nouvelles architectures (Mamba, RWKV) viennent enrichir le paysage en proposant des compromis variés entre coût computationnel, longueur de contexte et qualité de génération.

## 1.2.3 Le concept d'embeddings et représentations vectorielles

Le langage humain est une donnée non structurée que les ordinateurs ne peuvent traiter directement sous sa forme brute. Pour qu'un modèle de langage puisse manipuler et « calculer » le sens, il est indispensable de convertir au préalable le texte en représentations numériques appelées vecteurs. Cette opération de transformation porte le nom d'embedding (plongement vectoriel). Les *embeddings* constituent la représentation numérique fondamentale sur laquelle repose tout le pipeline de matching emploi-compétences. Un embedding est une projection d'un objet (mot, phrase, document, compétence) dans un espace vecto-

riel continu de dimension  $d$ , typiquement  $d \in [128, 4096]$ , où la proximité géométrique reflète la similarité sémantique. L'objectif d'un modèle d'embedding est de produire des représentations qui restituent, dans un espace mathématique, le sens des unités linguistiques de la manière la plus précise possible. Autrement dit, l'embedding constitue le pont entre le langage humain discret, symbolique et fortement ambigu et les opérations algébriques que les réseaux de neurones sont en mesure d'effectuer.

### 1.2.3.1 Embeddings statiques vs. contextuels

TABLE 1.1 – Comparaison des embeddings statiques et contextuels.

| Propriété              | Statiques (Word2Vec, GloVe)           | Contextuels (BERT, GPT)                   |
|------------------------|---------------------------------------|-------------------------------------------|
| Dépendance au contexte | Non - un mot = un vecteur unique      | Oui - vecteur différent selon le contexte |
| Capture de polysémie   | Limitée                               | Excellente                                |
| Exemple                | « Bank » = même vecteur (banque/rive) | « Bank » varie selon la phrase            |
| Usage en NLP moderne   | Rare (benchmarks historiques)         | Dominant                                  |
| Coût computationnel    | Faible                                | Élevé (GPU requis)                        |

Source : Auteur

### 1.2.3.2 Le rôle des embeddings dans l'architecture Transformer

Dans un modèle Transformer, les embeddings constituent la première étape du traitement. Le pipeline d'entrée se déroule selon les étapes suivantes :

1. Le texte d'entrée est segmenté en jetons (tokens) par un algorithme de tokenisation, généralement de type sous-mots (Byte-Pair Encoding, WordPiece ou SentencePiece).
2. Chaque jeton est associé à un vecteur initial issu d'une matrice d'embeddings apprise lors du pré-entraînement et indexée par les identifiants des jetons du vocabulaire.
3. Un codage positionnel (positional encoding) est ajouté à ces vecteurs afin que le modèle puisse exploiter l'ordre des mots dans la séquence, l'architecture Transformer traitant l'ensemble des jetons simultanément et n'ayant donc, par construction, aucune notion intrinsèque d'ordre.
4. Les vecteurs ainsi enrichis circulent à travers les couches successives du modèle, où ils sont progressivement contextualisés par les mécanismes d'auto-attention et les réseaux de propagation avant.

## 1.2.4 L'architecture Transformer et le mécanisme d'attention

L'architecture Transformer, introduite par VASWANI et al. (2017) dans le célèbre article *Attention Is All You Need*, constitue le paradigme architectural dominant dans le traitement du langage naturel. Elle repose sur un mécanisme d'auto-attention (*self-attention*) qui permet au modèle d'examiner simultanément l'ensemble des positions d'une séquence d'entrée pour calculer des représentations contextualisées de chaque token.

### 1.2.4.1 Le mécanisme d'auto-attention

Formellement, étant donnée une séquence de vecteurs d'entrée  $\mathbf{X} \in \mathbb{R}^{n \times d}$ , le mécanisme d'attention produit une sortie en calculant trois matrices : les requêtes  $\mathbf{Q}$ , les clés  $\mathbf{K}$  et les valeurs  $\mathbf{V}$ , obtenues par projections linéaires apprises :



$$\mathbf{Q} = \mathbf{XW}^Q, \quad \mathbf{K} = \mathbf{XW}^K, \quad \mathbf{V} = \mathbf{XW}^V \quad (1.1)$$

La sortie de l'attention est alors :


$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{QK}^T}{\sqrt{d_k}}\right) \mathbf{V} \quad (1.2)$$

où  $d_k$  est la dimension des vecteurs clés, utilisée pour normaliser le produit scalaire et éviter des gradients trop faibles. Ce mécanisme permet à chaque token de « regarder » tous les autres tokens de la séquence simultanément, contrairement aux architectures récurrentes (RNN, LSTM) qui traitent les tokens séquentiellement. Dans le contexte du matching emploi-compétences, cela signifie que le modèle peut mettre en relation le terme « Python » d'un CV avec « développement back-end » dans une offre d'emploi, même si ces termes sont distants dans le texte.

#### 1.2.4.2 L'attention multi-têtes

L'architecture utilise Afin de capturer simultanément des relations linguistiques de natures variées, le Transformer ne se limite pas à un unique calcul d'attention. Il met en œuvre une attention multi-têtes, c'est-à-dire plusieurs calculs d'attention exécutés en parallèle (typiquement 8 ou 12 têtes, parfois davantage dans les modèles de plus grande taille). Chaque tête d'attention dispose de ses propres matrices de projection  $Q, K$  et  $V$ , apprises de manière indépendante comme le montre la 1.2. Elle peut ainsi se spécialiser dans l'identification d'un type particulier de relation : dépendances syntaxiques, proximité sémantique, coréférence pronominale, reconnaissance d'entités, etc. Les sorties des différentes têtes sont ensuite concaténées puis projetées linéairement pour produire la représentation finale. Cette architecture confère au modèle une capacité d'expression supérieure et lui permet d'analyser une même séquence sous plusieurs angles complémentaires.

FIGURE 1.2 – Mécanisme de self-attention



Source : Auteur

#### 1.2.4.3 Composants internes d'un bloc Transformer

Au-delà de l'attention, la figure 1.3 montre que chaque bloc Transformer comprend deux éléments complémentaires essentiels au bon fonctionnement de l'architecture :


- **Le réseau de neurones à propagation avant (Feedforward Neural Network, FFN).** Appliqué de manière indépendante à chaque position de la séquence, il constitue la majeure partie de la

capacité de traitement et de mémorisation du modèle. C'est dans cette sous-couche qu'est essentiellement stockée la connaissance acquise lors du pré-entraînement.

- **Les connexions résiduelles et la normalisation de couche.** Les connexions résiduelles (residual connections) facilitent la propagation de l'information et du gradient à travers les couches profondes, tandis que les techniques de normalisation Layer Normalization dans la formulation originale, RMSNorm dans les architectures plus récentes stabilisent l'entraînement et accélèrent la convergence.

L'enchaînement de ces éléments self-attention, normalisation, FFN, connexions résiduelles est répété un grand nombre de fois (de 12 couches pour les modèles de petite taille à plus d'une centaine pour les plus grands LLMs), ce qui permet au modèle de construire des représentations linguistiques de plus en plus abstraites au fil des couches.

**FIGURE 1.3** – Architecture complète du Transformer



Source : Auteur

### 1.2.5 Variantes architecturales des LLMs

Selon leur architecture, les LLMs se distinguent principalement en trois familles, chacune présentant des avantages spécifiques pour les sous-tâches du système de recommandation.

#### 1.2.5.1 Modèles à encodeur seul (*Encoder-only*)

BERT [9] et ses variantes (RoBERTa, CamemBERT, XLM-R) sont optimisés pour la compréhension et la classification de texte. Leur mécanisme bidirectionnel leur permet de traiter le contexte gauche et



droit simultanément, ce qui est idéal pour l'extraction d'entités (compétences, diplômes, expériences) à partir de CV ou d'offres d'emploi, ainsi que pour la classification de niveau de qualification.

### 1.2.5.2 Modèles à décodeur seul (*Decoder-only*)

GPT [10], LLaMA [11] et leurs successeurs sont spécialisés dans la génération de texte. MUENNIGHOFF (2022) propose SGPT, qui utilise des modèles GPT comme bi-encodeurs pour la recherche sémantique asymétrique, produisant des sentence embeddings sémantiquement riches par *contrastive fine-tuning*.

### 1.2.5.3 Modèles encodeur-décodeur (*Seq2Seq*)

T5 [13] et BART reformulent toutes les tâches NLP comme des problèmes de séquence à séquence. Leur flexibilité les rend utiles pour la traduction entre nomenclatures de compétences différentes (par exemple, entre la NCM camerounaise et le référentiel ESCO).

**TABLE 1.2** – Variantes architecturales des LLMs et leurs applications au matching emploi-compétences.

| Architecture      | Exemples      | Points forts               | Application au matching                    |
|-------------------|---------------|----------------------------|--------------------------------------------|
| Encodeur seul     | BERT, RoBERTa | Classification, extraction | Extraction de compétences CV/offres        |
| Décodeur seul     | GPT-4, LLaMA  | Génération, zero-shot      | Enrichissement de profils, recommandations |
| Encodeur-Décodeur | T5, BART      | Traduction, résumé         | Alignement inter-référentiels              |

Source : Auteur

## 1.3 Généralité sur le fine-tuning des modèles de LLMs

Le *fine-tuning*, ou ajustement fin, désigne l'adaptation d'un modèle pré-entraîné à une tâche, un domaine ou un style de réponse spécifique. Dans le cas des LLMs, le modèle dispose déjà de connaissances linguistiques et statistiques acquises lors d'un pré-entraînement massif sur de grands corpus. Le fine-tuning ne repart donc pas de zéro : il modifie une partie ou la totalité des paramètres du modèle afin d'améliorer ses performances sur un corpus plus spécialisé [9, 13]. Cette logique est particulièrement pertinente lorsque le domaine cible possède un vocabulaire, des relations sémantiques ou des critères de décision qui diffèrent des usages généraux du langage.

Dans le cadre du matching emploi-compétences, l'intérêt du fine-tuning est direct. Les textes manipulés ne sont pas de simples phrases ordinaires ; ce sont des CV, des offres d'emploi, des intitulés de métiers, des descriptions de tâches, des compétences techniques, des certifications et des parcours de formation. Un modèle généraliste peut comprendre une partie de ces informations, mais il peut confondre des compétences proches, ignorer des synonymes professionnels locaux ou mal hiérarchiser l'importance d'une compétence dans une offre. L'ajustement sur des données du domaine permet de spécialiser les représentations du modèle afin qu'il rapproche mieux les profils et les postes réellement compatibles.

### 1.3.1 Pré-entraînement, adaptation et spécialisation

Le pré-entraînement consiste à exposer un modèle à de très grands volumes de textes afin qu'il apprenne des régularités générales du langage. Selon l'architecture, l'objectif peut être de prédire des mots masqués, comme dans BERT, ou de prédire le prochain token, comme dans les modèles génératifs de type GPT [9, 14]. Cette phase produit un modèle généraliste, puissant mais non spécialisé.

Le fine-tuning intervient ensuite comme une phase d'adaptation. On fournit au modèle des exemples représentatifs du problème cible : paires CV-offre, couples compétence-métier, descriptions de formation-compétences développées, ou encore triplets du type *offre, compétence requise, niveau attendu*. Le modèle apprend alors à ajuster ses représentations internes aux régularités du domaine. Dans un système emploi-compétences, l'objectif n'est pas seulement de générer du texte ; il est surtout d'améliorer l'extraction d'entités, la classification des compétences, la recherche sémantique et le classement des recommandations.

Il faut néanmoins éviter une erreur fréquente : fine-tuner un LLM ne garantit pas automatiquement un meilleur système. Si les données sont faibles, bruitées ou biaisées, le modèle apprendra ces biais. Si les labels sont incohérents, le fine-tuning dégradera la qualité des représentations. Si le domaine est mal défini, l'adaptation risque d'être superficielle. La qualité du corpus, la définition des tâches et la cohérence des annotations sont donc plus importantes que la seule taille du modèle.

### 1.3.2 Les principales formes de fine-tuning

On distingue plusieurs formes d'adaptation, selon l'objectif et les ressources disponibles.

#### 1.3.2.1 Fine-tuning supervisé

Le fine-tuning supervisé utilise des données annotées. Dans le cas du matching emploi-compétences, il peut s'agir de paires *profil-offre* annotées comme pertinentes ou non pertinentes, de compétences extraites manuellement de CV, ou de descriptions associées à une catégorie métier. Le modèle apprend à reproduire ces décisions. Cette approche est utile pour des tâches comme la classification, l'extraction d'entités et le scoring de similarité.

#### 1.3.2.2 Instruction tuning

L'*instruction tuning* adapte le modèle à suivre des consignes formulées en langage naturel. Au lieu de seulement prédire une classe ou une similarité, le modèle apprend à répondre à des demandes telles que : « extrais les compétences techniques de ce CV », « identifie les compétences manquantes pour cette offre » ou « propose une formation pour combler cet écart ». Les travaux d'Ouyang et al. montrent que l'ajustement sur des instructions et préférences humaines améliore l'utilité perçue des réponses des grands modèles de langage [15].

#### 1.3.2.3 Fine-tuning contrastif pour les embeddings

Pour la recherche sémantique, le fine-tuning peut viser non pas la génération de texte, mais la qualité des embeddings. L'objectif est alors de rapprocher dans l'espace vectoriel les éléments similaires et d'éloigner les éléments non similaires. Par exemple, une offre de « data analyst » et un profil maîtrisant Python, SQL, Excel, visualisation et statistiques doivent être proches ; une offre de comptabilité pure et un profil de développement web doivent être plus éloignés. Cette logique de fine-tuning contrastif est centrale pour les modèles de type Sentence-BERT [16].

#### 1.3.2.4 Adaptation légère des paramètres

Le fine-tuning complet d'un LLM peut être coûteux, car il met à jour tous les paramètres du modèle. Les méthodes d'adaptation efficace, comme LoRA, réduisent ce coût en insérant de petites matrices entraînaables dans certaines couches du réseau, tout en gardant la majorité des paramètres gelés [17]. QLoRA pousse cette logique plus loin en combinant quantification et adaptation légère, ce qui permet d'ajuster de grands modèles avec beaucoup moins de mémoire GPU [18]. Pour un projet appliqué comme

celui-ci, ces méthodes sont souvent plus réalistes qu'un fine-tuning complet.

### 1.3.3 Application au matching emploi-compétences

Dans le système proposé, le fine-tuning peut intervenir à trois niveaux complémentaires. Le premier niveau concerne l'extraction : le modèle doit identifier dans les textes les compétences, outils, diplômes, années d'expérience, secteurs et métiers. Le deuxième niveau concerne la représentation : les embeddings doivent capturer les similarités professionnelles, y compris lorsque les formulations sont différentes. Le troisième niveau concerne l'explication : le modèle doit être capable de produire une justification lisible, par exemple en distinguant les compétences acquises, les compétences manquantes et les formations recommandées.

Cette architecture suppose une articulation rigoureuse avec la nomenclature métiers-compétences. Le fine-tuning ne doit pas seulement apprendre des régularités textuelles ; il doit être contraint par un référentiel. Par exemple, si le modèle extrait « Power BI », « tableau de bord » et « reporting », ces éléments doivent pouvoir être rattachés à une compétence standardisée de visualisation ou d'aide à la décision. C'est cette normalisation qui permet ensuite d'alimenter correctement le graphe de connaissances.

### 1.3.4 Risques et précautions méthodologiques

Le fine-tuning présente plusieurs risques. Le premier est le sur-apprentissage : le modèle peut mémoriser les exemples du corpus sans généraliser à de nouvelles offres. Le deuxième est le biais de données : si les offres collectées favorisent certains secteurs, niveaux de diplôme ou formulations linguistiques, le modèle reproduira ces déséquilibres. Le troisième est la perte de robustesse : un modèle trop spécialisé peut devenir moins performant sur des formulations inattendues. Enfin, le quatrième risque est l'opacité : si le modèle produit un score sans explication, il sera difficile de convaincre un utilisateur ou un recruteur de la pertinence de la recommandation.

Ces limites justifient le recours à un système hybride. Le LLM apporte la compréhension linguistique ; la base vectorielle apporte la recherche par similarité ; le graphe de connaissances apporte la structure, les contraintes et l'explicabilité. Dans cette perspective, le fine-tuning n'est pas une fin en soi. Il est un levier d'adaptation qui doit rester subordonné à l'objectif central du mémoire : produire un matching emploi-compétences plus pertinent, plus interprétable et plus utile pour la montée en compétences.

## 1.4 Généralité sur des BD vectorielles et orientées graphes

Les bases de données vectorielles et les bases orientées graphes répondent à deux besoins complémentaires dans les systèmes modernes d'intelligence artificielle. Les premières sont conçues pour indexer et interroger des représentations numériques continues, généralement produites par des modèles d'embeddings. Les secondes sont conçues pour représenter explicitement des entités et les relations qui les relient. Dans le cadre du matching emploi-compétences, cette complémentarité est stratégique : la base vectorielle permet de retrouver des profils et offres proches sur le plan sémantique, tandis que le graphe permet d'expliquer pourquoi ces éléments sont liés à travers des métiers, compétences, secteurs, formations et niveaux d'exigence.

### 1.4.1 Structure générale d'une base de données vectorielle

Une base de données vectorielle est un système de stockage et de recherche optimisé pour des vecteurs numériques de grande dimension. Chaque objet textuel, par exemple un CV, une offre d'emploi, une compétence ou une description de formation, est transformé en embedding par un modèle de représentation. Cet embedding est ensuite stocké avec un identifiant, des métadonnées et parfois le texte source. La base ne manipule donc pas seulement des chaînes de caractères ; elle manipule des points dans un espace vectoriel où la distance ou la proximité traduit une forme de similarité sémantique.

La structure minimale d'une base vectorielle comprend généralement quatre composantes. La première est le *document source*, c'est-à-dire l'information initiale : CV, offre, compétence, métier ou contenu de formation. La deuxième est le *vecteur d'embedding*, qui encode ce document dans un espace numérique. La troisième est l'ensemble des *métadonnées*, comme le pays, le secteur, le niveau d'expérience, la date de collecte ou le type d'objet. La quatrième est l'*index vectoriel*, qui accélère la recherche des plus proches voisins.

Dans un système de matching emploi-compétences, une table vectorielle peut par exemple contenir les colonnes suivantes : un identifiant d'offre, le texte nettoyé de l'offre, le vecteur associé, le secteur d'activité, le niveau d'expérience requis et la liste normalisée des compétences extraites. Une requête utilisateur, comme un profil candidat, est vectorisée à son tour. Le système compare ensuite ce vecteur avec ceux de la base afin d'identifier les offres les plus proches.

La difficulté principale vient du fait que les embeddings sont souvent de grande dimension. Une recherche exhaustive sur tous les vecteurs devient coûteuse lorsque la base contient des milliers ou millions d'objets. C'est pourquoi les bases vectorielles utilisent des index de recherche approximative des plus proches voisins, tels que HNSW ou IVF, largement employés dans les moteurs spécialisés comme FAISS ou dans des extensions comme pgvector [19, 20, 21].

### 1.4.2 Principe de la recherche sémantique dans une BD vectorielle

La recherche sémantique consiste à retrouver des objets proches par le sens plutôt que par la présence exacte des mêmes mots. Contrairement à une recherche lexicale classique, qui dépend fortement des mots-clés, elle exploite la position des embeddings dans un espace vectoriel. Deux textes peuvent donc être rapprochés même s'ils n'emploient pas les mêmes termes. Par exemple, une offre mentionnant « conception de tableaux de bord décisionnels » peut être rapprochée d'un profil indiquant « Power BI, reporting et visualisation de données ».

Le processus comprend généralement cinq étapes. Premièrement, les textes sont nettoyés et segmentés. Deuxièmement, un modèle d'embedding transforme chaque texte en vecteur. Troisièmement, les vecteurs sont stockés et indexés. Quatrièmement, la requête est elle-même transformée en vecteur. Cinquièmement, la base retourne les objets les plus proches selon une mesure de similarité.

Les mesures les plus utilisées sont la similarité cosinus, la distance euclidienne et le produit scalaire. La similarité cosinus est particulièrement fréquente en traitement du langage, car elle mesure l'angle entre deux vecteurs et neutralise en partie l'effet de leur norme. Elle est définie par :

$$\cos(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \quad (1.3)$$

Dans le cas du matching emploi-compétences, cette recherche permet de produire une première liste d'offres candidates pour un profil donné. Toutefois, un score vectoriel seul ne suffit pas. Il peut identifier une proximité globale, mais il ne dit pas toujours quelles compétences expliquent cette proximité, quelles compétences manquent, ni quelle formation pourrait combler l'écart. C'est précisément la limite qui justifie l'association avec une base orientée graphe.

### 1.4.3 Structure générale d'une base de données orientée graphe

Une base de données orientée graphe représente l'information sous forme de nœuds et de relations. Les nœuds désignent les entités du domaine, tandis que les relations décrivent les liens entre ces entités. Cette logique diffère des bases relationnelles classiques, où les relations sont généralement reconstituées par des jointures entre tables. Dans une base graphe, les liens sont des objets de première classe : ils sont stockés, typés, parcourus et analysés directement.

Dans le domaine emploi-compétences, les nœuds peuvent représenter des candidats, offres, métiers, compétences, secteurs, formations, certifications ou niveaux de qualification. Les relations peuvent exprimer des liens tels que *possède*, *exige*, *appartient à*, *développe*, *est similaire à* ou *prépare à*. Cette représentation est beaucoup plus proche de la structure réelle du marché de l'emploi, car un métier n'est pas une simple ligne de table : il est défini par un ensemble de compétences, d'activités, de niveaux, de secteurs et de trajectoires possibles.

Formellement, un graphe peut être défini comme un couple  $G = (V, E)$ , où  $V$  désigne l'ensemble des nœuds et  $E$  l'ensemble des relations. Dans un graphe de connaissances, les relations sont souvent représentées sous forme de triplets :

$$(\text{sujet}, \text{relation}, \text{objet}) \quad (1.4)$$

Par exemple, le triplet (Data Analyst, exige, SQL) signifie que la compétence SQL est requise pour le métier de data analyst. De même, (Formation Power BI, développe, Visualisation de données) indique qu'une formation contribue à développer une compétence standardisée.

Les bases graphes comme Neo4j permettent ensuite d'interroger ces relations avec des langages adaptés, notamment Cypher. Un système peut ainsi répondre à des questions que la recherche vectorielle seule gère mal : quelles compétences manquent à un candidat pour viser un métier ? Quelles formations développent ces compétences ? Quelles offres sont proches d'un profil si l'on accepte une trajectoire de formation courte ?

### 1.4.4 Techniques de description et d'analyse des graphes de connaissances

Un graphe de connaissances ne sert pas seulement à stocker des relations ; il permet aussi de les analyser. Les techniques de description de graphe visent à comprendre la structure du réseau, l'importance relative des entités et les chemins qui relient les objets. Dans un système emploi-compétences, ces analyses peuvent aider à identifier les compétences centrales, les métiers passerelles, les formations les plus utiles ou les trajectoires de reconversion les plus plausibles.

Une première famille de techniques concerne les mesures de centralité. La centralité de degré mesure le nombre de connexions directes d'un nœud. Une compétence fortement connectée à de nombreux métiers, comme Excel, SQL ou communication professionnelle, peut être considérée comme transversale. La

centralité d'intermédiarité mesure la fréquence avec laquelle un nœud se trouve sur les chemins les plus courts entre d'autres nœuds ; elle permet d'identifier des compétences ou formations jouant un rôle de passerelle entre plusieurs familles de métiers. La centralité de proximité mesure la distance moyenne d'un nœud à tous les autres, indiquant sa capacité à atteindre rapidement le reste du réseau.

Une deuxième famille concerne la recherche de chemins. Dans le matching emploi-compétences, les chemins permettent de produire des recommandations explicables. Si un candidat possède Python et statistiques, et qu'une offre exige aussi SQL et Power BI, le graphe peut identifier les compétences manquantes, puis rechercher les formations qui les développent. L'explication ne repose donc pas uniquement sur un score opaque ; elle repose sur un chemin interprétable entre profil, compétences, offre et formation.

Une troisième famille concerne la détection de communautés. Elle permet de repérer des groupes de métiers ou de compétences fortement liés entre eux. Par exemple, les métiers de la data peuvent former une communauté autour des compétences Python, SQL, statistiques, visualisation et machine learning, tandis que les métiers du marketing numérique peuvent former une autre communauté autour du SEO, de la publicité en ligne, de l'analyse d'audience et de la stratégie de contenu. Ces regroupements peuvent aider à structurer les parcours de formation et les recommandations de reconversion.

Enfin, les graphes de connaissances peuvent être enrichis par des représentations vectorielles de graphes, ou *graph embeddings*. Ces méthodes projettent les nœuds et relations dans un espace vectoriel afin de faciliter la prédiction de liens, la classification de nœuds ou la recommandation. Des approches plus avancées, comme les réseaux de neurones sur graphes, exploitent la structure locale du graphe pour apprendre des représentations tenant compte du voisinage des entités [22, 23].

### 1.4.5 Synergie LLM + Graphes de Connaissances

La combinaison entre LLMs et graphes de connaissances répond à une faiblesse de chacun des deux outils pris isolément. Les LLMs sont puissants pour comprendre et générer du langage naturel, extraire des entités et reformuler des contenus. Cependant, ils peuvent produire des réponses approximatives, manquer de traçabilité ou halluciner des relations non vérifiées. Les graphes de connaissances, à l'inverse, offrent une structure explicite, contrôlable et interrogeable, mais ils nécessitent une alimentation régulière et une normalisation rigoureuse des données.

Dans un pipeline emploi-compétences, les LLMs peuvent intervenir en amont pour extraire automatiquement les entités présentes dans les CV et offres d'emploi : métiers, compétences, diplômes, outils, années d'expérience, secteurs et certifications. Ces entités sont ensuite alignées sur une nomenclature standardisée, comme la NCM ou ESCO, puis insérées dans le graphe sous forme de nœuds et relations. Le graphe sert alors de mémoire structurée du système.

La synergie apparaît aussi au moment de la recommandation. Une base vectorielle peut identifier les offres les plus proches d'un profil, mais le graphe permet de vérifier la cohérence métier de cette proximité. Par exemple, si deux offres sont proches vectoriellement mais appartiennent à des familles de métiers différentes, le graphe peut aider à distinguer une proximité linguistique superficielle d'une proximité professionnelle réelle. Inversement, le graphe peut révéler des correspondances indirectes que la recherche vectorielle ne voit pas, comme une compétence transférable entre deux métiers voisins.

Enfin, cette combinaison améliore l'explicabilité. Un LLM peut générer une recommandation lisible en langage naturel, mais cette recommandation doit être fondée sur des relations vérifiables dans le

graphe : compétences possédées, compétences exigées, compétences manquantes, formations associées et trajectoire possible. Le rôle du LLM n'est donc pas d'inventer l'explication ; il est de verbaliser une chaîne de raisonnement structurée par le graphe. Cette logique rejoint les approches de RAG et de GraphRAG, qui cherchent à combiner récupération d'information, génération et structure relationnelle pour produire des réponses plus contextualisées et plus contrôlables [24, 22].

## 1.5 Généralité sur les systèmes de recommandation

Les systèmes de recommandation (SR) sont des outils algorithmiques conçus pour prédire et suggérer des éléments pertinents à un utilisateur, en se basant sur des informations le concernant ainsi que sur les caractéristiques des éléments disponibles. Appliqués au marché de l'emploi, ils permettent de mettre en relation candidats et offres de manière automatisée, personnalisée et à grande échelle. Dans un système classique de recommandation, on distingue généralement trois types d'entités : les utilisateurs, les items et les interactions. Dans le commerce électronique, l'utilisateur est un client et l'item est un produit. Dans le cas du présent mémoire, l'utilisateur peut être un candidat ou un membre de la communauté KmerAI, tandis que l'item peut être une offre d'emploi, un métier cible, une compétence ou une formation. Les interactions peuvent correspondre à des candidatures, clics, sauvegardes d'offres, évaluations, historiques de formation ou correspondances validées par un expert.

La recommandation appliquée à l'emploi présente cependant une difficulté plus forte que la recommandation de produits. Une mauvaise recommandation de film a un coût faible ; une mauvaise recommandation professionnelle peut orienter un candidat vers une trajectoire peu adaptée. Le système doit donc prendre en compte la pertinence, mais aussi l'explicabilité, l'équité, le niveau réel du candidat et la faisabilité de la montée en compétences.

### 1.5.1 Filtrage basé sur le contenu (*Content-Based Filtering*)

Le filtrage basé sur le contenu recommande des items similaires à ceux qui correspondent déjà au profil ou aux préférences de l'utilisateur. Il repose sur les caractéristiques des objets. Dans le cas du matching emploi-compétences, ces caractéristiques peuvent être les compétences exigées, le secteur, le niveau d'expérience, le type de contrat, le lieu, le domaine de formation ou les outils techniques demandés.

Son principe est simple : si un candidat possède Python, SQL, statistiques et visualisation de données, le système recherchera des offres contenant des caractéristiques proches, par exemple analyste de données, chargé d'études statistiques ou business intelligence analyst. Les embeddings permettent d'améliorer cette approche en dépassant les mots-clés exacts. Le système peut alors rapprocher « reporting décisionnel » de « tableau de bord » ou « visualisation de données ».

L'avantage principal du filtrage basé sur le contenu est son interprétabilité relative : on peut expliquer une recommandation par les caractéristiques communes entre le profil et l'offre. Sa limite est qu'il tend à enfermer l'utilisateur dans ce qu'il possède déjà. Si un candidat a un profil statistique, le système peut négliger des trajectoires proches mais exigeant une courte montée en compétences vers la data engineering ou le marketing analytics. Cette limite justifie l'introduction du skill gap et des relations de proximité dans le graphe [25].



### 1.5.2 Filtrage collaboratif (*Collaborative Filtering*)

Le filtrage collaboratif recommande des items à partir des comportements collectifs observés. L'idée centrale est que deux utilisateurs ayant eu des comportements similaires dans le passé peuvent être intéressés par des items similaires dans le futur. Dans une plateforme d'emploi, cela peut signifier que des candidats ayant des profils et parcours comparables postulent aux mêmes offres, consultent les mêmes formations ou réussissent dans des métiers proches.

Les méthodes collaboratives peuvent être fondées sur la similarité entre utilisateurs, sur la similarité entre items ou sur des modèles factoriels. Les approches de factorisation matricielle, popularisées notamment dans les systèmes de recommandation à grande échelle, apprennent des représentations latentes des utilisateurs et des items à partir d'une matrice d'interactions [26]. Dans le cas emploi-compétences, cette matrice peut contenir des signaux comme *a consulté*, *a postulé*, *a été retenu*, *a suivi la formation* ou *a validé la compétence*.

L'avantage du filtrage collaboratif est qu'il capte des régularités que les caractéristiques explicites ne révèlent pas toujours. Sa limite est le problème du démarrage à froid : lorsqu'un nouveau candidat ou une nouvelle offre apparaît sans historique d'interaction, le système dispose de peu d'information comportementale. En contexte camerounais, où les données d'interaction peuvent être rares ou peu structurées, cette limite est importante. Il serait donc imprudent de fonder tout le système uniquement sur du collaboratif.

### 1.5.3 Filtrage hybride (*Hybrid Filtering*)

Le filtrage hybride combine plusieurs sources de signal afin de réduire les limites propres à chaque approche. Dans ce mémoire, l'hybridation est particulièrement adaptée, car le problème ne consiste pas seulement à prédire une préférence ; il consiste à évaluer une compatibilité professionnelle, mesurer un écart de compétences et proposer une trajectoire d'amélioration.

Un moteur hybride emploi-compétences peut combiner quatre scores. Le premier est un score sémantique, issu de la proximité vectorielle entre le profil et l'offre. Le deuxième est un score structurel, issu du graphe de connaissances et des relations entre métiers, compétences et formations. Le troisième est un score collaboratif, issu des comportements observés sur la plateforme. Le quatrième est un score de skill gap, qui pénalise les offres pour lesquelles les compétences manquantes sont trop nombreuses ou trop critiques.

Une formulation simple du score hybride peut être donnée par :

$$Score_{hyb} = \alpha S_{sem} + \beta S_{graph} + \gamma S_{collab} - \delta Gap \quad (1.5)$$

où  $S_{sem}$  désigne la similarité sémantique,  $S_{graph}$  la proximité structurelle dans le graphe,  $S_{collab}$  le signal collaboratif,  $Gap$  l'écart de compétences, et  $\alpha, \beta, \gamma, \delta$  des poids à calibrer empiriquement.

L'intérêt d'une telle architecture est double. D'abord, elle améliore la robustesse du système : si les interactions collaboratives sont faibles, le contenu et le graphe restent exploitables ; si les descriptions textuelles sont ambiguës, le graphe fournit une structure de contrôle. Ensuite, elle améliore l'explicabilité : le système peut indiquer qu'une offre est recommandée parce que le profil est sémantiquement proche, que plusieurs compétences clés sont déjà acquises, que le métier appartient à une trajectoire proche, et



que deux formations permettent de combler les compétences manquantes.

La recommandation hybride est donc cohérente avec l’objectif général du mémoire. Elle permet de dépasser une logique naïve de mots-clés pour construire un système capable de raisonner sur les compétences, les relations entre métiers et les parcours de montée en qualification [27, 28].

## 1.6 Recherche sémantique et Génération Augmentée par Récupération (RAG)

La recherche sémantique et la RAG forment le pont entre la représentation des profils et des offres d’emploi et la génération de recommandations personnalisées. Elles permettent de dépasser les limites de la correspondance lexicale pour identifier des correspondances conceptuelles profondes.

### 1.6.1 Recherche par similarité sémantique

### 1.6.2 Bases de données vectorielles et algorithmes ANN

### 1.6.3 Principe et fonctionnement du RAG native

La RAG [24] est un paradigme architectural qui combine la puissance de génération des LLMs avec la précision factuelle de la recherche dans une base de connaissances externe. Elle répond à deux limitations majeures des LLMs purs : leur coupure de connaissance temporelle (*knowledge cutoff*) et leur tendance aux hallucinations.

### 1.6.4 RAG et graphes de connaissances

L’intégration du graphe de connaissances dans le pipeline RAG étend le système au-delà de la recherche vectorielle pure. Lors de la phase de récupération, le graphe permet d’exploiter des relations structurées : un candidat maîtrisant *TensorFlow* peut se voir suggérer des offres requérant *PyTorch* si le graphe encode une relation « est similaire à » entre ces frameworks. La propagation d’information à  $L$  sauts dans le graphe révèle des correspondances indirectes invisibles pour la recherche vectorielle pure.

## 1.7 Métriques d’évaluation des systèmes de recommandation

L’évaluation rigoureuse d’un système de recommandation est indispensable pour valider sa pertinence et le comparer aux approches existantes. Nous nous concentrons sur les métriques *offline*, calculées sur des jeux de données annotés.

### 1.7.1 Les différentes fonctions de pertes

### 1.7.2 Métriques de précision du ranking

**TABLE 1.3** – Métriques d'évaluation des systèmes de recommandation emploi-compétences.

| Métrique    | Formule                                                         | Interprétation                                 | Références |
|-------------|-----------------------------------------------------------------|------------------------------------------------|------------|
| Precision@K | $ \text{pert.} \cap \text{top-}K /K$                            | Proportion de bonnes recommandations           | [29, 30]   |
| Recall@K    | $ \text{pert.} \cap \text{top-}K / \text{pert.} $               | Couverture des pertinents                      | [29, 30]   |
| MRR         | $\frac{1}{ Q } \sum 1/\text{rank}_i$                            | Position du 1 <sup>er</sup> résultat pertinent | [31]       |
| NDCG@K      | $\text{DCG@K} / \text{IDCG@K}$                                  | Qualité du ranking pondérée                    | Tous       |
| Cosinus     | $\mathbf{u} \cdot \mathbf{v} / (\ \mathbf{u}\  \ \mathbf{v}\ )$ | Proximité sémantique                           | [16]       |
| MAP@K       | Moy. des AP@K                                                   | Précision moyenne                              | [31]       |

*Source : Auteur*

# APPROCHE MÉTHODOLOGIQUE ET DONNÉES

---

## Deuxième partie

# Presentation des resultats

# PRÉSENTATION ET ANALYSE DES RÉSULTATS

---

# DISCUSSION ET RECOMMANDATIONS

---

---

# Conclusion générale

---

---

# Bibliographie

---

- [1] Dale T. MORTENSEN et Christopher A. PISSARIDES. "Job Creation and Job Destruction in the Theory of Unemployment". In : *The Review of Economic Studies* 61.3 (1994), p. 397-415. DOI : [10.2307/2297896](https://doi.org/10.2307/2297896).
- [2] Christopher A. PISSARIDES. *Equilibrium Unemployment Theory*. 2<sup>e</sup> éd. Cambridge, MA : MIT Press, 2000.
- [3] George A. AKERLOF. "The Market for "Lemons" : Quality Uncertainty and the Market Mechanism". In : *The Quarterly Journal of Economics* 84.3 (1970), p. 488-500. DOI : [10.2307/1879431](https://doi.org/10.2307/1879431).
- [4] Michael SPENCE. "Job Market Signaling". In : *The Quarterly Journal of Economics* 87.3 (1973), p. 355-374. DOI : [10.2307/1882010](https://doi.org/10.2307/1882010).
- [5] Gary S. BECKER. *Human Capital : A Theoretical and Empirical Analysis, with Special Reference to Education*. University of Chicago Press, 1964.
- [6] David H. AUTOR. "The "Task Approach" to Labor Markets : An Overview". In : *Journal for Labour Market Research* 46.3 (2013), p. 185-199. DOI : [10.1007/s12651-013-0128-z](https://doi.org/10.1007/s12651-013-0128-z).
- [7] EUROPEAN COMMISSION. *ESCO : European Skills, Competences, Qualifications and Occupations*. 2024. URL : <https://esco.ec.europa.eu/> (visité le 04/05/2026).
- [8] Ashish VASWANI et al. "Attention Is All You Need". In : *Advances in Neural Information Processing Systems*. 2017, p. 5998-6008.
- [9] Jacob DEVLIN et al. "BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding". In : *Proceedings of NAACL-HLT*. 2019, p. 4171-4186.
- [10] Alec RADFORD et al. *Improving Language Understanding by Generative Pre-training*. OpenAI. 2018.
- [11] Hugo TOUVRON et al. *LLaMA : Open and Efficient Foundation Language Models*. 2023. arXiv : [2302.13971](https://arxiv.org/abs/2302.13971) [cs.CL].
- [12] Niklas MUENNIGHOFF. *SGPT : GPT Sentence Embeddings for Semantic Search*. 2022. arXiv : [2202.08904](https://arxiv.org/abs/2202.08904) [cs.CL].
- [13] Colin RAFFEL et al. "Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer". In : *Journal of Machine Learning Research* 21.140 (2020), p. 1-67.
- [14] Tom B. BROWN et al. "Language Models are Few-Shot Learners". In : *Advances in Neural Information Processing Systems* 33 (2020), p. 1877-1901. URL : <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>.



- [15] Long OUYANG et al. “Training Language Models to Follow Instructions with Human Feedback”. In : *Advances in Neural Information Processing Systems* 35 (2022), p. 27730-27744. URL : [https://proceedings.neurips.cc/paper\\_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html](https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html).
- [16] Nils REIMERS et Iryna GUREVYCH. “Sentence-BERT : Sentence Embeddings using Siamese BERT-Networks”. In : *Proceedings of EMNLP-IJCNLP*. Association for Computational Linguistics, 2019.
- [17] Edward J. HU et al. “LoRA : Low-Rank Adaptation of Large Language Models”. In : *arXiv preprint arXiv :2106.09685* (2021). URL : <https://arxiv.org/abs/2106.09685>.
- [18] Tim DETTMERS et al. “QLoRA : Efficient Finetuning of Quantized LLMs”. In : *Advances in Neural Information Processing Systems* 36 (2023). URL : [https://proceedings.neurips.cc/paper\\_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html](https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html).
- [19] Yu A. MALKOV et D. A. YASHUNIN. “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs”. In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.4 (2020), p. 824-836. DOI : [10.1109/TPAMI.2018.2889473](https://doi.org/10.1109/TPAMI.2018.2889473).
- [20] Jeff JOHNSON, Matthijs DOUZE et Hervé JÉGOU. “Billion-scale Similarity Search with GPUs”. In : *IEEE Transactions on Big Data* 7.3 (2019), p. 535-547. DOI : [10.1109/TBDATA.2019.2921572](https://doi.org/10.1109/TBDATA.2019.2921572).
- [21] PGVECTOR CONTRIBUTORS. *pgvector : Open-source Vector Similarity Search for Postgres*. 2024. URL : <https://github.com/pgvector/pgvector> (visité le 04/05/2026).
- [22] Aidan HOGAN et al. “Knowledge Graphs”. In : *ACM Computing Surveys* 54.4 (2021), p. 1-37. DOI : [10.1145/3447772](https://doi.org/10.1145/3447772).
- [23] William L. HAMILTON. *Graph Representation Learning*. Morgan & Claypool Publishers, 2020. DOI : [10.2200/S01045ED1V01Y202009AIM046](https://doi.org/10.2200/S01045ED1V01Y202009AIM046).
- [24] Patrick LEWIS et al. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. In : *Advances in Neural Information Processing Systems*. 2020.
- [25] Michael J. PAZZANI et Daniel BILLSUS. “Content-Based Recommendation Systems”. In : *The Adaptive Web* (2007), p. 325-341. DOI : [10.1007/978-3-540-72079-9\\_10](https://doi.org/10.1007/978-3-540-72079-9_10).
- [26] Yehuda KOREN, Robert BELL et Chris VOLINSKY. “Matrix Factorization Techniques for Recommender Systems”. In : *Computer* 42.8 (2009), p. 30-37. DOI : [10.1109/MC.2009.263](https://doi.org/10.1109/MC.2009.263).
- [27] Robin BURKE. “Hybrid Recommender Systems : Survey and Experiments”. In : *User Modeling and User-Adapted Interaction* 12 (2002), p. 331-370. DOI : [10.1023/A:1021240730564](https://doi.org/10.1023/A:1021240730564).
- [28] Francesco RICCI et al., éd. *Recommender Systems Handbook*. Springer, 2011. DOI : [10.1007/978-0-387-85820-3](https://doi.org/10.1007/978-0-387-85820-3).
- [29] A. T. WASI. “HRGraph : Leveraging LLMs for HR Data Knowledge Graphs with Information Propagation-based Job Recommendation”. In : *Proceedings of the 1st Workshop on Knowledge Graphs and Large Language Models*. 2024, p. 56-62.
- [30] B. YANG et Z. SHEN. “Knowledge Graph Construction and Talent Competency Prediction for Human Resource Management”. In : *Alexandria Engineering Journal* 121 (2025), p. 223-235.

- [31] J. DU et al. *LLM-based GANs Interactive Recommendation for Job Recommendation*. 2023. arXiv : [2307.10747 \[cs.IR\]](#).

# ANNEXES

---

---

# Table des matières

---

|                                                                                                                 |          |
|-----------------------------------------------------------------------------------------------------------------|----------|
| Dédicace                                                                                                        | i        |
| Remerciements                                                                                                   | ii       |
| Liste des sigles et abréviations                                                                                | v        |
| Liste des tableaux                                                                                              | vi       |
| Liste des figures                                                                                               | vii      |
| Avant-propos                                                                                                    | viii     |
| Résumé                                                                                                          | ix       |
| Abstract                                                                                                        | x        |
| Introduction générale                                                                                           | 1        |
| <b>I Cadre théorique et conceptuel</b>                                                                          | <b>4</b> |
| <b>1 Fondements théoriques et revue de la littérature sur l'IA générative et les systèmes de recommandation</b> | <b>5</b> |
| 1.1 Marché de l'emploi, information imparfaite et appariement des compétences . . . . .                         | 5        |
| 1.1.1 Le marché du travail comme marché d'appariement . . . . .                                                 | 5        |
| 1.1.2 Asymétrie d'information et signalement des compétences . . . . .                                          | 6        |
| 1.1.3 Capital humain, compétences et inadéquation . . . . .                                                     | 6        |
| 1.1.4 Transformation numérique et demande de compétences . . . . .                                              | 7        |
| 1.1.5 Compétences, formation et besoin de standardisation . . . . .                                             | 7        |
| 1.2 Les fondements des LLMs . . . . .                                                                           | 8        |
| 1.2.1 Définition et évolution historique des LLMs en NLP . . . . .                                              | 9        |
| 1.2.2 Une évolution en plusieurs étapes . . . . .                                                               | 9        |
| 1.2.2.1 Les approches statistiques et le sac-de-mots (Bag-of-Words) . . . . .                                   | 9        |
| 1.2.2.2 Les représentations vectorielles denses Word2Vec (2013) : . . . . .                                     | 10       |
| 1.2.2.3 Les réseaux récurrents et l'introduction de l'attention (2014-2016) . . . . .                           | 10       |
| 1.2.2.4 Le Transformer et l'ère des LLMs (2017-aujourd'hui) . . . . .                                           | 10       |
| 1.2.3 Le concept d'embeddings et représentations vectorielles . . . . .                                         | 10       |

|          |                                                                               |           |
|----------|-------------------------------------------------------------------------------|-----------|
| 1.2.3.1  | Embeddings statiques vs. contextuels . . . . .                                | 11        |
| 1.2.3.2  | Le rôle des embeddings dans l'architecture Transformer . . . . .              | 11        |
| 1.2.4    | L'architecture Transformer et le mécanisme d'attention . . . . .              | 11        |
| 1.2.4.1  | Le mécanisme d'auto-attention . . . . .                                       | 11        |
| 1.2.4.2  | L'attention multi-têtes . . . . .                                             | 12        |
| 1.2.4.3  | Composants internes d'un bloc Transformer . . . . .                           | 12        |
| 1.2.5    | Variantes architecturales des LLMS . . . . .                                  | 13        |
| 1.2.5.1  | Modèles à encodeur seul ( <i>Encoder-only</i> ) . . . . .                     | 13        |
| 1.2.5.2  | Modèles à décodeur seul ( <i>Decoder-only</i> ) . . . . .                     | 14        |
| 1.2.5.3  | Modèles encodeur-décodeur ( <i>Seq2Seq</i> ) . . . . .                        | 14        |
| 1.3      | Généralité sur le fine-tuning des modèles de LLMS . . . . .                   | 14        |
| 1.3.1    | Pré-entraînement, adaptation et spécialisation . . . . .                      | 14        |
| 1.3.2    | Les principales formes de fine-tuning . . . . .                               | 15        |
| 1.3.2.1  | Fine-tuning supervisé . . . . .                                               | 15        |
| 1.3.2.2  | Instruction tuning . . . . .                                                  | 15        |
| 1.3.2.3  | Fine-tuning contrastif pour les embeddings . . . . .                          | 15        |
| 1.3.2.4  | Adaptation légère des paramètres . . . . .                                    | 15        |
| 1.3.3    | Application au matching emploi-compétences . . . . .                          | 16        |
| 1.3.4    | Risques et précautions méthodologiques . . . . .                              | 16        |
| 1.4      | Généralité sur des BD vectorielles et orientées graphes . . . . .             | 16        |
| 1.4.1    | Structure générale d'une base de données vectorielle . . . . .                | 17        |
| 1.4.2    | Principe de la recherche sémantique dans une BD vectorielle . . . . .         | 17        |
| 1.4.3    | Structure générale d'une base de données orientée graph . . . . .             | 18        |
| 1.4.4    | Techniques de description et d'analyse des graphes de connaissances . . . . . | 18        |
| 1.4.5    | Synergie LLM + Graphes de Connaissances . . . . .                             | 19        |
| 1.5      | Généralité sur les systèmes de recommandation . . . . .                       | 20        |
| 1.5.1    | Filtrage basé sur le contenu ( <i>Content-Based Filtering</i> ) . . . . .     | 20        |
| 1.5.2    | Filtrage collaboratif ( <i>Collaborative Filtering</i> ) . . . . .            | 21        |
| 1.5.3    | Filtrage hybride ( <i>Hybrid Filtering</i> ) . . . . .                        | 21        |
| 1.6      | Recherche sémantique et Génération Augmentée par Récupération (RAG) . . . . . | 22        |
| 1.6.1    | Recherche par similarité sémantique . . . . .                                 | 22        |
| 1.6.2    | Bases de données vectorielles et algorithmes ANN . . . . .                    | 22        |
| 1.6.3    | Principe et fonctionnement du RAG native . . . . .                            | 22        |
| 1.6.4    | RAG et graphes de connaissances . . . . .                                     | 22        |
| 1.7      | Métriques d'évaluation des systèmes de recommandation . . . . .               | 22        |
| 1.7.1    | Les différentes fonctions de pertes . . . . .                                 | 22        |
| 1.7.2    | Métriques de précision du ranking . . . . .                                   | 23        |
| <b>2</b> | <b>Approche méthodologique et données</b>                                     | <b>24</b> |

|           |                                              |           |
|-----------|----------------------------------------------|-----------|
| <b>II</b> | <b>Presentation des resultats</b>            | <b>25</b> |
| <b>3</b>  | <b>Présentation et analyse des résultats</b> | <b>26</b> |
| <b>4</b>  | <b>Discussion et recommandations</b>         | <b>27</b> |
|           | Conclusion générale                          | I         |
|           | Bibliographie                                | I         |
|           | Bibliographie                                | II        |
| <b>A</b>  | <b>Annexes</b>                               | <b>V</b>  |