

*Communauté Économique et Monétaire
de l'Afrique Centrale
(CEMAC)*



Cameroon AI Enthousiaste



*Institut Sous-régional de Statistique
et d'Économie Appliquée*

Organisation Internationale

BP : 294 Yaoundé - Tél : 222 220 134

*Direction du Développement et de la
Recherche*

ONG camerounaise

BP : 83000 Toulon, France

*Mémoire professionnel de fin d'étude présenté en vue de l'obtention du
diplôme d'Ingénieur Statisticien Économiste (ISE)*

OPTION : Data Science et Marketing

CONCEPTION D'UN SYSTEME DE RECOMMANDATION HYBRIDE POUR LE MATCHING EMPLOI-COMPETENCES AU CAMEROUN PAR INTEGRATION DES LLMS ET DES GRAPHES DE CONNAISSANCES

Rédigé par :

NGOULOU NGOUBILI Irch Defluviaire

Élève Ingénieur Statisticien Économiste cycle long – 5^e année

Sous l'encadrement de :

Dr. FOUTSE Yuehgoh

Présidente & Directrice exécutive adjointe, PhD Computer Science & Data Scientist

Année académique 2025-2026

Dédicace

À mes parents... (Max 1 page)

Remerciements

Sommaire

Dédicace	i
Remerciements	ii
Liste des sigles et abréviations	v
Liste des tableaux	vi
Liste des figures	vii
Avant-propos	viii
Résumé	ix
Abstract	x
Introduction générale	1
I Cadre théorique et conceptuel	5
1 Fondements théoriques et revue de la littérature sur l'IA générative et les systèmes de recommandation	6
1.1 Concepts clés mobilisés dans le mémoire	6
1.2 Fondements économiques et problématique d'appariement	8
1.3 Systèmes de recommandation et person-job fit	8
1.4 IA générative et connaissances	10
1.5 RAG, GraphRAG et orchestration agentique	11
1.6 Évaluation, acquis de la littérature et positionnement du mémoire	13
2 Source de données et Approche méthodologique	16
2.1 Cadre méthodologique et sources de données	16
2.2 Modélisation sémantique et structuration des connaissances	21
2.3 Orchestration agentique et génération contrôlée	23
2.4 Évaluation prévue, limites et synthèse méthodologique	24

II	Présentation des résultats	26
3	Implémentation du système de recommandation	27
3.1	Architecture générale et périmètre implémenté	27
3.2	Données exploitées et diagnostic descriptif du corpus	28
3.3	Implémentation des briques de recherche et de recommandation	36
3.4	Orchestration, interfaces et validation d'intégration	38
4	Évaluation de la performance du système	40
4.1	Objectif et logique générale de l'évaluation	40
4.2	Données et protocole expérimental	40
4.3	Évaluation du modèle d'embeddings	41
4.4	Ablation pgvector seul contre pgvector + graphe	42
4.5	Analyse du reranking par le graphe	43
4.6	Performance opérationnelle et stabilité	44
4.7	Interprétation par rapport aux hypothèses	45
4.8	Lecture des sorties graphiques de performance	45
4.9	Limites de l'évaluation	46
4.10	Synthèse du chapitre	47
5	Discussion et recommandations	48
	Conclusion générale	I
	Bibliographie	I
	Bibliographie	II
A	Annexes	V

Liste des sigles et abréviations

ANN :	Approximate Nearest Neighbors
API :	Application Programming Interface
BERT :	Bidirectional Encoder Representations from Transformers
BI :	Business Intelligence
CEMAC :	Communauté Économique et Monétaire de l'Afrique Centrale
CV :	Curriculum Vitae
DCG :	Discounted Cumulative Gain
ESCO :	European Skills, Competences, Qualifications and Occupations
FAISS :	Facebook AI Similarity Search
FNE :	Fonds National de l'Emploi
FRED :	Federal Reserve Economic Data
GAT :	Graph Attention Network
GCN :	Graph Convolutional Network
GNN :	Graph Neural Network
GPT :	Generative Pre-trained Transformer
GPU :	Graphics Processing Unit
HNSW :	Hierarchical Navigable Small World
IA :	Intelligence Artificielle
IDCG :	Ideal Discounted Cumulative Gain
ISE :	Ingénieur Statisticien Économiste
ISSEA :	Institut Sous-régional de Statistique et d'Économie Appliquée
IVF :	Inverted File Index
KG :	Knowledge Graph
LLM :	Large Language Model
LoRA :	Low-Rank Adaptation
LSTM :	Long Short-Term Memory
MAP :	Mean Average Precision
MEPC :	Nomenclature Camerounaise des Métiers, Emplois et Professions
MRR :	Mean Reciprocal Rank
NCF :	Nomenclature Camerounaise des Formations
NCM :	Nomenclature Camerounaise des Métiers
NDCG :	Normalized Discounted Cumulative Gain
NLP :	Natural Language Processing
OIT :	Organisation Internationale du Travail
ONG :	Organisation Non Gouvernementale
QLoRA :	Quantized Low-Rank Adaptation
RAG :	Retrieval-Augmented Generation
RNN :	Recurrent Neural Network
RWKV :	Receptance Weighted Key Value
SEO :	Search Engine Optimization
SGPT :	Sentence Generative Pre-trained Transformer
SQL :	Structured Query Language
SR :	Système de Recommandation

Liste des tableaux

2.1	Correspondance entre objectifs spécifiques et choix méthodologiques	19
2.2	Sources de données mobilisées et utilisation méthodologique	20
3.1	Briques fonctionnelles du système implémenté	27
3.2	Vue d'ensemble des données normalisées	28
3.3	Synthèse du diagnostic d'intégration	39
4.1	Benchmark des modèles d'embeddings sur 473 requêtes de test	41
4.2	Comparaison retrieval : pgvector seul versus pgvector + graphe	42
A.1	Labels de nœuds et relations structurantes du graphe	V
A.2	Volume d'entités indexées dans la base vectorielle pgvector	VI

Table des figures

1.1	Évolution simplifiée des modèles de langage et des représentations textuelles	10
1.2	Différence fonctionnelle entre RAG, GraphRAG et Agentic RAG	12
2.1	Architecture méthodologique du workflow agentique de recommandation emploi-compétences	17
3.1	Disponibilité des champs clés pour le matching	29
3.2	Principaux secteurs représentés dans les offres	30
3.3	Localisation principale des offres	31
3.4	Niveaux NCF et expérience minimale demandés dans les offres	31
3.5	Structure des candidats selon le niveau NCF et le secteur visé	32
3.6	Compétences et familles de compétences les plus fréquentes dans les offres	33
3.7	Longueur des textes utilisés pour les embeddings	34
3.8	Comparaison macro entre secteurs des offres et secteurs visés par les candidats	35
3.9	Couverture des référentiels MEPC et NCF intégrés	35
3.10	Entités indexées dans la base vectorielle	36
3.11	Répartition des nœuds Neo4j par label	37
4.1	Comparaison des modèles d’embeddings sur le jeu de test	42
4.2	Effet de l’enrichissement graphe sur les métriques de retrieval	43
4.3	Distribution des déplacements de rang après reranking par le graphe	44
4.4	Stabilité opérationnelle observée pendant l’évaluation d’ablation	46

Avant-propos

L’Institut Sous-régional de Statistique et d’Économie Appliquée (ISSEA), institution spécialisée de la CEMAC créée en 1984, a pour mission principale la formation de cadres supérieurs en statistique, économie et data science, capables de répondre aux enjeux contemporains de décision fondée sur les données. Dans ce cadre, l’ISSEA propose plusieurs filières de formation, parmi lesquelles figure celle des Ingénieurs Statisticiens Économistes (ISE), alliant rigueur mathématique, modélisation économétrique et outils modernes d’analyse de données (Data Science).

Arrivés à un niveau avancé de leur formation, les élèves Ingénieurs Statisticiens Économistes sont tenus d’effectuer un stage professionnel d’une durée minimale de trois (03) mois. Ce stage constitue une phase essentielle du cursus, permettant de confronter les connaissances théoriques acquises à des problématiques réelles, tout en favorisant l’acquisition de compétences opérationnelles en environnement professionnel. Il est sanctionné par la rédaction d’un mémoire professionnel, soutenu devant un jury.

C’est dans ce cadre que nous avons effectué un stage du 9 mars 2026 au 30 juin 2026 au sein de KmerAI, où nous avons été intégrés à la Direction du Développement et de la Recherche. Cette immersion nous a permis de travailler sur une problématique appliquée située au croisement de l’analyse de données, de l’intelligence artificielle générative, du traitement automatique du langage naturel et de l’aide à la décision : l’amélioration du matching entre offres d’emploi, profils de candidats et compétences recherchées sur le marché camerounais.

Le présent mémoire s’inscrit dans cette dynamique et porte sur le thème : « Conception d’un système de recommandation hybride pour le matching emploi-compétences au Cameroun par intégration des LLMs et des graphes de connaissances ». Il vise principalement à concevoir une architecture capable de structurer les données d’offres et de profils, d’exploiter les référentiels métiers et formations, puis de produire des recommandations plus explicables que les approches fondées uniquement sur des mots-clés. Plus spécifiquement, il s’agit de normaliser les données disponibles, d’aligner les métiers et compétences avec les référentiels ESCO, MEPC et NCF, d’adapter un modèle d’embeddings au domaine emploi-compétences, de construire un graphe de connaissances sous Neo4j et de poser les bases d’un moteur de recommandation hybride intégrant similarité sémantique, relations de graphe et analyse du *skill gap*.

Ce travail répond à un double enjeu. Sur le plan scientifique et méthodologique, il cherche à montrer comment les modèles de représentation sémantique, les bases vectorielles et les graphes de connaissances peuvent être combinés pour traiter un problème réel d’appariement sur le marché du travail. Sur le plan opérationnel, il propose une démarche reproductible susceptible d’aider KmerAI à développer des outils de recommandation, d’orientation et de montée en compétences adaptés aux besoins des candidats, des recruteurs et des acteurs de la formation.

Résumé

Mots-clés : Économétrie, Statistique, Développement...

Abstract

INTRODUCTION GÉNÉRALE

Contexte et justification

Le fonctionnement du marché de l'emploi constitue un déterminant central de la performance économique et sociale d'un pays. Au Cameroun, ce marché reste marqué par des déséquilibres structurels persistants, notamment l'inadéquation entre les compétences disponibles et les besoins des entreprises, la forte informalité et les difficultés d'insertion professionnelle des jeunes. Les données disponibles montrent que le chômage des jeunes demeure une réalité importante, avec un taux estimé à 6,6% en 2024 et 6,5% en 2025 selon les estimations modélisées de l'OIT relayées par la Banque Mondiale et la base FRED. Par ailleurs, plusieurs travaux sur le Cameroun soulignent que le problème ne tient pas uniquement au manque d'emplois, mais aussi à un mismatch entre formation, compétences et exigences du marché.

Dans ce contexte, la question du matching emploi-compétences devient centrale. En théorie, un marché du travail efficient devrait permettre d'associer rapidement les profils disposant des compétences requises aux postes vacants correspondants. En pratique, plusieurs frictions informationnelles persistent : asymétrie d'information entre recruteurs et candidats, faible structuration des profils de compétences, hétérogénéité des offres d'emploi et faiblesse des systèmes d'intermédiation comme le FNE et certains agences de recrutement. Ces dysfonctionnements conduisent à une situation paradoxale où coexistent des postes non pourvus et des chercheurs d'emploi, traduisant une inefficacité allocative du marché du travail.

Par ailleurs, l'essor des technologies numériques et de l'intelligence artificielle ouvre des perspectives nouvelles pour améliorer l'appariement entre offres et profils. Dans cette dynamique, KmerAI se positionne comme une plateforme camerounaise dédiée à la promotion de l'intelligence artificielle, à la vulgarisation de ses usages et à l'accompagnement des étudiants, chercheurs et entreprises dans l'adoption de solutions innovantes adaptées au contexte local. Ses missions consistent notamment à former aux bases de l'IA, à offrir un espace de partage d'expériences et à encourager la collaboration autour de cas d'usage appliqués à des secteurs stratégiques tels que la santé, l'agriculture, le transport, l'éducation et le marketing.

Cette orientation est particulièrement pertinente pour le marché de l'emploi camerounais, où les données liées aux offres, aux CV et aux compétences restent souvent dispersées et peu exploitées. Une approche fondée sur l'intelligence artificielle peut permettre d'analyser plus efficacement ces données hétérogènes afin de proposer des recommandations d'emploi plus pertinentes, plus rapides et plus personnalisées.

Problématique

Le marché de l'emploi camerounais est marqué par une forte asymétrie d'information, une hétérogénéité des profils professionnels et des offres d'emploi, ainsi qu'une faible capacité des outils classiques à évaluer les écarts réels de compétences. Les systèmes fondés sur des mots-clés ou des filtres statiques ne parviennent pas à détecter les compétences implicites, les équivalences sémantiques et les trajectoires de montée en compétences.

Par ailleurs, si des référentiels structurants existent notamment la Nomenclature Camerounaise des

Métiers (NCM 2013), le référentiel européen ESCO et la Nomenclature Camerounaise des Formations (NCF), leur intégration opérationnelle dans les plateformes et outils d'appariement reste encore limitée. Ils sont peu exploités pour aligner les intitulés locaux de métiers sur des standards internationaux, harmoniser les compétences attendues, qualifier les niveaux et domaines de formation, et rendre les correspondances profil-offre plus transparentes et comparables. Il en résulte un décalage entre la richesse potentielle de ces référentiels et leur usage effectif dans les systèmes d'information dédiés à l'emploi et à l'orientation.

Dans ce contexte, la question centrale n'est plus seulement d'apparier un profil à une offre, mais de concevoir un système capable (i) d'exploiter conjointement les référentiels NCM, ESCO et NCF pour structurer les métiers, les compétences et les formations, (ii) de mesurer finement le *skill gap* entre un candidat et un poste cible, et (iii) de proposer un parcours de montée en compétences compatible avec le niveau, le domaine de formation et les trajectoires de qualification du candidat. La question principale de recherche peut ainsi être formulée comme suit :

Comment concevoir un système de recommandation hybride, fondé sur les LLMs, les graphes de connaissances, les embeddings vectoriels et le filtrage collaboratif, capable de mesurer le skill gap entre un profil et une offre d'emploi, puis de recommander un parcours de montée en compétences cohérent avec la nomenclature des formations, le niveau du candidat et le métier visé pour les membres de la communauté KmerAi ?

Cette question générale se décline en plusieurs questions de recherche sous-jacentes :

- **Q1** : Comment identifier et formaliser, dans le contexte camerounais, les compétences, métiers, formations et relations pertinentes pour un matching emploi compétences fiable et opérationnel à partir des référentiels NCM, ESCO et NCF ?
- **Q2** : Dans quelle mesure l'intégration d'un graphe de connaissances améliore-t-elle la qualité et la précision du matching par rapport aux approches purement vectorielles ?

Objectifs de l'étude

L'objectif général de cette étude est de concevoir et d'évaluer un système de recommandation hybride emploi-compétences capable d'aider à la décision dans le recrutement et la montée en compétence. Le système vise à rapprocher les profils de candidats et les offres d'emploi en combinant la recherche sémantique, les référentiels métiers et formations, le graphe de connaissances et une logique explicable de *skill gap*. Il ne s'agit donc pas seulement de retrouver les offres textuellement proches d'un profil, mais de produire un verdict opérationnel : identifier les offres immédiatement accessibles, distinguer celles qui nécessitent une montée en compétence, signaler les profils à conserver en vivier et expliciter les compétences à développer.

Plus spécifiquement, il sera question de :

- normaliser et aligner les offres d'emploi et profils candidats avec les référentiels ESCO, MEPC et NCF afin de produire des variables structurées intitulé de poste, compétences, niveau NCF, secteur, localisation exploitables par le système de matching ;
- adapter par *fine-tuning* contrastif un modèle *SentenceTransformer* au domaine emploi-compétences à partir de paires offre-profil, puis indexer les représentations produites dans une base vectorielle *pgvector* pour le retrieval sémantique ;

- construire un graphe de connaissances sous Neo4j modélisant les relations entre candidats, offres, compétences, métiers, secteurs et niveaux NCF, et concevoir un score hybride combinant similarité sémantique, couverture de compétences, compatibilité NCF et alignement sectoriel;
- orchestrer, via un workflow *LangGraph* multi-étapes, l'ensemble du pipeline de recommandation retrieval sémantique, enrichissement graphe, analyse de *skill gap*, scoring hybride, critique et replanification afin de produire des verdicts interprétables (profil prêt, montée en compétence, vivier, hors cible) accompagnés d'une trajectoire de formation, et d'évaluer la qualité du retrieval par les métriques Recall@K, NDCG@K, MRR@K et MAP@K.

Intérêt de l'étude

L'intérêt d'une telle approche est renforcé par les limites des méthodes classiques de recrutement, souvent fondées sur des critères statiques ou sur des mots-clés, qui ne captent pas toujours la richesse des parcours et des compétences. En combinant différentes logiques de recommandation, un système hybride peut mieux prendre en compte les dimensions explicites et implicites des profils candidats, tout en améliorant la qualité des correspondances proposées. Cela rejoint la mission de KmerAI, qui vise à favoriser l'appropriation locale de l'IA pour résoudre des problèmes concrets du développement camerounais.

Hypothèses de recherche

Afin de répondre à la problématique, cette étude repose sur les hypothèses suivantes.

- **H1** : L'intégration conjointe de la NCM, d'ESCO et de la NCF dans un référentiel unifié métiers-compétences-formations améliore la structuration et les performances d'appariement profil-offre, par rapport à une approche sans ces référentiels;
- **H2** : La modélisation du marché de l'emploi sous forme de graphe de connaissances (Neo4j), incluant explicitement les niveaux et domaines de formation de la NCF, améliore la qualité du matching par rapport à une approche purement vectorielle;
- **H3** : Le *fine-tuning* d'un modèle de représentation sémantique sur le domaine emploi-compétences améliore la qualité des embeddings et la similarité sémantique entre profils et offres, par rapport au même modèle non adapté;
- **H4** : La combinaison d'un RAG vectoriel, d'un GraphRAG et d'un score de recommandation hybride améliore la pertinence et l'explicabilité des recommandations de *skill gap* et de parcours de montée en compétences, notamment lorsque ces parcours sont contraints par la nomenclature des formations.

Méthodologie de recherche

La démarche adoptée s'inscrit dans un cadre d'ingénierie des données combinant structuration des connaissances et modélisation hybride. Elle repose sur la collecte et la normalisation des données issues d'offres d'emploi sur les différents sites web et de profils, alignées sur la NCM 2013 afin d'assurer la cohérence sémantique. Un graphe de connaissances est ensuite construit sous Neo4j en intégrant les référentiels ESCO et NCM, à partir d'un processus d'extraction automatique de triplets à partir des données textuelles. Parallèlement, les descriptions sont vectorisées et indexées dans un espace sémantique permettant la mesure de similarité. Le moteur de recommandation combine ces différentes sources d'information à travers un score hybride intégrant similarité structurelle, similarité sémantique et signal collaboratif. Le système permet ainsi d'identifier les écarts de compétences entre profils et offres, et de générer

des recommandations sous forme de trajectoires d'apprentissage. L'évaluation repose sur des métriques standard telles que la précision@K, le rappel et le NDCG, ainsi que sur l'analyse de la cohérence des recommandations générées.

Plan du travail

Le mémoire est structuré en trois parties. La première présente le cadre théorique relatif aux systèmes de recommandation, aux modèles de langage et aux graphes de connaissances. La deuxième détaille l'approche méthodologique, incluant la modélisation du graphe et la conception du système hybride. La troisième analyse les résultats obtenus et discute les performances du modèle ainsi que ses implications dans le contexte du marché du travail camerounais.

Première partie

Cadre théorique et conceptuel

FONDEMENTS THÉORIQUES ET REVUE DE LA LITTÉRATURE SUR L'IA GÉNÉRATIVE ET LES SYSTÈMES DE RECOMMANDATION

Ce chapitre situe le mémoire dans la littérature sur l'appariement emploi-compétences, les systèmes de recommandation, l'intelligence artificielle générative, les graphes de connaissances et la génération augmentée par récupération. Il ne vise pas à reprendre l'ensemble des raisonnements des ouvrages ou articles consultés. Il sélectionne les résultats qui éclairent directement le thème du stage : concevoir un système capable de recommander des offres, d'identifier des écarts de compétences et de produire des explications fondées sur des données structurées et non structurées.

La revue est guidée par une hypothèse centrale : le matching emploi-compétences n'est pas un simple problème de similarité textuelle. Il combine des frictions du marché du travail, une forte variabilité du vocabulaire, des contraintes de qualification, des relations métier-compétence-formation et un besoin d'explicabilité. Cette nature composite explique pourquoi la littérature pertinente relève à la fois de l'économie du travail, de la recommandation hybride, de la recherche sémantique, des graphes de connaissances et de la génération contrôlée.

1.1 Concepts clés mobilisés dans le mémoire

Avant d'entrer dans la revue de littérature, il est nécessaire de stabiliser les concepts utilisés dans la suite du mémoire. Cette clarification évite une confusion fréquente : employer indifféremment IA générative, LLM, RAG, GraphRAG, moteur de recommandation et chatbot. Dans ce travail, ces termes désignent des fonctions complémentaires, mais non interchangeables.

Matching emploi-compétences.

Le matching emploi-compétences désigne le processus qui consiste à rapprocher un profil candidat d'une offre, d'un métier ou d'une trajectoire de formation à partir de caractéristiques observables : compétences, niveau de formation, expérience, secteur, localisation et objectif professionnel. Il est traité ici comme un problème d'appariement économique, mais aussi comme un problème de représentation des connaissances.

Système de recommandation.

Un système de recommandation est un dispositif algorithmique qui classe des éléments selon leur pertinence probable pour un utilisateur ou un cas d'usage [1]. Dans ce mémoire, les éléments recommandés peuvent être des offres d'emploi, des compétences, des métiers ou des pistes de formation. La pertinence ne renvoie donc pas seulement à une préférence ; elle renvoie aussi à une compatibilité professionnelle

explicable.

Skill gap.

Le *skill gap*, ou écart de compétences, correspond à la différence entre les compétences déjà détenues par un candidat et celles attendues pour une offre ou un métier cible. Il permet de dépasser une logique binaire compatible/non compatible : un candidat peut être proche d'un poste tout en nécessitant une montée en compétences.

Embedding et recherche sémantique.

Un embedding est une représentation vectorielle d'un texte, d'un profil, d'une offre ou d'une compétence. La recherche sémantique utilise cette représentation pour retrouver des objets proches en sens, même lorsque les formulations diffèrent. Elle répond à un problème récurrent des données d'emploi : des expressions comme « data analyst », « analyste de données » et « reporting statistique » peuvent désigner des zones de compétences voisines.

Base vectorielle pgvector.

pgvector désigne l'extension PostgreSQL utilisée pour stocker et rechercher des embeddings [2]. Dans ce mémoire, elle sert de couche de recherche rapide pour retrouver les offres, métiers, compétences ou documents proches d'une requête. Son rôle est de présélectionner des candidats à la recommandation. Elle ne suffit cependant pas à décider seule, car un bon score vectoriel ne garantit pas que le niveau NCF, l'expérience ou les compétences obligatoires soient compatibles.

Graphe de connaissances Neo4j.

Un graphe de connaissances représente des entités et leurs relations : candidat, offre, compétence, métier, secteur, niveau, formation et référentiel [3]. Dans ce mémoire, Neo4j sert à représenter les relations explicites entre ces entités. Il permet de répondre à des questions que la seule similarité vectorielle ne traite pas correctement : quelles compétences une offre exige-t-elle ? quelles compétences le candidat possède-t-il ? quel niveau de formation est demandé ? quels chemins relient un métier à une formation ?

IA générative, LLM et prompting.

L'intelligence artificielle générative désigne les modèles capables de produire du contenu, notamment du texte. Un LLM est un grand modèle de langage entraîné sur de grands corpus textuels et capable de générer, reformuler ou synthétiser des réponses. Dans ce mémoire, le LLM n'est pas le moteur de vérité du système. Il intervient comme générateur contrôlé : il reçoit un contexte construit à partir de pgvector, Neo4j et des documents, puis rédige une réponse en français. Le prompting désigne l'ensemble des consignes données au modèle pour encadrer son comportement, limiter les inventions et structurer la réponse.

RAG, GraphRAG et Agentic RAG.

La RAG combine récupération d'information et génération : le système recherche d'abord des éléments pertinents, puis les transmet au LLM pour produire une réponse [4]. Le GraphRAG étend cette logique en ajoutant des faits et chemins issus d'un graphe de connaissances. L'Agentic RAG ajoute une couche d'orchestration : l'agent analyse l'intention, choisit les outils, récupère les données, construit le contexte, génère la réponse et peut demander une révision si le contexte est insuffisant. Dans ce mémoire, cette orchestration est assurée par LangGraph.

Critic et traçabilité.

Le critic est un mécanisme de contrôle qui examine si la réponse générée semble suffisamment couverte par le contexte récupéré. Il ne remplace pas une validation humaine, mais il réduit le risque d'une réponse fluide et insuffisamment fondée. La traçabilité désigne la capacité à afficher les outils mobilisés, les sources consultées et le chemin suivi par le workflow. Elle est indispensable dans un système d'aide à la décision, car une recommandation professionnelle doit être vérifiable.

1.2 Fondements économiques et problématique d'appariement

1.2.1 Marché du travail, recherche d'emploi et frictions

Le problème traité dans ce mémoire relève d'abord de l'économie du travail. Les modèles de recherche et d'appariement montrent que le chômage peut coexister avec des postes vacants lorsque la rencontre entre travailleurs et entreprises est coûteuse, lente ou imparfaitement informée [5, 6]. Cette lecture est importante : un système de recommandation emploi-compétences n'est pas seulement un outil informatique ; c'est un dispositif d'intermédiation qui cherche à réduire les coûts de recherche et à améliorer la qualité des mises en relation.

La littérature sur l'asymétrie d'information renforce ce diagnostic. Akerlof montre que l'incertitude sur la qualité peut dégrader les échanges lorsque les acteurs ne disposent pas de signaux fiables [7]. Sur le marché de l'emploi, cette asymétrie apparaît des deux côtés : le recruteur ne voit pas toujours les compétences réelles du candidat, et le candidat ne connaît pas toujours les exigences effectives du poste. La théorie du signalement de Spence explique alors le rôle des diplômes, certifications et expériences comme signaux observables [8]. Mais ces signaux restent incomplets lorsque les métiers évoluent rapidement, notamment dans les domaines numériques où les compétences techniques sont souvent décrites par des formulations instables.

1.2.2 Capital humain, tâches et inadéquation des compétences

La théorie du capital humain rappelle que la formation et l'expérience sont des investissements productifs [9]. Toutefois, la possession d'un capital humain ne garantit pas l'appariement. Encore faut-il que les compétences acquises soient visibles, comparables et alignées sur les compétences demandées. Autor montre que le progrès technique transforme surtout les tâches composant les métiers, et non uniquement les intitulés d'emploi [10]. Pour un système de recommandation, cela impose de descendre au niveau des compétences et des tâches plutôt que de s'arrêter aux titres de poste.

L'apport de cette littérature est de montrer que l'inadéquation emploi-compétences relève autant de la circulation imparfaite de l'information que d'un manque de formation. Sa limite, pour notre objet, est qu'elle ne fournit pas directement les outils de traitement des données nécessaires pour extraire, normaliser, comparer et expliquer les compétences. La section suivante examine donc les systèmes de recommandation comme réponse algorithmique à ce problème d'appariement.

1.3 Systèmes de recommandation et person-job fit

1.3.1 Approches par contenu, collaboratives et hybrides

Les systèmes de recommandation cherchent à classer des items selon leur pertinence probable pour un utilisateur. La littérature distingue classiquement les approches fondées sur le contenu, le filtrage collaboratif et les approches hybrides [11, 1]. Dans le contexte de ce mémoire, l'utilisateur peut être un candidat, un conseiller emploi ou une plateforme; les items peuvent être des offres, compétences, métiers ou formations.

Les approches fondées sur le contenu utilisent les caractéristiques explicites des items et des profils. Elles sont adaptées au matching emploi-compétences parce que les offres et les candidats possèdent des descriptions textuelles, des secteurs, des niveaux et des compétences. Pazzani et Billsus montrent que ces systèmes exploitent les attributs des contenus pour produire des recommandations personnalisées [12]. Leur avantage est l'interprétabilité; leur limite est la dépendance au vocabulaire observé.

Le filtrage collaboratif exploite les interactions passées entre utilisateurs et items. Les approches de factorisation matricielle ont fortement structuré ce domaine en apprenant des facteurs latents à partir des matrices d'interactions [13]. Les modèles neuronaux ont ensuite généralisé cette logique, par exemple avec le Neural Collaborative Filtering [14]. Ces méthodes sont puissantes lorsque l'on dispose d'un historique dense : clics, candidatures, recrutements, évaluations ou parcours de formation. Dans le cas étudié ici, cette hypothèse est fragile, car les données d'interaction restent limitées et de nombreux profils se trouvent en situation de démarrage à froid.

Les approches hybrides combinent plusieurs sources de signal pour compenser les limites propres à chaque famille. Burke montre que l'hybridation peut améliorer la robustesse en associant contenu, collaboration, connaissances et règles métier [15]. Cette conclusion prépare directement le choix d'un système hybride : les signaux textuels, relationnels et métier doivent être séparés puis combinés, car chacun ne capture qu'une partie de la compatibilité.

1.3.2 Spécificité du *person-job fit*

La recommandation d'emploi se distingue de la recommandation de films ou de produits. Une offre n'est pas seulement un item susceptible de plaire; elle impose des contraintes de qualification, d'expérience, de localisation, de disponibilité et de compétences. La littérature récente sur le *person-job fit* insiste sur cette double sélection : le candidat doit être intéressé par l'offre, mais l'employeur doit aussi pouvoir considérer le profil comme compatible [16]. La recommandation devient donc un problème bilatéral.

Cette spécificité change l'interprétation des scores. Dans le commerce électronique, une recommandation peut viser la probabilité de clic ou d'achat. Dans l'emploi, une recommandation doit distinguer au moins trois situations : le candidat est immédiatement compatible; le candidat est proche mais nécessite une montée en compétences; le candidat est trop éloigné du poste cible. La notion de *skill gap* devient alors centrale.

Les travaux récents mobilisant les graphes et les LLM dans les ressources humaines vont dans ce sens. HRGraph propose par exemple d'exploiter des graphes de connaissances enrichis par LLM pour la recommandation d'emploi [17]. D'autres travaux s'intéressent à la prédiction des compétences et à la construction de graphes de talents pour les ressources humaines [18]. Ces contributions confirment l'intérêt des graphes pour représenter les relations entre compétences, métiers et profils, mais elles ne résolvent pas automatiquement la question de l'ancrage local : nomenclatures camerounaises, données


réelles de plateforme, contraintes de formation et explication opérationnelle.

1.4 IA générative et connaissances

1.4.1 Grands modèles de langage et génération contrôlée

Les grands modèles de langage ont transformé le traitement automatique du langage naturel en permettant des tâches de génération, synthèse, reformulation et raisonnement assisté. Leur rupture technique vient principalement de l'architecture Transformer proposée par Vaswani et al., fondée sur le mécanisme d'attention [19]. Avant cette rupture, les représentations textuelles étaient passées des sacs de mots aux embeddings denses comme Word2Vec, qui apprennent des vecteurs capturant des régularités sémantiques et syntaxiques [20]. Les mécanismes d'attention introduits en traduction neuronale ont ensuite permis aux modèles de pondérer dynamiquement les parties pertinentes d'une séquence [21].

FIGURE 1.1 – Évolution simplifiée des modèles de langage et des représentations textuelles



Source : Figure du dossier du projet, synthèse pédagogique de l'évolution des modèles de langage

Deux grandes familles de modèles sont utiles pour ce mémoire. La première regroupe les modèles de représentation, comme BERT et Sentence-BERT. BERT apprend des représentations contextuelles bidirectionnelles adaptées à la compréhension du texte [22]. Sentence-BERT adapte cette logique pour produire des embeddings de phrases comparables efficacement par similarité cosinus [23]. La seconde famille regroupe les modèles génératifs, comme GPT, T5 ou les modèles instruction-tuned. GPT-3 a montré qu'un modèle de grande taille pouvait effectuer des tâches variées à partir de quelques exemples dans le prompt [24]. T5 a proposé une formulation unifiée des tâches NLP comme transformation texte-vers-texte [25]. L'apprentissage par retour humain a ensuite amélioré la capacité des modèles à suivre des instructions [26].

L'acquis de cette littérature est considérable : les LLM savent reformuler, synthétiser et produire des explications lisibles. Sa limite, pour notre problématique, tient au statut de la vérité : un modèle génératif peut produire une réponse plausible sans être fondée sur les données locales. Dans un système d'emploi, cette limite impose une génération contrôlée par des sources récupérées.

1.4.2 Embeddings, recherche sémantique et bases vectorielles

Après la clarification conceptuelle, l'enjeu est de savoir dans quelles conditions les représentations vectorielles sont fiables pour la recherche d'information. Les benchmarks montrent que les modèles d'embeddings doivent être évalués sur des tâches variées, car un bon modèle généraliste peut être insuffisant dans un domaine spécialisé [27, 28]. Cette observation justifie l'adaptation d'un modèle SentenceTransformer au vocabulaire emploi-compétences.

La recherche sémantique résout une partie du problème de vocabulaire, mais elle reste une approximation. Deux textes proches peuvent cacher une incompatibilité : niveau insuffisant, compétence obligatoire absente, localisation incompatible ou métier trop éloigné. La similarité vectorielle doit donc être traitée comme un signal de présélection, non comme une décision finale.

La littérature sur la recherche approximative de plus proches voisins montre par ailleurs que le passage à l'échelle exige des structures d'indexation efficaces. HNSW fournit un cadre robuste pour la recherche vectorielle approximative [29], tandis que FAISS a popularisé la recherche vectorielle à grande échelle [30]. Dans ce mémoire, l'utilisation de PostgreSQL avec pgvector répond à une logique pragmatique : conserver les embeddings dans une base relationnelle exploitable, interrogeable et intégrable au reste du pipeline [2].

1.4.3 Graphes de connaissances et recommandation relationnelle

Hogan et al. montrent que les graphes de connaissances servent à structurer des informations hétérogènes, à rendre explicites des relations sémantiques et à soutenir des tâches de recherche ou de raisonnement [3]. Dans le domaine emploi-compétences, cette représentation complète la recherche vectorielle : elle rend visibles les relations entre candidats, offres, compétences, métiers, formations et niveaux.

La recommandation par graphe a également connu des avancées importantes. Les graph neural networks ont fourni des outils pour propager de l'information dans des graphes [31, 32]. LightGCN a montré que, dans la recommandation collaborative, une architecture simplifiée de propagation sur graphe pouvait être très efficace [33]. Ces travaux établissent l'intérêt de la structure relationnelle pour la recommandation.

Cependant, le présent mémoire ne cherche pas principalement à entraîner un GNN. Le choix méthodologique est différent : utiliser un graphe de connaissances comme support d'explication, de contraintes et de calcul du skill gap. Ce choix est plus adapté au contexte disponible. Les données d'interaction ne sont pas assez riches pour justifier un modèle collaboratif profond, tandis que les relations métier-compétence-formation sont directement interprétables.


1.5 RAG, GraphRAG et orchestration agentique

1.5.1 De la RAG au GraphRAG

La génération augmentée par récupération, ou RAG, combine une étape de recherche d'information et une étape de génération. Lewis et al. montrent que l'accès à une mémoire externe améliore les tâches intensives en connaissances, car le modèle ne dépend plus uniquement de ses paramètres internes [4]. Les synthèses récentes sur la RAG insistent sur les mêmes enjeux : qualité de la récupération, actualisation des connaissances, évaluation de la factualité et articulation entre retriever et générateur [34].

Dans une RAG classique, le système récupère des documents proches d’une requête, puis les transmet au LLM. Cette architecture est utile, mais elle reste centrée sur des passages textuels. Pour le matching emploi-compétences, le contexte doit aussi intégrer des relations : compétences possédées, compétences requises, niveau de formation, métier cible, secteur et formation possible. Le GraphRAG étend alors la récupération vers des informations structurées par graphe.

FIGURE 1.2 – Différence fonctionnelle entre RAG, GraphRAG et Agentic RAG



Source : Figure du dossier du projet, inspirée des architectures Agentic RAG et des travaux sur agents outillés

La figure 1.2 illustre cette évolution. Une RAG simple suit une chaîne relativement fixe : requête, récupération, génération. Une architecture GraphRAG ajoute une couche relationnelle. Une architecture agentique introduit une capacité de planification et de contrôle : le système peut choisir un outil, observer le résultat, élargir le contexte et réviser la réponse.

1.5.2 Agentic RAG, critic et traçabilité

Les travaux ReAct montrent l’intérêt d’alterner raisonnement et action outillée dans les modèles de langage [35]. Self-RAG va plus loin en introduisant une logique d’auto-réflexion pour décider quand récupérer de l’information et comment critiquer la réponse [36]. Pour ce mémoire, ces travaux ne doivent pas être interprétés comme une autorisation à laisser un agent décider librement. Ils justifient plutôt

une orchestration contrôlée : classer l'intention, choisir les sources, récupérer les preuves, construire le contexte, générer, puis vérifier si la réponse est suffisamment fondée.

Le manque de la littérature est ici opérationnel. Beaucoup de travaux décrivent des architectures générales, mais la fiabilité dépend de détails concrets : qualité des chunks, schéma du graphe, robustesse des requêtes, traçabilité des sources, gestion des cas sans résultat et critères de révision. C'est pourquoi l'architecture retenue ajoute un critic et des traces d'exécution. Le LLM produit la réponse finale, mais les données récupérées et les outils appelés doivent rester observables.

1.6 Évaluation, acquis de la littérature et positionnement du mémoire

1.6.1 Évaluer la performance et la factualité

L'évaluation d'un système emploi-compétences ne peut pas se limiter à la fluidité de la réponse générée. Elle doit d'abord mesurer la qualité de la récupération d'information : le système retrouve-t-il les offres, compétences ou documents réellement pertinents ? La littérature en recherche d'information utilise pour cela des métriques de classement comme Precision@k, Recall@k, MRR et NDCG [27, 28]. Ces métriques supposent l'existence d'un ensemble de résultats pertinents, noté $Rel(q)$, pour une requête q , et d'une liste classée de résultats retournés par le système.

La **Precision@k** mesure la proportion de résultats pertinents parmi les k premiers résultats retournés. Si $R_k(q)$ désigne l'ensemble des k premiers éléments proposés pour la requête q , alors :

$$Precision@k(q) = \frac{|R_k(q) \cap Rel(q)|}{k}. \quad (1.1)$$

Cette métrique répond à la question suivante : parmi les premières recommandations affichées, combien sont réellement utiles ? Dans un système emploi-compétences, une Precision@5 élevée signifie que les cinq premières offres proposées contiennent peu de résultats non pertinents. Sa limite est qu'elle ne mesure pas si le système a retrouvé tous les bons résultats disponibles.

Le **Recall@k** mesure au contraire la proportion des éléments pertinents retrouvés dans les k premiers résultats :

$$Recall@k(q) = \frac{|R_k(q) \cap Rel(q)|}{|Rel(q)|}. \quad (1.2)$$

Cette métrique répond à la question : parmi toutes les offres ou compétences pertinentes, quelle part le système a-t-il réussi à faire remonter ? Elle est importante pour ne pas éliminer trop tôt des offres utiles. En recommandation emploi, un faible Recall@k peut signifier que le moteur rate des opportunités pertinentes pour le candidat.

Le **MRR** (*Mean Reciprocal Rank*) évalue la position du premier résultat pertinent. Pour une requête q , si $rank_q$ est le rang du premier résultat pertinent, alors le score associé est :

$$RR(q) = \frac{1}{rank_q}. \quad (1.3)$$

Sur un ensemble de N requêtes, le MRR est :

$$MRR = \frac{1}{N} \sum_{q=1}^N \frac{1}{rank_q}. \quad (1.4)$$

Cette métrique est utile lorsque l'on veut savoir si le système place rapidement au moins une bonne réponse. Dans une interface de recommandation, cela correspond à une logique pratique : l'utilisateur regarde souvent les premiers résultats avant de parcourir toute la liste.

Le **nDCG@k** (*normalized Discounted Cumulative Gain*) tient compte non seulement de la présence des résultats pertinents, mais aussi de leur ordre et éventuellement de leur degré de pertinence. Si rel_i désigne le niveau de pertinence du résultat placé au rang i , alors :

$$DCG@k = \sum_{i=1}^k \frac{2^{rel_i} - 1}{\log_2(i + 1)}. \quad (1.5)$$

Le score est ensuite normalisé par le meilleur classement possible, noté $IDCG@k$:

$$NDCG@k = \frac{DCG@k}{IDCG@k}. \quad (1.6)$$

Cette métrique est particulièrement adaptée lorsque tous les résultats pertinents ne se valent pas. Par exemple, une offre parfaitement alignée avec les compétences du candidat devrait être mieux classée qu'une offre seulement partiellement compatible.

Dans une architecture RAG, l'évaluation ne s'arrête pas au classement des résultats. Elle doit aussi mesurer la qualité de la réponse générée à partir du contexte récupéré. RAGAS distingue notamment la fidélité au contexte, la pertinence de la réponse, la qualité de la récupération et l'usage des sources [37]. La **fidélité** vérifie si les affirmations de la réponse sont supportées par les éléments récupérés. La **pertinence de réponse** vérifie si la réponse traite effectivement la question posée. La **couverture des sources** vérifie si le contexte contient suffisamment d'informations pour répondre. Enfin, la **traçabilité** vérifie si les preuves ou citations sont identifiables.

Ces critères sont moins simples à formaliser que Precision@k ou Recall@k, car ils portent sur du langage naturel. Des approches comme G-Eval utilisent des LLM comme juges pour approximer l'évaluation humaine [38]. Cette pratique doit rester prudente : un juge automatique peut aider à comparer des variantes de système, mais il ne remplace pas une validation métier. Dans ce mémoire, l'évaluation doit donc combiner des métriques de retrieval pour pgvector et Neo4j, des critères de factualité pour la réponse générée, et une interprétation professionnelle de l'utilité des recommandations.

1.6.2 Acquis, manques et contribution du mémoire

La littérature fournit plusieurs acquis solides. Les modèles d'appariement du marché du travail expliquent pourquoi les frictions informationnelles justifient des dispositifs d'intermédiation. Les systèmes de recommandation montrent que l'hybridation est souvent nécessaire lorsque les données sont hétérogènes. Les Transformers et les embeddings permettent de dépasser la recherche lexicale. Les graphes de connaissances apportent une structure relationnelle utile pour expliquer les recommandations. La RAG et l'Agentic RAG permettent enfin de produire des réponses en langage naturel à partir de contextes récupérés.

Mais ces acquis laissent des manques importants. Premièrement, une proximité sémantique n'est pas une preuve de compatibilité professionnelle. Deuxièmement, les modèles collaboratifs exigent des

historiques d'interaction souvent absents dans les plateformes émergentes. Troisièmement, un LLM peut formuler une réponse convaincante sans être fidèle aux données. Quatrièmement, les graphes RH proposés dans la littérature ne sont pas automatiquement adaptés aux nomenclatures camerounaises ni aux données locales de KmerAI.

Le domaine de recherche du mémoire se situe donc à l'intersection de la recommandation hybride, des graphes de connaissances et de la génération contrôlée. La contribution n'est pas de proposer un nouveau Transformer ou un nouvel algorithme de factorisation matricielle. Elle consiste à concevoir et évaluer une architecture intégrée pour le matching emploi-compétences, dans laquelle chaque brique remplit une fonction distincte : présélection sémantique, contrôle relationnel, calcul d'écart de compétences, génération contextualisée et vérification de la réponse.

Cette position est volontairement prudente. Le système ne prétend pas remplacer l'expertise humaine du conseiller emploi ou du recruteur. Il vise à rendre l'information plus exploitable : quelles offres sont proches du profil, quelles compétences expliquent la recommandation, quels écarts subsistent, et quelles pistes de formation peuvent réduire ces écarts. C'est cette articulation entre performance algorithmique, explicabilité et utilité professionnelle qui guide les choix méthodologiques et l'implémentation présentés dans les chapitres suivants.

SOURCE DE DONNÉES ET APPROCHE

MÉTHODOLOGIQUE

2.1 Cadre méthodologique et sources de données

2.1.1 Positionnement méthodologique

La présente étude adopte une démarche d'ingénierie appliquée orientée vers la conception, l'intégration et l'évaluation d'un artefact numérique d'aide à la décision. L'objet étudié n'est donc pas uniquement un modèle statistique pris isolément, mais un système complet de recommandation emploi-compétences combinant données structurées, représentations vectorielles, graphe de connaissances, règles métier et génération augmentée par récupération. Ce positionnement est cohérent avec la problématique du mémoire : améliorer l'appariement entre candidats, offres d'emploi, compétences, métiers et trajectoires de formation dans un contexte où l'information est hétérogène, incomplète et dispersée.

La logique méthodologique retenue repose sur quatre principes. Le premier est la *traçabilité* : chaque recommandation doit pouvoir être rattachée à des données observables, à un référentiel ou à une relation explicite du graphe. Le deuxième est l'*hybridation* : aucune source d'information ne suffit seule à résoudre le problème. La similarité sémantique capte les proximités de langage, le graphe encode les relations métier, les règles contrôlent les contraintes de niveau et le LLM sert à formuler une réponse intelligible. Le troisième principe est l'*explicabilité opérationnelle* : le système ne doit pas seulement retourner une liste d'offres, mais justifier le rapprochement, signaler les compétences communes, identifier les écarts et proposer une trajectoire de montée en compétences. Le quatrième principe est le *contrôle génératif* : les réponses produites par le LLM doivent être contraintes par le contexte récupéré afin de réduire le risque d'hallucination, conformément à la logique du RAG [4, 37].

Ce chapitre précise donc les choix de conception du système. Les résultats d'exécution, les performances mesurées et les exemples de réponses sont volontairement réservés aux chapitres suivants. La méthodologie décrit ici comment les données sont préparées, comment les représentations sont construites, comment les bases pgvector et Neo4j sont articulées, comment le workflow agentique est organisé et comment l'évaluation est conçue.

La figure 2.1 présente l'architecture générale retenue pour la solution. Elle doit être lue comme une carte méthodologique du système plutôt que comme un simple schéma technique. Le point d'entrée est la requête de l'utilisateur. Cette requête n'est pas transmise directement au modèle génératif ; elle est d'abord interprétée par une couche d'orchestration qui détermine le type de besoin exprimé. Cette étape est centrale, car une demande de recommandation candidat-offre, une question sur un référentiel, une interrogation relationnelle sur les compétences ou une question globale ne mobilisent pas les mêmes




FIGURE 2.1 – Architecture méthodologique du workflow agentique de recommandation emploi-compétences

Source : Auteur

sources ni les mêmes traitements.

Le workflow distingue ainsi plusieurs familles de traitements. La recommandation candidat s'appuie sur une combinaison de recherche vectorielle, de recherche textuelle et de signaux issus du graphe afin de produire un classement explicable. La recherche référentielle privilégie les fragments documentaires et les métadonnées associées, car l'enjeu est alors de retrouver une information sourcée. Les questions relationnelles exploitent davantage Neo4j, où les liens entre métiers, compétences, niveaux, secteurs et formations permettent de répondre à des questions que la similarité textuelle seule ne suffit pas à résoudre. Les questions globales mobilisent une synthèse plus large, fondée sur des résumés, des communautés ou des agrégations issues de plusieurs sources.

L'intérêt méthodologique de cette architecture est donc l'hybridation contrôlée. PostgreSQL avec pg-vector joue le rôle de mémoire sémantique pour retrouver des objets proches dans l'espace des embeddings. Neo4j joue le rôle de mémoire relationnelle pour vérifier, expliquer et pondérer les liens métier-compétence-formation. Les documents référentiels apportent une base de citation et de traçabilité. Le constructeur de contexte rassemble ensuite ces résultats dans un format exploitable par le LLM, en évitant de lui confier seul la décision de pertinence. La génération intervient donc en aval, après récupération et structuration du contexte.

Enfin, la partie inférieure du schéma rappelle que le système ne s'arrête pas à la production d'une réponse. Un module de critique évalue si la réponse est suffisamment pertinente, factuelle, complète et traçable. Si le contexte est insuffisant, la boucle peut relancer une recherche élargie avant de produire une réponse révisée. Ce choix méthodologique est important pour le mémoire : l'architecture ne cherche pas seulement à générer un texte convaincant, mais à produire une recommandation fondée sur des sources identifiables, des relations vérifiables et des critères métier explicites. Les sections suivantes détaillent chacune de ces briques : préparation des données, construction des embeddings, stockage vectoriel, graphe de connaissances, moteur hybride, orchestration agentique et protocole d'évaluation.

TABLE 2.1 – Correspondance entre objectifs spécifiques et choix méthodologiques

Objectif spécifique	Choix méthodologique retenu
Normaliser les offres, candidats et référentiels	Construction d'une couche de données standardisée : identifiants stables, champs nettoyés, niveaux de formation, secteurs, compétences et textes d'embedding.
Adapter la recherche sémantique au domaine emploi-compétences	Fine-tuning contrastif d'un modèle SentenceTransformer, puis indexation des embeddings dans PostgreSQL avec pgvector pour le retrieval top- K [23, 2].
Représenter les relations entre métiers, compétences et profils	Construction d'un graphe de connaissances Neo4j reliant candidats, offres, compétences, métiers, secteurs, localisations et référentiels [3, 39].
Produire une recommandation explicable	Score hybride combinant similarité vectorielle, couverture de compétences, compatibilité de niveau et alignement sectoriel, complété par une analyse de <i>skill gap</i> .
Orchestrer la réponse utilisateur	Workflow LangGraph routant la requête vers les outils adaptés : pgvector, Neo4j, recherche documentaire, Text2Cypher, critic et génération finale.
Evaluer la qualité du système	Protocole séparant l'évaluation du retrieval, du graphe, du classement et de la réponse générée.

Source : Auteur

2.1.2 Sources de données et leur rôle dans le système

Le système mobilise deux catégories de données. La première correspond aux données opérationnelles du marché du travail : offres d'emploi et profils de candidats. Ces données décrivent respectivement la demande de travail et l'offre de travail disponible. La seconde catégorie correspond aux référentiels de structuration : ESCO, MEPC et NCF. Ces référentiels permettent d'éviter une approche purement textuelle et de rattacher les intitulés, compétences et niveaux de formation à des nomenclatures interprétables.

Les offres d'emploi apportent les informations relatives aux postes disponibles : intitulé, employeur, secteur, localisation, type de contrat, expérience attendue, niveau d'étude, compétences mentionnées et description détaillée. Les profils candidats décrivent les caractéristiques individuelles : diplôme, niveau d'étude, spécialité, expérience, compétences, mobilité et objectif professionnel. Ces deux sources sont naturellement bruitées : les intitulés ne sont pas normalisés, les compétences peuvent être formulées librement et certaines variables sont incomplètes. La méthodologie doit donc transformer ces données en objets comparables.

ESCO fournit une nomenclature internationale des métiers et compétences. Son intérêt est de disposer d'un vocabulaire structuré et de relations métier-compétence déjà établies. La MEPC permet d'ancrer le système dans la nomenclature camerounaise des métiers. La NCF fournit une structure nationale des niveaux et domaines de formation. L'intégration conjointe de ces sources permet de relier le langage des annonces, les profils des candidats et les classifications institutionnelles.

TABLE 2.2 – Sources de données mobilisées et utilisation méthodologique

Source	Nature		Utilisation dans la méthode
Offres d'emploi	Données opérationnelles collectées par KmerAI		Normalisation, extraction de compétences, génération de <code>text_to_embed</code> , indexation vectorielle, création des noeuds d'offres et calcul des scores de matching.
Profils candidats	Base locale de demandeurs		Normalisation du niveau, du diplôme, de la mobilité et du métier visé; création des embeddings candidats; analyse de compatibilité avec les offres.
ESCO	Référentiel	métiers-compétences	Source de métiers, compétences, groupes ISCO et relations métier-compétence, utilisée pour structurer le graphe et enrichir les correspondances.
MEPC	Nomenclature camerounaise des métiers		Ancrage national des métiers, structuration hiérarchique et alignement partiel avec les groupes internationaux.
NCF	Nomenclature camerounaise des formations		Codification des niveaux et domaines de formation, utilisée pour la compatibilité candidat-offre et l'analyse de montée en compétences.
PDF réglementaires	Documents	officiels fragmentés	Constitution de <code>DocChunk</code> pour la recherche référentielle et la citation des sources.

Source : Auteur

2.1.3 Préparation et normalisation des données

La préparation des données constitue la première couche méthodologique du système. Son objectif est de produire des tables propres, stables et exploitables par les deux moteurs de recherche : le moteur vectoriel et le moteur graphe. Cette étape ne se limite pas au nettoyage cosmétique des textes. Elle détermine la qualité des relations construites, la pertinence des embeddings et la fiabilité des recommandations.

Pour les offres d'emploi, la normalisation consiste d'abord à réduire les doublons et les variations de forme. Une annonce peut apparaître plusieurs fois avec des différences mineures de titre, d'employeur ou de localisation. Le traitement doit donc stabiliser les identifiants et conserver les informations utiles sans multiplier artificiellement les observations. Les champs textuels sont ensuite harmonisés : suppression des caractères parasites, standardisation des espaces, séparation des champs multi-valeurs et conservation des informations de contexte. Les compétences mentionnées sont transformées en listes exploitables, tandis que les localisations et secteurs sont séparés en valeurs principales et valeurs secondaires.

Pour les candidats, la normalisation porte sur le diplôme, le niveau d'étude, la spécialité, l'expérience, les compétences, le secteur visé et la mobilité géographique. Une attention particulière est portée au niveau de formation. Lorsque l'information disponible le permet, le niveau est rapproché de la NCF. Ce rapprochement est indispensable parce qu'une recommandation emploi-compétences ne peut pas se fonder uniquement sur la proximité textuelle : une offre peut être sémantiquement proche d'un profil tout en exigeant un niveau de qualification supérieur.

Chaque offre et chaque candidat reçoit enfin un champ `text_to_embed`. Ce champ synthétise les éléments utiles pour la recherche sémantique : intitulé, compétences, secteur, niveau, description et ob-

jectif. Le choix d'un texte synthétique répond à une contrainte pratique : les modèles d'embeddings travaillent sur des séquences textuelles, mais les données métier sont partiellement structurées. Le champ `text_to_embed` sert donc d'interface entre les variables métiers et l'espace vectoriel.

2.1.4 Alignement des référentiels métiers et formations

L'alignement des référentiels répond à un besoin central : rendre comparables des données issues de sources différentes. Les annonces utilisent des formulations libres, ESCO propose une taxonomie internationale, la MEPC suit une logique nationale de classification des métiers et la NCF structure les formations. La méthode adoptée est prudente : elle vise un alignement exploitable pour la recommandation, sans prétendre établir une équivalence parfaite entre toutes les nomenclatures.

La MEPC est structurée selon ses niveaux hiérarchiques : grands groupes, sous-groupes et groupes de base. La NCF est organisée autour des niveaux de formation, grands domaines, domaines spécialisés et domaines détaillés. Cette structuration permet de conserver l'information institutionnelle au lieu de la réduire à de simples libellés. Les tables obtenues alimentent ensuite le graphe Neo4j et la base vectorielle.

L'alignement avec ESCO s'appuie sur les codes et les proximités de libellés lorsque ces informations sont disponibles. Cette stratégie est méthodologiquement raisonnable, mais elle doit être interprétée avec prudence. Un même groupe de classification peut regrouper plusieurs réalités professionnelles. L'alignement sert donc à améliorer la couverture et l'interprétabilité, non à produire une vérité définitive sur l'équivalence entre métiers.

2.2 Modélisation sémantique et structuration des connaissances

2.2.1 Choix du modèle d'embeddings et fine-tuning

Le système utilise un modèle SentenceTransformer pour représenter les offres, candidats, métiers, compétences et fragments documentaires dans un espace vectoriel. Ce choix est adapté au problème, car le matching emploi-compétences repose largement sur la similarité sémantique entre textes courts ou semi-structurés : intitulés de postes, compétences, descriptions d'annonces, objectifs professionnels et libellés de référentiels. Les SentenceTransformers ont été conçus pour produire des embeddings directement comparables par similarité cosinus, ce qui les rend adaptés aux tâches de recherche sémantique [23].

Le fine-tuning retenu n'est pas un fine-tuning génératif. Il ne vise pas à apprendre au modèle à rédiger des réponses, mais à adapter l'espace vectoriel au vocabulaire local du domaine emploi-compétences. La logique est contrastive : rapprocher les paires pertinentes et éloigner les paires moins pertinentes. Par exemple, une offre de « data analyst » doit être rapprochée d'un profil mentionnant analyse de données, statistique, Python, SQL ou visualisation, même si les formulations exactes diffèrent. A l'inverse, un profil orienté développement web ne doit pas être considéré comme équivalent à une offre de comptabilité uniquement parce que certaines expressions génériques se ressemblent.

Les paires d'apprentissage sont construites à partir des données préparées. Elles peuvent mobiliser les relations offre-compétence, métier-compétence, candidat-métier et offre-candidat lorsque les signaux disponibles sont suffisamment fiables. Cette étape est critique : un fine-tuning apprend les régularités de ses exemples. Des paires mal construites peuvent dégrader l'espace vectoriel au lieu de l'améliorer. La méthodologie retient donc une construction contrôlée des exemples, puis une évaluation séparée du

modèle de base et du modèle adapté.

2.2.2 Indexation vectorielle dans PostgreSQL et pgvector

Les embeddings produits sont stockés dans PostgreSQL avec l’extension pgvector. Ce choix permet de conserver dans un même environnement des représentations vectorielles et des métadonnées relationnelles. pgvector permet l’indexation et la recherche de voisins proches dans PostgreSQL, ce qui facilite l’intégration avec les autres tables du système [2]. Pour accélérer les recherches top- K , la méthode s’appuie sur une logique d’indexation approximative des voisins proches, cohérente avec les travaux sur HNSW [29].

La base vectorielle joue deux rôles. Le premier est le retrieval sémantique : retrouver les offres, métiers, compétences ou documents proches d’une requête. Le second est le préfiltrage pour la recommandation : produire un ensemble de candidats plausibles avant d’appliquer des contraintes plus structurées. Ce préfiltrage est nécessaire, car le graphe de connaissances apporte de l’explicabilité, mais il n’est pas toujours le meilleur premier filtre lorsque la requête est formulée librement.

Chaque résultat vectoriel doit conserver ses métadonnées : identifiant, type d’entité, libellé, source, score de similarité et texte associé. Sans ces métadonnées, la génération finale serait incapable de citer ses sources et le système perdrait sa traçabilité.

2.2.3 Construction du graphe de connaissances Neo4j

Le graphe de connaissances représente la couche relationnelle du système. Son rôle est de modéliser explicitement les relations entre les candidats, les offres, les compétences, les métiers, les secteurs, les localisations et les référentiels. Cette représentation est justifiée par la nature même du problème : le matching emploi-compétences n’est pas seulement une question de proximité textuelle, mais une question de relations. Une offre requiert des compétences, un candidat possède des compétences, un métier est classé dans une nomenclature, un niveau de formation conditionne l’accès à certains postes, et une trajectoire de montée en compétences dépend des écarts identifiés.

La méthodologie retient des noeuds correspondant aux entités principales : **OffreEmploi**, **Candidat**, **Compétence**, **Métier**, **Secteur**, **Localisation**, **DocChunk**, **DocumentReferentiel** et groupes de nomenclature. Les relations décrivent les liens fonctionnels : une offre **REQUIERT** une compétence, un candidat **POSSEDE** une compétence, une offre est rattachée à un secteur ou à une localisation, un métier est classé dans un groupe, et un fragment documentaire provient d’un document référentiel.

Ce graphe sert à trois opérations méthodologiques. Premièrement, il vérifie les correspondances proposées par la recherche vectorielle. Deuxièmement, il explique les recommandations en identifiant les compétences communes et manquantes. Troisièmement, il permet des requêtes relationnelles que la recherche vectorielle gère mal, par exemple : quelles compétences sont associées à un métier donné ? quelles offres exigent une compétence précise ? quelles compétences manquent à un candidat pour viser une famille de métiers ?

2.2.4 Score hybride et logique de skill gap

Le score de recommandation combine plusieurs signaux complémentaires. La similarité sémantique mesure la proximité entre le texte du profil et celui de l’offre. La couverture de compétences mesure la proportion des compétences requises par l’offre qui sont déjà présentes chez le candidat. La compatibilité de niveau vérifie si le niveau de formation du candidat est cohérent avec le niveau attendu par l’offre.

L'alignement sectoriel mesure la cohérence entre le secteur ou le domaine du candidat et celui de l'offre.

La forme générale du score est la suivante :

$$S_{hyb}(c, o) = \alpha S_{sem}(c, o) + \beta S_{graph}(c, o) + \gamma C_{ncf}(c, o) + \delta A_{sect}(c, o),$$

où c désigne un candidat, o une offre, S_{sem} la similarité sémantique, S_{graph} la couverture de compétences issue du graphe, C_{ncf} la compatibilité de niveau de formation et A_{sect} l'alignement sectoriel. Cette formulation traduit un choix méthodologique important : le système ne délègue pas toute la décision au LLM. Le LLM intervient pour synthétiser et expliquer, mais le classement repose sur des signaux calculables et auditables.

L'analyse de *skill gap* complète le score. Elle distingue les compétences acquises, les compétences requises et les compétences manquantes. Cette distinction permet de produire un verdict opérationnel : candidat immédiatement compatible, candidat compatible après montée en compétence, candidat à conserver en vivier ou profil hors cible. Ce verdict est plus utile qu'un simple score numérique, car il transforme la recommandation en aide à la décision.

2.3 Orchestration agentique et génération contrôlée

2.3.1 Architecture Agentic RAG et orchestration LangGraph

L'orchestration du système repose sur un workflow agentique. La requête utilisateur est d'abord analysée afin d'identifier son intention : diagnostic, recommandation candidat, skill gap, recherche référentielle, question relationnelle sur le graphe, orientation métier ou recherche générale. Le système sélectionne ensuite les outils adaptés. Cette étape de routage est essentielle : interroger pgvector, Neo4j ou les documents réglementaires ne répond pas au même besoin.

Le workflow suit une chaîne contrôlée : `analyse_request`, `plan_tools`, `execute_tools`, `build_context`, `generate_final_answer`, puis critique éventuelle de la réponse. Le noeud d'analyse identifie le use-case. Le noeud de planification sélectionne les outils. Le noeud d'exécution appelle les bases et services nécessaires. Le noeud de construction de contexte organise les résultats récupérés. Le noeud de génération produit la réponse finale avec le LLM. Le critic vérifie ensuite si la réponse paraît suffisamment fidèle au contexte ; en cas de faiblesse, le workflow peut élargir le contexte avant de régénérer la réponse.

Ce choix s'inscrit dans la logique de l'Agentic RAG : le système n'est pas un simple prompt envoyé à un modèle, mais une orchestration d'outils spécialisés autour d'un état partagé [35, 36]. Dans le présent travail, l'agent n'est pas conçu comme une entité autonome non contrôlée. Il est plutôt un routeur raisonné, limité à des outils définis, dont les sorties sont tracées.

2.3.2 Text2Cypher et rôle du LLM

Deux usages du LLM sont distingués. Le premier concerne l'interrogation du graphe en langage naturel. Pour les questions de type `graph_query` ou les recherches générales nécessitant un raisonnement relationnel, la question peut être transformée en requête Cypher par un module Text2Cypher. Le modèle retenu pour cette tâche est `neo4j/text2cypher-gemma-2-9b-it-finetuned-2024v1`. La génération de Cypher est encadrée par le schéma Neo4j : types de noeuds, propriétés et relations autorisées. Cette contrainte est indispensable, car un modèle génératif qui ne connaît pas le schéma réel peut produire des requêtes syntaxiquement plausibles mais inexécutables ou non pertinentes.

Le second usage du LLM concerne la génération de la réponse finale. Le système utilise l'API OpenRouter avec le modèle `openai/gpt-oss-20b:free`. Ce modèle ne doit pas inventer la réponse à partir de ses connaissances générales. Il reçoit un contexte construit par le workflow : résultats pgvector, lignes Neo4j, fragments documentaires et métadonnées de source. Le prompt lui demande de répondre en français, de structurer la réponse et de citer les informations utilisées.

Cette séparation des rôles est méthodologiquement importante. Text2Cypher sert à produire une requête structurée vers le graphe. Le LLM final sert à formuler une synthèse lisible. Dans les deux cas, le modèle est subordonné aux données disponibles et non l'inverse.

2.3.3 Interfaces et traçabilité

Le système prévoit trois modes d'accès : une interface Streamlit pour l'usage conversationnel, une API FastAPI pour l'intégration applicative et une CLI pour les tests de développement. Ces interfaces ne changent pas la logique de recommandation ; elles exposent le même moteur sous des formes différentes. La CLI facilite la vérification rapide des use-cases, Streamlit permet une démonstration interactive et FastAPI prépare l'intégration dans un environnement applicatif.

La traçabilité est intégrée à plusieurs niveaux. Les traces du workflow indiquent les noeuds traversés et les outils appelés. Les résultats conservent les identifiants des entités, les sources documentaires, les scores et les chemins du graphe. La réponse finale doit citer les éléments utilisés. Cette exigence est décisive dans un système d'aide à l'orientation ou au recrutement : une recommandation sans preuve peut être séduisante, mais elle n'est pas défendable.

2.4 Évaluation prévue, limites et synthèse méthodologique

2.4.1 Protocole d'évaluation prévu

L'évaluation est conçue comme une évaluation en plusieurs étapes. Le premier étage porte sur le retrieval vectoriel : le système retrouve-t-il les offres, compétences, métiers ou documents attendus dans les premiers résultats ? Les métriques retenues sont notamment Precision@K, Recall@K, MRR@K, MAP@K et NDCG@K, couramment utilisées pour les tâches de recherche d'information [27, 28].

Le deuxième étage porte sur le graphe : les relations retournées sont-elles correctes, utiles et interprétables ? Les tests doivent couvrir les requêtes métier-compétence, candidat-compétence, offre-compétence, compatibilité de niveau et recherche de chemins explicatifs. Le troisième étage porte sur le score hybride : il s'agit de comparer les classements produits par la recherche vectorielle seule, le graphe seul et la combinaison hybride. Le quatrième étage porte sur la réponse générée : fidélité au contexte, pertinence par rapport à la question, couverture des preuves, citations et utilité opérationnelle.

La méthode distingue donc clairement performance de récupération et qualité de génération. Une réponse bien rédigée ne prouve pas que le système a retrouvé les bonnes informations. Inversement, un bon retrieval ne garantit pas une bonne synthèse. Cette séparation protège l'analyse contre une erreur fréquente dans les systèmes RAG : juger le système uniquement à l'apparence de la réponse finale.

2.4.2 Limites méthodologiques et précautions d'interprétation

Plusieurs limites doivent être prises en compte dès la conception. Premièrement, les données d'offres et de candidats peuvent contenir des omissions, des doublons et des formulations ambiguës. Deuxième-

ment, l'alignement entre référentiels reste partiel : il améliore la structuration, mais ne garantit pas une équivalence parfaite entre catégories. Troisièmement, le graphe dépend de la qualité des relations extraites ou importées. Une relation manquante peut conduire à sous-estimer une compatibilité réelle. Quatrièmement, les LLM peuvent produire des formulations plausibles mais non soutenues par les données ; c'est pourquoi le contexte, les citations et le critic sont nécessaires.

Une autre limite est matérielle. L'utilisation locale ou semi-locale de modèles spécialisés, notamment pour Text2Cypher, peut être contrainte par la mémoire disponible. Cette contrainte influence les choix techniques : recours à une API pour la génération finale, chargement contrôlé du modèle Text2Cypher et possibilité de fallback vers des templates Cypher sécurisés. Ces choix ne sont pas des faiblesses méthodologiques en soi ; ils traduisent l'adaptation du système aux ressources disponibles.

2.4.3 Synthèse de l'approche méthodologique

La méthodologie proposée construit un système hybride plutôt qu'un modèle isolé. Elle part de données locales hétérogènes, les normalise, les rattache à des référentiels, les encode dans un espace vectoriel, les structure dans un graphe de connaissances, puis orchestre leur interrogation par un workflow agentique. Le rôle du LLM est strictement encadré : transformer certaines questions en requêtes graphe, puis formuler une réponse fondée sur les preuves récupérées.

Cette approche répond aux objectifs du mémoire. Elle permet de dépasser la recherche par mots-clés, d'exploiter les référentiels institutionnels, de produire des recommandations explicables et de relier chaque verdict à des compétences, des niveaux de formation et des sources identifiées. Les chapitres suivants présentent la réalisation opérationnelle de cette méthodologie, puis l'évaluation de ses performances.

Deuxième partie

Présentation des résultats

IMPLÉMENTATION DU SYSTÈME DE RECOMMANDATION

Ce chapitre présente la réalisation opérationnelle du système de recommandation hybride emploi-compétences. Il montre comment l'architecture méthodologique définie précédemment a été transformée en un dispositif fonctionnel capable de préparer les données, de représenter les profils et les offres, d'interroger une base vectorielle et un graphe de connaissances, puis de produire une réponse explicable à l'utilisateur.

3.1 Architecture générale et périmètre implémenté

Le système implémenté repose sur une chaîne complète allant des données brutes à la réponse finale. Les données d'offres d'emploi, de candidats et de référentiels sont d'abord normalisées. Elles sont ensuite transformées en représentations textuelles exploitables par un modèle d'embeddings. Ces représentations sont stockées dans une base vectorielle afin de permettre la recherche sémantique. En parallèle, les entités métiers, compétences, formations, offres et candidats sont organisées dans un graphe de connaissances pour représenter les relations professionnelles utiles au raisonnement.

La recommandation finale résulte de la combinaison de ces deux mémoires du système : la base vectorielle identifie les proximités sémantiques entre profils et offres, tandis que le graphe vérifie les relations métier, les compétences, les niveaux de formation et les rattachements sectoriels. L'orchestration agentique permet ensuite de choisir dynamiquement les sources à interroger selon la question posée.

TABLE 3.1 – Briques fonctionnelles du système implémenté

Brique	Fonction dans le système
Préparation des données	Nettoyer, harmoniser et structurer les offres, candidats et référentiels.
Représentation sémantique	Transformer les textes métiers en vecteurs comparables.
Base vectorielle	Retrouver les offres, métiers, compétences et documents proches d'une requête.
Graphe de connaissances	Représenter les relations entre candidats, offres, compétences, métiers, secteurs et niveaux de formation.
Moteur hybride	Combiner proximité sémantique, signaux graphe, niveau de formation et alignement sectoriel.
Orchestration agentique	Router chaque question vers les outils nécessaires et construire le contexte de réponse.
Interface utilisateur	Donner accès au système par chatbot, API ou interface de test.

Source : Auteur

Cette architecture traduit une décision importante : le système ne repose pas sur un LLM utilisé comme source de vérité. Le modèle génératif intervient en sortie pour formuler une réponse structurée, mais les faits utilisés proviennent des données normalisées, de la base vectorielle et du graphe.

3.2 Données exploitées et diagnostic descriptif du corpus

3.2.1 Description statistique du corpus exploité

Avant de présenter les différentes briques, il est nécessaire de caractériser le corpus sur lequel elles reposent. Le système est alimenté par des offres d'emploi, des profils candidats et des référentiels métiers et formations. Le tableau 3.2 présente les volumes exploités après normalisation.

TABLE 3.2 – Vue d'ensemble des données normalisées

Bloc de données	Nombre de lignes	Nombre de colonnes
Offres d'emploi normalisées	7 861	30
Profils candidats normalisés	1 105	20
Groupes de base MEPC	209	7
Domaines détaillés NCF	201	6

Source : Analyse descriptive des données normalisées

Ces volumes montrent que le système n'est pas construit sur un exemple isolé, mais sur un corpus réel comportant plusieurs milliers d'offres et plus d'un millier de profils. Les référentiels MEPC et NCF apportent la couche institutionnelle nécessaire pour éviter une simple comparaison de mots-clés.

3.2.2 Qualité et disponibilité des informations utiles

La qualité d'un système de recommandation dépend fortement de la disponibilité des champs utilisés pour le matching. Dans ce projet, les champs les plus importants sont le secteur, la localisation, le niveau de formation, l'expérience, les compétences et le texte utilisé pour les embeddings.




FIGURE 3.1 – Disponibilité des champs clés pour le matching

Source : Analyse descriptive des données normalisées

La figure 3.1 montre que certains champs sont bien renseignés, notamment les textes utilisés pour l’encodage et plusieurs informations structurantes. En revanche, les variables plus spécifiques, comme certaines informations de localisation, d’expérience ou de compétences détaillées, peuvent être moins complètes. Cette situation a deux conséquences. Premièrement, le système doit être capable de fonctionner avec des informations partielles. Deuxièmement, le score hybride doit rester prudent : l’absence d’une information ne doit pas être interprétée automatiquement comme une incompatibilité réelle.

La disponibilité du champ textuel utilisé pour l’encodage est particulièrement importante. Il constitue le pont entre les données structurées et la recherche vectorielle. Lorsqu’il est suffisamment riche, le modèle d’embeddings peut comparer les profils et les offres sur la base d’un contenu plus large que le seul intitulé de poste.

3.2.3 Structure sectorielle des offres

La distribution des offres par secteur permet de comprendre la composition du marché observé dans le corpus. Elle influence directement les recommandations, car les secteurs fortement représentés disposent de davantage d’exemples et de signaux textuels.




FIGURE 3.2 – Principaux secteurs représentés dans les offres

Source : Analyse descriptive des offres normalisées

Le secteur le plus représenté est la distribution, avec 546 offres, soit environ 6,95 % du corpus. Cette dominance relative n'est pas écrasante : le corpus reste distribué sur plusieurs familles d'activités. Cette diversité est favorable à un système d'orientation, car elle permet de traiter plusieurs trajectoires professionnelles. Elle introduit toutefois une contrainte : les secteurs peu représentés disposent de moins d'observations, ce qui peut réduire la stabilité des recommandations pour ces domaines.

3.2.4 Répartition géographique des opportunités

La localisation des offres est un autre facteur essentiel, car une recommandation pertinente sur le plan sémantique peut être peu utile si elle n'est pas compatible avec la mobilité du candidat. La figure 3.3 présente la répartition des offres selon la ville principale.




FIGURE 3.3 – Localisation principale des offres

Source : Analyse descriptive des offres normalisées

Yaoundé concentre 4049 offres, soit environ 51,51 % du corpus. Cette concentration géographique est un résultat important pour l'interprétation des recommandations. Le système risque naturellement de proposer davantage d'offres localisées dans les zones les plus représentées. Pour un usage opérationnel, il est donc nécessaire de tenir compte de la mobilité déclarée par le candidat, afin d'éviter qu'un bon score sémantique conduise à une recommandation peu réaliste géographiquement.

3.2.5 Niveaux de formation et expérience demandés

La compatibilité entre le niveau de formation d'un candidat et les exigences d'une offre constitue l'un des apports du système hybride. La base vectorielle peut rapprocher deux textes, mais elle ne contrôle pas toujours explicitement l'écart de niveau. C'est pourquoi le niveau NCF et l'expérience minimale sont intégrés comme signaux complémentaires.




FIGURE 3.4 – Niveaux NCF et expérience minimale demandés dans les offres

Source : Analyse descriptive des offres normalisées

La figure 3.4 montre que les offres ne se limitent pas à un seul niveau de qualification. Cette hétérogénéité justifie l'utilisation de la NCF dans le système : deux offres proches textuellement peuvent correspondre à des niveaux de formation très différents. L'expérience minimale complète cette information en donnant un signal d'accessibilité. Une offre peut être compatible par son secteur et ses compétences, mais demander un niveau d'expérience qui la rend difficilement accessible immédiatement.

3.2.6 Structure des profils candidats

Le système doit également tenir compte de la structure du vivier de candidats. Les profils ne sont pas homogènes : ils diffèrent par leur niveau de formation, leur secteur visé, leur spécialité et leur objectif professionnel.




FIGURE 3.5 – Structure des candidats selon le niveau NCF et le secteur visé

Source : Analyse descriptive des profils candidats normalisés

Cette analyse permet de rapprocher la structure de l'offre et celle de la demande. Si les candidats se concentrent dans certains secteurs alors que les offres se concentrent ailleurs, le système doit être capable de détecter les passerelles possibles : métiers voisins, compétences transférables et formations de rattrapage. C'est précisément le rôle du graphe et du module de *skill gap*.

3.2.7 Compétences fréquentes dans les offres

Les compétences déclarées dans les offres fournissent un signal central pour le matching. Elles servent à la fois à enrichir le texte encodé, à alimenter le graphe et à expliquer les écarts entre un profil et une offre.




FIGURE 3.6 – Compétences et familles de compétences les plus fréquentes dans les offres

Source : Analyse descriptive des compétences déclarées dans les offres

La figure 3.6 montre que les premiers signaux de compétences recouvrent aussi des familles sectorielles ou fonctionnelles, comme la distribution, la finance, le commerce, l'administration, l'informatique, la comptabilité et le marketing. Ce résultat doit être interprété avec prudence : il indique que les données d'offres mélangent parfois compétences, secteurs et domaines professionnels. L'implémentation doit donc distinguer progressivement les compétences techniques, les familles de métiers et les secteurs, afin d'améliorer la précision du *skill gap*.

3.2.8 Richesse textuelle des représentations utilisées

La recherche vectorielle dépend de la qualité des textes envoyés au modèle d'embeddings. Un texte trop court peut réduire le matching à un intitulé de poste. Un texte plus riche permet d'intégrer le secteur, les compétences, le niveau, l'expérience et la description.




FIGURE 3.7 – Longueur des textes utilisés pour les embeddings

Source : Analyse descriptive des textes d'encodage

La figure 3.7 compare la longueur des textes côté offres et côté candidats. Les offres disposent généralement d'un contenu plus riche, car elles incluent souvent un intitulé, un secteur, des compétences et une description. Les profils candidats peuvent être plus courts, notamment lorsque l'objectif professionnel ou les informations de spécialité sont peu détaillés. Ce déséquilibre justifie l'usage d'un moteur hybride : lorsque le texte candidat est limité, les référentiels et le graphe peuvent apporter des signaux complémentaires.

3.2.9 Équilibre macro entre offres et profils

L'analyse sectorielle conjointe des offres et des candidats permet d'observer les déséquilibres entre opportunités disponibles et profils en recherche. Cette lecture ne remplace pas le matching individuel, mais elle donne un contexte important pour interpréter les recommandations.




FIGURE 3.8 – Comparaison macro entre secteurs des offres et secteurs visés par les candidats

Source : Analyse croisée offres-candidats

La figure 3.8 montre que certains secteurs sont davantage représentés côté offres, tandis que d'autres apparaissent plus fortement côté candidats. Ce déséquilibre est une justification opérationnelle du système de recommandation : il ne s'agit pas seulement d'apparier un candidat à son secteur déclaré, mais aussi d'identifier des opportunités voisines ou des trajectoires de montée en compétences lorsqu'un secteur souhaité offre peu d'opportunités.

3.2.10 Intégration des référentiels métiers et formations

Le système s'appuie sur deux référentiels institutionnels essentiels : la nomenclature des métiers et la nomenclature des formations. Leur rôle est de donner une structure interprétable aux données d'emploi et de formation. Les groupes de base MEPC représentent l'ancrage métier, tandis que les domaines détaillés NCF représentent l'ancrage formation.




FIGURE 3.9 – Couverture des référentiels MEPC et NCF intégrés

Source : Analyse descriptive des référentiels intégrés

Le système intègre 209 groupes de base MEPC et 201 domaines détaillés NCF. Cette couverture référentielle permet d'éviter que les recommandations soient uniquement dictées par les formulations présentes dans les offres. Elle donne au système une capacité d'interprétation : un métier, une compétence ou une formation peut être replacé dans une famille plus large, ce qui facilite l'orientation et la construction de trajectoires.

3.3 Implémentation des briques de recherche et de recommandation

3.3.1 Indexation vectorielle dans pgvector

La base vectorielle constitue la mémoire sémantique du système. Elle permet de retrouver rapidement les entités proches d'une requête, même lorsque les formulations ne sont pas identiques. Cette capacité est essentielle dans le domaine emploi-compétences, où un même besoin peut être exprimé par plusieurs libellés : « analyse de données », « data analytics », « reporting » ou « exploitation statistique ».




FIGURE 3.10 – Entités indexées dans la base vectorielle

Source : Diagnostic de la base vectorielle

La base pgvector contient 34215 embeddings. Ces vecteurs couvrent plusieurs types d'entités : offres, candidats, métiers, compétences, domaines NCF et groupes MEPC. Cette diversité est importante, car le même moteur de recherche peut être utilisé pour recommander des offres, retrouver des compétences, orienter vers des métiers ou rechercher dans les référentiels.

3.3.2 Construction du graphe de connaissances Neo4j

Le graphe de connaissances constitue la mémoire relationnelle du système. Contrairement à pgvector, qui mesure une proximité dans un espace sémantique, Neo4j représente explicitement les relations : une offre appartient à un secteur, requiert un niveau, mobilise des compétences ; un candidat vise un métier, possède une formation, dispose d'un niveau et peut être rapproché de certaines compétences.




FIGURE 3.11 – Répartition des nœuds Neo4j par label

Source : Diagnostic du graphe de connaissances

L'instance locale du graphe contient 43 008 nœuds. Ce volume montre que le graphe est effectivement alimenté. Il ne doit toutefois pas être confondu avec une mesure de qualité : un graphe volumineux peut rester peu utile si ses relations sont incomplètes ou mal typées. Dans ce projet, le graphe est surtout utilisé pour enrichir les résultats vectoriels, calculer des signaux de compatibilité et appuyer les réponses relationnelles.

Le comptage global des relations n'est pas retenu dans ce chapitre, car l'instance locale a retourné une erreur interne lors de certaines requêtes de comptage. Cette limite est signalée explicitement afin d'éviter d'annoncer un chiffre non stabilisé. Elle confirme aussi qu'un système GraphRAG dépend de la qualité logique et technique de son graphe.

3.3.3 Moteur hybride de recommandation

Le moteur de recommandation combine les résultats de pgvector et les informations du graphe. La recherche vectorielle agit comme un premier filtre : elle identifie un ensemble d'offres proches du profil candidat. Le graphe intervient ensuite pour enrichir ces offres par des informations métier : niveau de formation, secteur, compétences acquises, compétences manquantes et cohérence du parcours.

Le score final n'est donc pas une simple similarité textuelle. Il combine quatre dimensions :

- la proximité sémantique entre le profil et l'offre ;
- la couverture des compétences requises ;
- la compatibilité du niveau de formation ;
- l'alignement sectoriel ou métier.

Cette combinaison permet de produire une recommandation plus interprétable. Une offre proche textuellement peut être rétrogradée si le niveau requis est trop éloigné ou si plusieurs compétences essentielles

manquent. À l'inverse, une offre moins proche lexicalement peut être retenue si elle correspond mieux au parcours, au secteur ou aux compétences du candidat.

3.3.4 Analyse du *skill gap* et montée en compétences

L'analyse du *skill gap* constitue l'une des sorties importantes du système. Elle consiste à comparer les compétences exigées par une offre aux compétences observées ou déduites pour un candidat. Le résultat n'est pas seulement un score ; il devient une explication opérationnelle.

Trois situations peuvent être distinguées :

- **profil prêt à postuler** : les compétences et le niveau sont globalement compatibles ;
- **profil à accompagner** : l'offre est pertinente, mais certaines compétences doivent être renforcées ;
- **profil à développer en vivier** : le profil est intéressant, mais l'écart actuel reste trop important pour une candidature immédiate.

Cette logique transforme le système en outil d'orientation. Il ne répond pas seulement à la question « quelle offre recommander ? » ; il répond aussi à la question « que manque-t-il pour rendre cette candidature plus crédible ? ».

3.4 Orchestration, interfaces et validation d'intégration

3.4.1 Orchestration agentique et génération contrôlée

L'orchestration agentique permet au système de choisir les sources à interroger selon la demande de l'utilisateur. Une question sur un candidat active le moteur de recommandation. Une question sur une relation métier-compétence mobilise le graphe. Une question documentaire active la recherche dans les fragments référentiels. Une question générale peut mobiliser à la fois la base vectorielle et Neo4j.

La réponse finale est générée par un modèle de langage configuré via OpenRouter. Le modèle utilisé est celui déclaré dans l'environnement du système : `openai/gpt-oss-20b:free`. Son rôle est de formuler la réponse en français, d'organiser les informations et de citer les éléments du contexte. Il ne remplace pas les bases de données : il reçoit un contexte déjà construit à partir des résultats de recherche.

Le système intègre également un mécanisme de critique de réponse. Si la réponse semble insuffisamment fondée sur le contexte, l'agent peut élargir la recherche et reconstruire une réponse. Cette boucle limite le risque de réponse plausible mais non soutenue par les données.

3.4.2 Interfaces d'utilisation

Le système est accessible par plusieurs interfaces. L'interface conversationnelle permet à un utilisateur de poser une question en langage naturel et d'obtenir une réponse structurée. Elle peut afficher les traces du workflow afin de montrer quelles briques ont été mobilisées. L'API permet une intégration dans une application externe ou un site web. Une interface de test permet enfin de vérifier rapidement le comportement du moteur avec des requêtes contrôlées.

Ces interfaces reposent sur le même moteur. Elles ne changent pas la logique de recommandation ; elles modifient seulement le mode d'accès. Cette séparation est importante pour la maintenance : le système peut être démontré localement, testé techniquement ou intégré à une plateforme sans réécrire le moteur.

3.4.3 Diagnostic d'intégration

Un diagnostic local permet de vérifier que les principales briques sont raccordées. Les résultats disponibles indiquent que la base vectorielle contient 34 215 embeddings et que le graphe contient 43 008 nœuds. Le modèle d'embeddings est configuré et le backend génératif OpenRouter utilise le modèle `openai/gpt-oss-20b:free`.

TABLE 3.3 – Synthèse du diagnostic d'intégration

Composant	État observé
Données d'offres	7 861 offres normalisées.
Données candidats	1 105 profils candidats normalisés.
Référentiels	209 groupes de base MEPC et 201 domaines détaillés NCF.
Base vectorielle	34 215 embeddings indexés.
Graphe de connaissances	43 008 nœuds Neo4j.
Génération finale	Modèle OpenRouter <code>openai/gpt-oss-20b:free</code> .

Source : Diagnostic local et analyses descriptives

Ce diagnostic ne constitue pas une évaluation de performance. Il confirme seulement que les briques principales sont alimentées et interconnectées. La qualité du classement et l'impact du graphe sur les recommandations sont analysés dans le chapitre suivant.

3.4.4 Synthèse du chapitre

L'implémentation réalisée aboutit à un système complet combinant données normalisées, embeddings, base vectorielle, graphe de connaissances, moteur hybride et orchestration agentique. Les analyses statistiques montrent que le corpus contient 7 861 offres, 1 105 candidats, 209 groupes de base MEPC, 201 domaines détaillés NCF, 34 215 embeddings et 43 008 nœuds Neo4j.

Ces chiffres ne suffisent pas à prouver la qualité du système, mais ils montrent que la chaîne est effectivement alimentée. Les analyses sectorielles, géographiques, de niveaux de formation et de compétences permettent de mieux comprendre les contraintes du matching. Elles justifient l'architecture hybride : la recherche vectorielle est utile pour retrouver des proximités sémantiques, mais le graphe est nécessaire pour structurer les relations, expliquer les écarts et soutenir la montée en compétences.

Le chapitre suivant évalue donc la performance du système, en particulier l'apport du graphe par rapport à une approche fondée uniquement sur pgvector.

ÉVALUATION DE LA PERFORMANCE DU SYSTÈME

4.1 Objectif et logique générale de l'évaluation

Ce chapitre évalue empiriquement le système implémenté au chapitre précédent. L'objectif n'est pas seulement de produire des scores globaux, mais de répondre à une question centrale du mémoire : l'ajout d'un graphe de connaissances Neo4j apporte-t-il une amélioration mesurable par rapport à une recherche vectorielle fondée uniquement sur pgvector ? Cette question est décisive, car le graphe ajoute une complexité technique réelle : modélisation des nœuds et relations, chargement Neo4j, requêtes Cypher, enrichissement des résultats, maintenance d'une base supplémentaire. Son intérêt doit donc être justifié par un gain observable en qualité de classement, en explicabilité ou en contrôle métier.

L'évaluation a été conduite en trois niveaux. Le premier niveau porte sur le modèle d'embeddings, c'est-à-dire la capacité du SentenceTransformer fine-tuné à retrouver les paires offre-profil pertinentes dans un corpus de test. Le deuxième niveau porte sur l'ablation du moteur de recommandation : une configuration *pgvector seul* est comparée à une configuration *pgvector + graphe*. Le troisième niveau porte sur les limites opérationnelles observées, notamment la stabilité de la connexion Neo4j et la portée réelle des métriques utilisées.

Les résultats présentés dans ce chapitre proviennent de deux artefacts exécutables : le benchmark d'embeddings sauvegardé dans `outputs/evaluation/embedding_benchmark.json` et le notebook d'ablation `notebooks/10_Evaluation_pgvector_vs_graph.ipynb`. Les sorties de ce notebook sont exportées dans `outputs/evaluation/pgvector_vs_graph` et les figures dans `rapport/figures/generated/evaluation`. Cette traçabilité est importante : les nombres présentés ici ne sont pas des valeurs théoriques, mais des sorties produites par le pipeline local.

4.2 Données et protocole expérimental

Le système dispose de 7 861 offres normalisées et de 1 105 profils candidats. Le benchmark d'embeddings utilise le jeu de test issu de la construction des paires contrastives offre-profil, soit 473 requêtes de test. Chaque requête correspond à une description structurée d'offre ou de profil, et le corpus contient les textes enrichis utilisés pour l'apprentissage contrastif. Les métriques calculées sont celles de la recherche d'information : Precision@K, Recall@K, NDCG@K et MRR@K.

Pour l'ablation *pgvector* contre *pgvector + graphe*, le protocole est différent. Un échantillon de 60 candidats est tiré aléatoirement avec la graine 42. Pour chaque candidat, pgvector retourne un pool initial de 30 offres candidates. Deux classements sont alors comparés :

- **pgvector seul** : l'ordre des offres est conservé tel qu'il est retourné par la recherche sémantique et lexicale dans PostgreSQL/pgvector ;
- **pgvector + graphe** : le même pool initial est enrichi par Neo4j, puis rerangé par le score hybride combinant similarité sémantique, compatibilité de compétences, compatibilité de niveau NCF et alignement sectoriel.

Cette comparaison est volontairement réalisée sans génération LLM. Le modèle génératif OpenRouter intervient dans le chatbot pour formuler la réponse finale, mais il n'est pas mobilisé dans l'ablation. Cette séparation évite de confondre deux phénomènes : la qualité du classement des offres et la qualité rédactionnelle de la réponse.

La pertinence utilisée pour calculer les métriques d'ablation est un proxy construit à partir des méta-données normalisées : chevauchement lexical entre le profil et l'offre, proximité sectorielle et compatibilité de niveau NCF. Cette approximation est acceptable pour comparer deux variantes internes sur le même échantillon, mais elle ne remplace pas une annotation humaine. Les résultats doivent donc être interprétés comme une mesure comparative de l'effet du graphe, non comme une mesure définitive de satisfaction utilisateur.

4.3 Évaluation du modèle d'embeddings

Le premier résultat concerne l'intérêt du fine-tuning du SentenceTransformer. Le tableau 4.1 présente les performances du modèle fine-tuné par rapport à plusieurs modèles généralistes ou multilingues. Le modèle spécialisé domine nettement les alternatives sur les métriques de retrieval.

TABLE 4.1 – Benchmark des modèles d'embeddings sur 473 requêtes de test

Modèle	NDCG@10	MRR@10	Recall@10	Latence ms/phrased
ST fine-tuné emploi-compétences	0.6336	0.5653	0.8520	32.77
MiniLM-L6 généraliste	0.1980	0.1603	0.3192	26.03
DistilUSE multilingue	0.1773	0.1434	0.2896	57.96
mE5-base multilingue	0.1505	0.1274	0.2262	295.76
ML-MiniLM-L12	0.1115	0.0922	0.1734	42.82
CamemBERT sentence	0.0904	0.0771	0.1332	144.15

Le modèle fine-tuné atteint un Recall@10 de 0.8520, contre 0.3192 pour MiniLM-L6 généraliste. L'écart est substantiel : le modèle spécialisé retrouve beaucoup plus souvent le document pertinent dans les dix premiers résultats. Le NDCG@10 passe également de 0.1980 à 0.6336, ce qui indique non seulement une meilleure récupération, mais aussi un meilleur ordre des résultats pertinents. La latence moyenne du modèle spécialisé reste contenue à 32.77 ms par phrase, ce qui est compatible avec une indexation ou une recherche interactive locale.




FIGURE 4.1 – Comparaison des modèles d'embeddings sur le jeu de test

Ce résultat valide le choix d'un encodeur adapté au domaine. Il montre aussi pourquoi une base vectorielle généraliste ne suffit pas : le vocabulaire emploi-compétences contient des formulations longues, des intitulés hybrides, des niveaux de formation et des compétences implicites. Le fine-tuning contrastif rapproche ces formulations dans l'espace vectoriel et améliore directement le retrieval.

4.4 Ablation pgvector seul contre pgvector + graphe

Le coeur de l'évaluation concerne l'apport de Neo4j. Le notebook d'ablation a demandé l'évaluation de 60 candidats. Sur cet échantillon, 55 requêtes ont été évaluées avec succès ; 5 requêtes ont échoué en raison d'une erreur interne Neo4j de type `CursorException` sur certaines relations. Cette information doit être conservée dans l'analyse : elle montre que la qualité d'un système GraphRAG ne dépend pas seulement du raisonnement algorithmique, mais aussi de l'intégrité physique et logique de la base graphe.

TABLE 4.2 – Comparaison retrieval : pgvector seul versus pgvector + graphe

Configuration	Precision@5	Recall@10	NDCG@10	MRR@10	HitRate@10
pgvector seul	0.2509	0.4599	0.3889	0.5602	0.9273
pgvector + graphe	0.3091	0.5557	0.4681	0.4647	0.7818
Différence	+0.0582	+0.0958	+0.0792	-0.0955	-0.1455

Les résultats sont instructifs parce qu'ils ne sont pas uniformément favorables au graphe. L'ajout de Neo4j améliore Precision@5, Recall@10 et NDCG@10. Autrement dit, lorsque l'on considère les cinq ou dix premiers résultats, l'enrichissement graphe permet de remonter davantage d'offres jugées pertinentes par le proxy métier. Le Recall@10 progresse de 0.4599 à 0.5557, soit un gain de 0.0958. Le NDCG@10 augmente également de 0.3889 à 0.4681, ce qui indique une meilleure organisation globale du top 10.

En revanche, le MRR@10 diminue de 0.5602 à 0.4647 et la Precision@1 passe de 0.4182 à 0.3636. Cela signifie que le graphe ne place pas toujours la première offre pertinente aussi haut que le classement

vectorel initial. Ce résultat est important : le graphe améliore la couverture et la cohérence globale du classement, mais il peut dégrader le tout premier rang lorsque ses signaux structurels sont imparfaits, incomplets ou trop fortement pondérés.




FIGURE 4.2 – Effet de l'enrichissement graphe sur les métriques de retrieval

La figure 4.2 confirme cette lecture. La configuration *pgvector + graphe* est supérieure sur les métriques orientées couverture, mais inférieure sur les métriques sensibles au premier rang. Dans un système de recommandation destiné au recrutement, cette distinction est opérationnellement importante. Si l'interface n'affiche qu'une seule offre, *pgvector* seul peut être plus robuste. Si l'interface affiche une liste courte accompagnée d'explications, le graphe devient plus utile car il enrichit le top 5 ou le top 10 avec des critères métier explicables.

4.5 Analyse du reranking par le graphe

Le reranking graphe déplace les offres dans le classement initial. Une offre qui était par exemple au rang 8 dans *pgvector* peut être remontée au rang 3 si elle présente une meilleure compatibilité NCF, un meilleur alignement sectoriel ou un meilleur score de compétences. Inversement, une offre très proche sémantiquement peut être rétrogradée si le niveau requis ou les signaux métier sont moins compatibles.




FIGURE 4.3 – Distribution des déplacements de rang après reranking par le graphe

Cette redistribution a deux effets. Le premier est positif : le système ne se limite plus à une proximité textuelle. Il peut corriger des cas où une offre ressemble lexicalement au profil mais ne correspond pas au niveau de formation ou au secteur recherché. Le second est plus problématique : si les relations du graphe sont incomplètes, le score structurel peut pénaliser de bonnes offres ou favoriser des offres seulement parce que leurs métadonnées sont mieux renseignées. Le graphe ajoute donc de l'information, mais il ajoute aussi une source d'erreur potentielle.

Ce résultat appelle une conclusion nuancée. Le graphe n'est pas une garantie automatique d'amélioration. Il améliore le système si les relations sont correctes, si les poids du score hybride sont bien calibrés et si l'objectif est de produire une liste explicable plutôt qu'un unique meilleur résultat. Dans le système actuel, l'apport est visible sur Recall@10 et NDCG@10, mais il reste insuffisamment stabilisé sur le rang 1.

4.6 Performance opérationnelle et stabilité

L'évaluation d'ablation a pris 38.7 secondes pour le cœur retrieval-reranking, hors coût complet de démarrage du notebook et de chargement du modèle. Le notebook exécuté par `nbconvert` a produit les résultats en environ 85 secondes en incluant le chargement du modèle SentenceTransformer, les connexions aux bases et l'export des figures. Cette durée reste acceptable pour une évaluation hors ligne, mais elle ne représente pas encore une latence utilisateur finale, car le chatbot complet ajoute la génération LLM via OpenRouter.

Le point critique est la stabilité Neo4j. Cinq candidats sur soixante ont échoué à cause d'une erreur interne `Neo.DatabaseError.Statement.ExecutionFailed` liée au page cache et à des relations corrompues. Le système a donc évalué 55 requêtes valides. Cette fragilité doit être traitée avant toute démonstration en production : il faut reconstruire ou vérifier la base Neo4j, contrôler les imports, et ajouter des tests d'intégrité sur les relations candidat-offre-compétence.

4.7 Interprétation par rapport aux hypothèses

Les résultats soutiennent partiellement l'hypothèse selon laquelle l'intégration d'un graphe améliore la recommandation. L'hypothèse est confirmée pour les métriques de couverture du top 10 : Recall@10 et NDCG@10 progressent lorsque Neo4j est utilisé pour enrichir et reranger les offres. En revanche, elle n'est pas confirmée pour le premier rang : Precision@1, MRR@10 et HitRate@10 diminuent. Le graphe apporte donc un gain structurel, mais ce gain n'est pas encore parfaitement aligné avec l'optimisation du meilleur résultat immédiat.

Sur le plan méthodologique, cette conclusion est plus utile qu'une affirmation générale. Elle montre où le graphe apporte de la valeur : explicabilité, couverture, prise en compte des niveaux et secteurs. Elle montre aussi où le système doit être amélioré : calibration des poids, complétude des relations, robustesse de Neo4j, et validation par annotation humaine.

4.8 Lecture des sorties graphiques de performance

Les figures du chapitre convergent vers une lecture prudente. La première sortie graphique, consacrée au benchmark d'embeddings, montre que le fine-tuning apporte le gain le plus net de toute l'évaluation : le modèle spécialisé domine les modèles généralistes sur NDCG@10, MRR@10 et Recall@10. Ce résultat indique que l'adaptation au vocabulaire emploi-compétences améliore directement la capacité du système à retrouver les correspondances pertinentes.

La deuxième sortie graphique, issue de l'ablation pgvector contre pgvector + graphe, confirme un effet plus nuancé. Le graphe améliore les métriques de couverture du top 5 et du top 10, mais il ne sécurise pas le premier rang. Cette différence est centrale pour l'interprétation métier : le graphe est utile lorsque l'utilisateur consulte une liste courte d'offres accompagnée d'explications, mais il reste insuffisamment calibré si l'objectif est de produire une unique meilleure offre.

La troisième sortie graphique, centrée sur les déplacements de rang, explique ce résultat. Neo4j ne se contente pas d'ajouter un score marginal ; il réordonne réellement le pool initial retourné par pgvector. Cette intervention peut corriger des proximités purement lexicales, mais elle peut aussi rétrograder une bonne offre lorsque les relations de compétences, de niveau ou de secteur sont incomplètes. Le gain du graphe dépend donc de la qualité des relations et du réglage des poids du score hybride.




FIGURE 4.4 – Stabilité opérationnelle observée pendant l'évaluation d'ablation

La figure 4.4 complète cette lecture par la stabilité d'exécution. Sur 60 requêtes demandées, 55 ont été évaluées et 5 ont échoué à cause de Neo4j. Le taux d'erreur observé atteint donc 8.3%. Ce résultat n'annule pas les gains mesurés sur Recall@10 et NDCG@10, mais il empêche de conclure à une robustesse de production. Dans l'état actuel, la performance algorithmique du graphe existe, mais elle est conditionnée par un assainissement de la base Neo4j.

Enfin, aucune figure de calibration du critic n'est interprétée dans ce chapitre, car le dépôt ne contient pas encore de jeu réel `critic_calibration_cases.csv`. Le fichier disponible est seulement un gabarit, avec des lignes fictives. L'utiliser pour produire des courbes RAGAS donnerait des graphiques visibles, mais méthodologiquement faux. La calibration du critic doit donc rester une étape d'évaluation complémentaire, à exécuter uniquement après constitution d'un échantillon réel de questions, réponses, contextes récupérés et labels RAGAS ou humains.

4.9 Limites de l'évaluation

La principale limite est l'absence d'un jeu d'annotations humaines indiquant quelles offres sont réellement pertinentes pour chaque candidat. Le proxy utilisé combine les métadonnées disponibles, mais il ne capture pas toutes les dimensions du recrutement : motivation, expérience qualitative, disponibilité, préférences salariales, soft skills ou contraintes géographiques fines. Les métriques doivent donc être lues comme des indicateurs comparatifs internes.

La deuxième limite concerne le graphe lui-même. Les erreurs Neo4j observées indiquent que l'instance locale doit être auditée. Une base graphe partiellement corrompue ou incomplète peut biaiser l'évaluation du système hybride. Avant une évaluation finale à plus grande échelle, il faudra reconstruire la base, vérifier les nombres de nœuds et de relations, puis contrôler des chemins représentatifs : candidat-compétence, offre-compétence, offre-niveau, candidat-formation et métier-compétence.

La troisième limite concerne la génération LLM. Ce chapitre a volontairement isolé le retrieval et le reranking. La fidélité des réponses générées, la qualité des citations, la robustesse du critic et l'expérience

utilisateur nécessitent une évaluation complémentaire, idéalement avec un protocole d'annotation humaine ou un juge LLM contrôlé par des critères explicites.

4.10 Synthèse du chapitre

L'évaluation confirme d'abord l'intérêt du SentenceTransformer fine-tuné : il dépasse nettement les modèles généralistes sur le jeu de test emploi-compétences. Elle montre ensuite que Neo4j apporte un gain réel sur les métriques de couverture et d'ordre global du top 10, mais qu'il dégrade le tout premier rang dans l'état actuel du système. La conclusion n'est donc pas que le graphe est automatiquement supérieur à pgvector. La conclusion correcte est que le graphe enrichit le classement lorsqu'on cherche une liste explicable et structurée, mais qu'il exige une meilleure qualité de relations et une calibration plus fine pour optimiser le top 1.

Ces résultats orientent directement les recommandations du chapitre suivant : renforcer l'intégrité Neo4j, construire un jeu d'évaluation annoté, ajuster les poids du score hybride, et distinguer dans l'interface les cas où le système privilégie la proximité sémantique immédiate et ceux où il privilégie la compatibilité métier structurée.

DISCUSSION ET RECOMMANDATIONS

Conclusion générale

Bibliographie

- [1] Francesco RICCI et al., éd. *Recommender Systems Handbook*. Springer, 2011. DOI : [10.1007/978-0-387-85820-3](#).
- [2] PGVECTOR CONTRIBUTORS. *pgvector : Open-source Vector Similarity Search for Postgres*. 2024. URL : <https://github.com/pgvector/pgvector> (visit   le 04/05/2026).
- [3] Aidan HOGAN et al. "Knowledge Graphs". In : *ACM Computing Surveys* 54.4 (2021), p. 1-37. DOI : [10.1145/3447772](#).
- [4] Patrick LEWIS et al. "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks". In : *Advances in Neural Information Processing Systems* 33 (2020), p. 9459-9474. URL : <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [5] Dale T. MORTENSEN et Christopher A. PISSARIDES. "Job Creation and Job Destruction in the Theory of Unemployment". In : *The Review of Economic Studies* 61.3 (1994), p. 397-415. DOI : [10.2307/2297896](#).
- [6] Christopher A. PISSARIDES. *Equilibrium Unemployment Theory*. 2     d. Cambridge, MA : MIT Press, 2000.
- [7] George A. AKERLOF. "The Market for "Lemons" : Quality Uncertainty and the Market Mechanism". In : *The Quarterly Journal of Economics* 84.3 (1970), p. 488-500. DOI : [10.2307/1879431](#).
- [8] Michael SPENCE. "Job Market Signaling". In : *The Quarterly Journal of Economics* 87.3 (1973), p. 355-374. DOI : [10.2307/1882010](#).
- [9] Gary S. BECKER. *Human Capital : A Theoretical and Empirical Analysis, with Special Reference to Education*. New York : Columbia University Press, 1964.
- [10] David H. AUTOR. "The "Task Approach" to Labor Markets : An Overview". In : *Journal for Labour Market Research* 46.3 (2013), p. 185-199. DOI : [10.1007/s12651-013-0128-z](#).
- [11] Gediminas ADOMAVICIUS et Alexander TUZHILIN. "Toward the Next Generation of Recommender Systems : A Survey of the State-of-the-Art and Possible Extensions". In : *IEEE Transactions on Knowledge and Data Engineering* 17.6 (2005), p. 734-749. DOI : [10.1109/TKDE.2005.99](#).
- [12] Michael J. PAZZANI et Daniel BILLSUS. "Content-Based Recommendation Systems". In : *The Adaptive Web* (2007), p. 325-341. DOI : [10.1007/978-3-540-72079-9_10](#).
- [13] Yehuda KOREN, Robert BELL et Chris VOLINSKY. "Matrix Factorization Techniques for Recommender Systems". In : *Computer* 42.8 (2009), p. 30-37. DOI : [10.1109/MC.2009.263](#).

- [14] Xiangnan HE et al. “Neural Collaborative Filtering”. In : *Proceedings of the 26th International Conference on World Wide Web*. 2017, p. 173-182.
- [15] Robin BURKE. “Hybrid Recommender Systems : Survey and Experiments”. In : *User Modeling and User-Adapted Interaction* 12 (2002), p. 331-370. DOI : [10.1023/A:1021240730564](https://doi.org/10.1023/A:1021240730564).
- [16] Chen YANG et al. “Modeling Two-way Selection Preference for Person-Job Fit”. In : *Proceedings of the 16th ACM Conference on Recommender Systems*. 2022, p. 102-112.
- [17] A. T. WASI. “HRGraph : Leveraging LLMs for HR Data Knowledge Graphs with Information Propagation-based Job Recommendation”. In : *Proceedings of the 1st Workshop on Knowledge Graphs and Large Language Models*. 2024, p. 56-62.
- [18] B. YANG et Z. SHEN. “Knowledge Graph Construction and Talent Competency Prediction for Human Resource Management”. In : *Alexandria Engineering Journal* 121 (2025), p. 223-235.
- [19] Ashish VASWANI et al. “Attention Is All You Need”. In : *Advances in Neural Information Processing Systems*. 2017, p. 5998-6008.
- [20] Tomas MIKOLOV et al. “Distributed Representations of Words and Phrases and their Compositionality”. In : *Advances in Neural Information Processing Systems*. T. 26. 2013. URL : <https://proceedings.neurips.cc/paper/5021-distributed-representations-of-words-and-phrases-and-their-compositionality>.
- [21] Dzmitry BAHDANAU, Kyunghyun CHO et Yoshua BENGIO. “Neural Machine Translation by Jointly Learning to Align and Translate”. In : *International Conference on Learning Representations*. 2015. URL : <https://arxiv.org/abs/1409.0473>.
- [22] Jacob DEVLIN et al. “BERT : Pre-training of Deep Bidirectional Transformers for Language Understanding”. In : *Proceedings of NAACL-HLT*. 2019, p. 4171-4186. URL : <https://aclanthology.org/N19-1423/>.
- [23] Nils REIMERS et Iryna GUREVYCH. “Sentence-BERT : Sentence Embeddings using Siamese BERT-Networks”. In : *Proceedings of EMNLP-IJCNLP*. 2019, p. 3982-3992. URL : <https://aclanthology.org/D19-1410/>.
- [24] Tom B. BROWN et al. “Language Models are Few-Shot Learners”. In : *Advances in Neural Information Processing Systems* 33 (2020), p. 1877-1901. URL : <https://proceedings.neurips.cc/paper/2020/hash/1457c0d6bfc4967418bfb8ac142f64a-Abstract.html>.
- [25] Colin RAFFEL et al. “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer”. In : *Journal of Machine Learning Research* 21.140 (2020), p. 1-67. URL : <https://www.jmlr.org/papers/v21/20-074.html>.
- [26] Long OUYANG et al. “Training Language Models to Follow Instructions with Human Feedback”. In : *Advances in Neural Information Processing Systems* 35 (2022), p. 27730-27744. URL : https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html.

- [27] Nandan THAKUR et al. “BEIR : A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models”. In : *Advances in Neural Information Processing Systems*. T. 34. 2021, p. 28974-28989. URL : <https://arxiv.org/abs/2104.08663>.
- [28] Niklas MUENNIGHOFF et al. “MTEB : Massive Text Embedding Benchmark”. In : *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*. 2023, p. 2014-2037. URL : <https://aclanthology.org/2023.eacl-main.148/>.
- [29] Yu A. MALKOV et D. A. YASHUNIN. “Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs”. In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.4 (2020), p. 824-836. DOI : [10.1109/TPAMI.2018.2889473](https://doi.org/10.1109/TPAMI.2018.2889473).
- [30] Jeff JOHNSON, Matthijs DOUZE et Hervé JÉGOU. “Billion-scale Similarity Search with GPUs”. In : *IEEE Transactions on Big Data* 7.3 (2019), p. 535-547. DOI : [10.1109/TBDATA.2019.2921572](https://doi.org/10.1109/TBDATA.2019.2921572).
- [31] Thomas N. KIPF et Max WELLING. “Semi-Supervised Classification with Graph Convolutional Networks”. In : *International Conference on Learning Representations*. 2017.
- [32] Petar VELIČKOVIĆ et al. “Graph Attention Networks”. In : *International Conference on Learning Representations*. 2018.
- [33] Xiangnan HE et al. “LightGCN : Simplifying and Powering Graph Convolution Network for Recommendation”. In : *Proceedings of SIGIR*. 2020, p. 639-648.
- [34] Yunfan GAO et al. *Retrieval-Augmented Generation for Large Language Models : A Survey*. 2023. arXiv : [2312.10997](https://arxiv.org/abs/2312.10997) [cs.CL]. URL : <https://arxiv.org/abs/2312.10997>.
- [35] Shunyu YAO et al. “ReAct : Synergizing Reasoning and Acting in Language Models”. In : *International Conference on Learning Representations*. 2023. URL : https://openreview.net/forum?id=WE_vluYUL-X.
- [36] Akari ASAI et al. “Self-RAG : Learning to Retrieve, Generate, and Critique through Self-Reflection”. In : *International Conference on Learning Representations*. 2024. URL : <https://openreview.net/forum?id=hSyW5go0v8>.
- [37] Shahul ES et al. “RAGAS : Automated Evaluation of Retrieval Augmented Generation”. In : *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics : System Demonstrations*. 2024, p. 150-158. URL : <https://aclanthology.org/2024.eacl-demo.16/>.
- [38] Yang LIU et al. “G-Eval : NLG Evaluation using GPT-4 with Better Human Alignment”. In : *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. 2023, p. 2511-2522. URL : <https://aclanthology.org/2023.emnlp-main.153/>.
- [39] William L. HAMILTON. *Graph Representation Learning*. Morgan & Claypool Publishers, 2020. DOI : [10.2200/S01045ED1V01Y202009AIM046](https://doi.org/10.2200/S01045ED1V01Y202009AIM046).

ANNEXES

TABLE A.1 – Labels de nœuds et relations structurantes du graphe

Bloc	Labels de nœuds	Relations principales et interprétation
Données d'emploi	<code>OffreEmploi</code> , <code>Employeur</code> , <code>Localisation</code>	<code>Candidat</code> , <code>Secteur</code> , <code>PUBLIEE_PAR</code> relie une offre à son employeur ; <code>DANS_SECTEUR</code> la rattache à un secteur ; <code>LOCALISEE_A</code> indique la ville ou zone d'exercice ; <code>A_NIVEAU</code> relie le candidat à son niveau de formation.
Compétences et métiers	<code>Compétence</code> , <code>GroupeCompétences</code> , <code>GroupeISCO</code>	<code>Métier</code> , <code>NECESSITE</code> relie un métier aux compétences attendues ; <code>PARTIE_DE</code> rattache une compétence à son groupe ; <code>CLASSIFIE_DANS</code> relie un métier à un groupe ISCO ; <code>PLUS_LARGE_QUE</code> représente les relations hiérarchiques entre compétences.
Référentiel MEPC	<code>GrandGroupeMEPC</code> , <code>SousGroupeMEPC</code> , <code>GroupeBaseMEPC</code>	<code>CONTIENT</code> représente la hiérarchie interne de la nomenclature ; <code>ALIGNE_AVEC</code> rapproche les groupes MEPC des groupes ISCO ; <code>CORRESPOND_MEPC</code> rattache un métier ESCO à un groupe de base MEPC.
Référentiel NCF	<code>NiveauFormationNCF</code> , <code>GrandDomaineNCF</code> , <code>DomaineSpécialiséNCF</code> , <code>DomaineDétailléNCF</code>	<code>CONTIENT</code> représente la hiérarchie formation ; <code>REQUIERT_NIVEAU_NCF</code> relie une offre au niveau demandé ; <code>A_FORMATION</code> rattache un candidat à son domaine de formation ; <code>PREPARE_POUR</code> relie un domaine de formation aux métiers visés.
Recommandation	<code>OffreEmploi</code> , <code>Compétence</code> , <code>DomaineDétailléNCF</code>	<code>Candidat</code> , <code>Métier</code> , Les chemins candidat-compétence-offre permettent d'identifier les compétences acquises et manquantes ; les chemins offre-niveau-formation servent à contrôler la compatibilité de qualification ; les chemins formation-métier soutiennent la proposition de montée en compétences.

Source : Auteur

TABLE A.2 – Volume d'entités indexées dans la base vectorielle pgvector

Type d'entité	Nombre	Source principale
OFFRE_EMPLOI	15 722	Scraping KmerAI
COMPETENCE	13 939	Référentiel ESCO v1.1
METIER	3 039	Référentiel ESCO v1.1
CANDIDAT	1 105	Base locale de profils demandeurs
GROUPE_BASE_MEPC	209	INS Cameroun - MEPC 2013
DOMAINE_DETAILLE_NCF	201	INS Cameroun - NCF 2017
Total	34 215	

Source : Auteur

Table des matières

Dédicace	i
Remerciements	ii
Liste des sigles et abréviations	v
Liste des tableaux	vi
Liste des figures	vii
Avant-propos	viii
Résumé	ix
Abstract	x
Introduction générale	1
I Cadre théorique et conceptuel	5
1 Fondements théoriques et revue de la littérature sur l'IA générative et les systèmes de recommandation	6
1.1 Concepts clés mobilisés dans le mémoire	6
1.2 Fondements économiques et problématique d'appariement	8
1.2.1 Marché du travail, recherche d'emploi et frictions	8
1.2.2 Capital humain, tâches et inadéquation des compétences	8
1.3 Systèmes de recommandation et person-job fit	8
1.3.1 Approches par contenu, collaboratives et hybrides	9
1.3.2 Spécificité du person-job fit	9
1.4 IA générative et connaissances	10
1.4.1 Grands modèles de langage et génération contrôlée	10
1.4.2 Embeddings, recherche sémantique et bases vectorielles	11
1.4.3 Graphes de connaissances et recommandation relationnelle	11
1.5 RAG, GraphRAG et orchestration agentique	11
1.5.1 De la RAG au GraphRAG	11
1.5.2 Agentic RAG, critic et traçabilité	12

1.6	Évaluation, acquis de la littérature et positionnement du mémoire	13
1.6.1	Évaluer la performance et la factualité	13
1.6.2	Acquis, manques et contribution du mémoire	14
2	Source de données et Approche méthodologique	16
2.1	Cadre méthodologique et sources de données	16
2.1.1	Positionnement méthodologique	16
2.1.2	Sources de données et leur rôle dans le système	19
2.1.3	Préparation et normalisation des données	20
2.1.4	Alignement des référentiels métiers et formations	21
2.2	Modélisation sémantique et structuration des connaissances	21
2.2.1	Choix du modèle d’embeddings et fine-tuning	21
2.2.2	Indexation vectorielle dans PostgreSQL et pgvector	22
2.2.3	Construction du graphe de connaissances Neo4j	22
2.2.4	Score hybride et logique de skill gap	22
2.3	Orchestration agentique et génération contrôlée	23
2.3.1	Architecture Agentic RAG et orchestration LangGraph	23
2.3.2	Text2Cypher et rôle du LLM	23
2.3.3	Interfaces et traçabilité	24
2.4	Évaluation prévue, limites et synthèse méthodologique	24
2.4.1	Protocole d’évaluation prévu	24
2.4.2	Limites méthodologiques et précautions d’interprétation	24
2.4.3	Synthèse de l’approche méthodologique	25
II	Présentation des résultats	26
3	Implémentation du système de recommandation	27
3.1	Architecture générale et périmètre implémenté	27
3.2	Données exploitées et diagnostic descriptif du corpus	28
3.3	Implémentation des briques de recherche et de recommandation	36
3.4	Orchestration, interfaces et validation d’intégration	38
4	Évaluation de la performance du système	40
4.1	Objectif et logique générale de l’évaluation	40
4.2	Données et protocole expérimental	40
4.3	Évaluation du modèle d’embeddings	41
4.4	Ablation pgvector seul contre pgvector + graphe	42
4.5	Analyse du reranking par le graphe	43
4.6	Performance opérationnelle et stabilité	44
4.7	Interprétation par rapport aux hypothèses	45
4.8	Lecture des sorties graphiques de performance	45

4.9	Limites de l'évaluation	46
4.10	Synthèse du chapitre	47
5	Discussion et recommandations	48
	Conclusion générale	I
	Bibliographie	I
	Bibliographie	II
A	Annexes	V