

IA hybride, explicable et responsable pour l'appariement emploi-compétences

Du mémoire d'ingénieur à un programme doctoral

Transformer un prototype prometteur en connaissance scientifique robuste,
reproductible et évaluée par ses utilisateurs

Irch Defluviaire NGOULOU NGOUBILI

Ingénieur Statisticien Économiste — Data Science & Marketing

RECHERCHE D'ENCADREMENT DOCTORAL

Août 2026

Le problème

Offres, profils et compétences utilisent des vocabulaires hétérogènes. Une similarité textuelle élevée ne garantit ni la compatibilité ni l'explicabilité.

Le prototype

Une chaîne opérationnelle combine recherche sémantique, graphe de connaissances, *skill gap* et génération contrôlée.

Le verrou scientifique


Les gains observés reposent encore sur un proxy interne : la validité métier, la robustesse et l'effet sur la décision restent à établir.

MA PROPOSITION

faire de ces limites le cœur d'un programme doctoral testable.

Source : Mémoire, introduction générale et conclusion ; cadre d'aide à la décision inspiré de (Mortensen and Pissarides, 1994; Pissarides, 2000).

Le problème scientifique : trois erreurs à éviter



Lacune ciblée : il manque encore un cadre qui relie performance de classement, validité des explications, robustesse aux changements de domaine et bénéfice réel pour la décision humaine.

Source : Synthèse du mémoire ; Sentence-BERT (Reimers and Gurevych, 2019), graphes de connaissances (Hogan et al., 2021), RAG (Lewis et al., 2020).


Un actif empirique déjà opérationnel

Marché pilote	Référentiels	Apprentissage	Infrastructure
13 957 offres d'emploi	13 939 compétences ESCO	6 476 paires offre-description	ETL + Sentence- Transformer PostgreSQL + pgvector Neo4j + LangGraph
41 298 profils candidats	3 039 professions ESCO	953 paires de test	

Avantage doctoral : partir d'un artefact exécutable et concentrer la recherche sur la validité, la généralisation et l'interaction humain-IA.

Source : Corpus et protocole documentés dans le mémoire et l'article scientifique ; ESCO (European Commission, 2024).

Architecture : séparer les responsabilités



PRINCIPE


Le LLM ne calcule pas seul le classement.

GARDE-FOU

Chaque sortie doit revenir à une preuve.

Source : Architecture implémentée dans le mémoire ; orchestration inspirée de ReAct et Self-RAG (Yao et al., 2023; Asai et al., 2024).

Preuve 1 — l'adaptation au domaine améliore le retrieval



Encodeur adapté

NDCG@10 = 0,6232

MRR@10 = 0,5874


Recall@10 = 0,7398

Test sur 953 paires, vecteurs de 384 dimensions.

Lecture correcte : amélioration sur une tâche interne de self-retrieval, pas validation d'un recrutement.

Source : Sortie reproductible 05_embedding_benchmark_extended.csv ; métriques de recherche d'information (Thakur et al., 2021; Muennighoff et al., 2023).

Preuve 2 — le graphe améliore le classement



Ablation contrôlée

69 candidats, même pool initial de 30 offres.

	pgvector	+ graphe
NDCG@10	0,5575	0,7392
MRR@10	0,6908	0,8093
Recall@10	0,4491	0,6147

C'est le résultat le mieux identifié du **mémoire**, mais la pertinence reste définie par un proxy.

Source : Sortie 13_ablation_pgvector_neo4j_reranking.csv ; 11 candidats initialement tirés exclus après erreurs techniques.

Preuve 3 — expliquer, puis contrôler l'ancrage

Explication relationnelle

Pour chaque candidat-offre :

- ▶ compétences possédées et requises ;
- ▶ couverture $|K_c \cap K_o| / |K_o|$;
- ▶ compétences manquantes $K_o \setminus K_c$;
- ▶ chemins métier-formation mobilisés.

Critic contrastif

Au seuil 0,46, le protocole accepte 50/51 vrais contextes et rejette 51/51 contextes mélangés.

Il mesure un ancrage lexical, pas la vérité métier.

APPORT

Une recommandation devient inspectable.
pas encore validée par l'utilisateur.

LIMITE

L'explication n'est

Source : Mémoire, chapitres d'évaluation et de discussion ; évaluation RAG (Es et al., 2024).

Conclusions défendables

- ▶ faisabilité d'un pipeline modulaire ;
- ▶ gain interne du graphe sur le même vivier ;
- ▶ production d'un *skill gap* traçable ;
- ▶ mécanisme expérimental de contrôle des réponses.

Conclusions non établies

- ▶ meilleure qualité réelle des recrutements ;
- ▶ amélioration causale de l'emploi ;
- ▶ absence de biais entre sous-groupes ;
- ▶ robustesse temporelle et intersectorielle ;
- ▶ utilité des explications pour les décideurs.

La thèse ne prolongera pas une promesse : elle organisera des tests capables de la réfuter.

Source : Discussion et limites du mémoire et de l'article scientifique.

Comment concevoir et évaluer des systèmes hybrides emploi-compétences qui demeurent pertinents, explicables et équitables sous hétérogénéité des données, changement de domaine et contrôle humain ?

PERTINENCE

annotations expertes et
évaluation hors échantillon

ROBUSTESSE

secteurs, temps, sources et
sous-groupes

DÉCISION HUMAINE

compréhension, calibration
et contestabilité

Source : Proposition originale dérivée des limites empiriques du mémoire.

Quatre questions de recherche, une progression logique

- RQ1 Validité.** Comment construire une vérité terrain indépendante et mesurer l'accord entre experts ?
- RQ2 Généralisation.** Quels composants restent performants sous changement temporel, sectoriel ou lexical ?
- RQ3 Confiance.** Les chemins du graphe et les preuves récupérées améliorent-ils réellement la compréhension et la calibration du jugement humain ?
- RQ4 Équité.** Où apparaissent les écarts de performance entre sous-groupes, et quelles contraintes réduisent les erreurs injustifiées sans masquer les compromis ?


Unité d'analyse : la recommandation candidat-offre, son rang, ses preuves, son incertitude et son effet sur un évaluateur humain.

Hypothèses falsifiables — pas de promesse technologique

	Hypothèse	Test décisif
H1	L'adaptation au domaine améliore le classement jugé pertinent par des experts indépendants.	Holdout temporel ; comparaison BM25, encodeurs génériques et adapté.
H2	Le reranking relationnel apporte un gain au-delà du retrieval sémantique.	Ablations à pool constant ; intervalles bootstrap ; tests appariés.
H3	Une explication fondée sur des preuves améliore la décision humaine.	Expérience contrôlée : liste seule vs score vs explication + incertitude.
H4	Des contraintes explicites peuvent réduire certains écarts d'erreur entre sous-groupes.	Audit désagrégé ; seuils et compromis performance-équité préspecifiés.

Source : Les hypothèses finales seront resserrées avec le directeur de thèse et préenregistrées avant l'évaluation confirmatoire.

Design empirique : construction, calibration, preuve



Mesures système

NDCG/MRR/Recall, calibration, robustesse, latence, coût et fidélité aux preuves.

Mesures humaines

précision de décision, temps, confiance calibrée, compréhension et capacité de contestation.

Inférence

- ▶ tailles d'effet et intervalles de confiance ;
- ▶ bootstrap par requête/candidat ;
- ▶ tests appariés et correction de multiplicité ;
- ▶ analyse de puissance pour l'étude utilisateur ;
- ▶ sensibilité aux définitions de pertinence.

Prévention des faux progrès

- ▶ jeu de test gelé et holdout temporel ;
- ▶ proxy interdit comme vérité finale ;
- ▶ ablations à vivier identique ;
- ▶ données manquantes et échecs explicités ;
- ▶ protocole, code et versions archivés.

LIGNE ROUGE

Pas d'impact sur l'emploi revendiqué sans design causal approprié.

Feuille de route doctorale sur 36 mois



Année 1

Gouvernance des données,
revue systématique,
annotation experte,
baselines.

Année 2

Nouveaux modèles hybrides,
robustesse, incertitude et
audit par sous-groupes.

Année 3

Étude utilisateur, pilote
encadré, articles, synthèse et
transfert reproductible.

Jalons : J1 benchmark

J2 modèle robuste

J3 preuve utilisateur

J4 thèse

Article 1

Benchmark

emploi-compétences

Annotation multi-experts,
temporalité, désaccord et
protocole de référence.

Article 2

Retrieval hybride robuste

Ablations, incertitude,
changement de domaine et
contraintes relationnelles.

Article 3

Explications utiles

Effet des preuves et du *skill gap* sur la qualité de
décision humaine.

**Livrable transversal : un cadre reproductible et auditable, transférable
à d'autres marchés où les historiques d'interaction sont rares.**

Source : Les cibles de publication et le périmètre exact seront définis avec l'équipe d'accueil.

Risque	Conséquence	Réponse méthodologique
Peu d'annotations expertes	vérité terrain fragile	échantillonnage actif, double codage, analyse du désaccord
Données privées/incomplètes	reproductibilité limitée	artefacts anonymisés, contrats de données, jeux synthétiques de test
Dérive temporelle/sectorielle	performance non transportable	splits temporels, stress tests, recalibration documentée
Biais de sélection	écarts invisibles	audits désagrégés, fiches de données, limites d'usage explicites
Explication persuasive mais fausse	confiance mal placée	citations de preuves, critic séparé, possibilité d'abstention et recours humain

Actifs immédiatement mobilisables

- ▶ une double formation statistique, économique et Data Science
- ▶ un pipeline complet déjà implémenté
- ▶ un corpus pilote et des référentiels structurés
- ▶ une évaluation reproductible et une connaissance du contexte camerounais.

Encadrement recherché

- ▶ resserrer la question et l'ancrage théorique
- ▶ challenger le design expérimental et statistique
- ▶ accéder à un environnement exigeant et à des partenaires d'annotation
- ▶ viser des contributions publiables, pas une simple plateforme.

POSTURE

Je cherche un encadrement qui teste mes idées, pas une validation du prototype.

À fixer ensemble

question centrale, terrain, population, accès aux experts, discipline d'inscription et contraintes éthiques.

À challenger

définition de pertinence, hypothèses, identification, comparateurs, métriques et stratégie de publication.

À préserver

séparation système/métier, traçabilité, décision humaine et honnêteté sur l'incertitude.

**Mon objectif : passer d'un système qui fonctionne
à une connaissance qui résiste à la critique.**

**Un terrain pertinent. Un prototype exécutable.
Des limites explicites. Des hypothèses falsifiables.**

**Je vous propose de transformer ce point de départ en
un programme doctoral rigoureux sur la recomman-
dation hybride, l'explicabilité et la décision humaine.**

PROCHAINE ÉTAPE

Discuter l'alignement avec vos axes, le terrain d'évaluation et un premier protocole d'annotation.

Merci pour votre attention — discussion

$$s_{\text{vec}}(q, o) = \frac{e(q) \cdot e(o)}{\|e(q)\|_2 \|e(o)\|_2},$$

$$s_{\text{graph}}(c, o) = \frac{|K_c \cap K_o|}{|K_o|},$$

$$s_{\text{hyb}}(c, o) = \alpha s_{\text{vec}}(c, o) + \beta s_{\text{graph}}(c, o), \quad \alpha + \beta = 1,$$

$$\text{gap}(c, o) = K_o \setminus K_c.$$

La calibration dépend de la fonction objectif et du proxy : elle n'est pas transportable sans réestimation.

Brique	Échantillon	Portée
Encodeur adapté	953 paires de test	self-retrieval sur paires offre–description
Ablation du graphe	69 candidats, pool de 30 offres	comparaison à vivier constant selon proxy
Optuna	690 couples, 500 essais	poids dépendants de l'objectif et de l'échantillon
Critic	51 vrais + 51 contextes mélangés	ancrage lexical contrastif au seuil 0,46

Limite commune

Aucune de ces évaluations ne remplace une annotation métier indépendante ou une étude utilisateur confirmatoire.

- Akari Asai, Zeqiu Wu, Yizhong Wang, Avirup Sil, and Hannaneh Hajishirzi. Self-rag: Learning to retrieve, generate, and critique through self-reflection. In *International Conference on Learning Representations*, 2024. URL <https://openreview.net/forum?id=hSyW5go0v8>.
- Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. RAGAS: Automated evaluation of retrieval augmented generation. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics: System Demonstrations*, pages 150–158, 2024. URL <https://aclanthology.org/2024.eacl-demo.16/>.
- European Commission. Esco: European skills, competences, qualifications and occupations, 2024. URL <https://esco.ec.europa.eu/>.
- Aidan Hogan, Eva Blomqvist, Michael Cochez, Claudia d'Amato, Gerard de Melo, Claudio Gutierrez, Sabrina Kirrane, José Emilio Labra Gayo, Roberto Navigli, Sebastian Neumaier, et al. Knowledge graphs. *ACM Computing Surveys*, 54(4):1–37, 2021. doi: 10.1145/3447772.

- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in Neural Information Processing Systems*, 33:9459–9474, 2020. URL <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- Dale T. Mortensen and Christopher A. Pissarides. Job creation and job destruction in the theory of unemployment. *The Review of Economic Studies*, 61(3):397–415, 1994. doi: 10.2307/2297896.
- Niklas Muennighoff, Nouamane Tazi, Loïc Magne, and Nils Reimers. MTEB: Massive text embedding benchmark. In *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*, pages 2014–2037, 2023. URL <https://aclanthology.org/2023.eacl-main.148/>.
- Christopher A. Pissarides. *Equilibrium Unemployment Theory*. MIT Press, Cambridge, MA, 2 edition, 2000.

- Nils Reimers and Iryna Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. In *Proceedings of EMNLP-IJCNLP*, pages 3982–3992, 2019. URL <https://aclanthology.org/D19-1410/>.
- Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. BEIR: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. In *Advances in Neural Information Processing Systems*, volume 34, pages 28974–28989, 2021. URL <https://arxiv.org/abs/2104.08663>.
- Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. React: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations*, 2023. URL https://openreview.net/forum?id=WE_vluYUL-X.